



人工智能数学基础

Essential Math for AI

第4章 不确定度量与熵

哈尔滨工业大学计算学部人工智能专业 刘绍辉

shliu@hit.edu.cn

微信: shliu13403627844

2026年4月8日




内容介绍

- 4.1 信息
- 4.2 通信系统模型
- 4.3 自信息量
- 4.4 熵-离散信源最大熵定理
- 4.5 平均互信息量、相对熵

4.1 信息——信息、消息、信号

- 信号是消息的物理表现形式，如声波、光波、电磁波等
- 消息是信号的具体内容。



信息

4.1 信息——信息的特性

- 信息是无形的
- 信息是可共享的
- 信息是无限的
 - 是一种取之不尽、用之不竭的资源
 - 时空上的可扩展：具有时效性；前后信息相连，会提供新信息。
- 信息是可度量的
 - 信息的度量是信息论的重要研究内容之一

4.1信息

- 概念——通俗概念




电话



报纸

“信息=消息”



电视



网络

- 虽然直观通俗、容易理解，但是并不准确。

地球绕着太阳转

这是众所周知的事情，信息量约为0

消息

4.1 信息

- 概念二——广义概念

“信息是对物质存在和运动形式的一般描述”

“信息是认识主体（人、生物、机器）所感受的事物运动状态和变换方式”

- 这个概念不容易定量描述，更接近于一个哲学概念。

4.1信息

- 概念三——概率信息，又称为狭义信息
 - “信息是用来消除不确定性的东西”
- 由美国数学家[香农](#)(Claude Elwood Shannon, 1916-2001)提出来的，故又称香农信息。
- 用事件发生的概率衡量它的信息量
 - 事件发生的概率越大，它提供的信息量就越小。
 - 事件“中国足球队0:1负于韩国足球队”
 - 事件发生的概率越小，一旦该事件发生，它发生后提供的信息量越大
 - 事件“中国足球队4:0力克韩国足球队”
- 研究概率信息，简称信息。


4.2 通信系统模型

- 研究对象：通用通信系统

- 通信系统的基本问题：在某一点精确或近似地恢复另一点发送的信息。

信息论是通信的数学理论

4.2 通信系统模型




通信系统模型


4.2 通信系统模型

- **信源**：产生消息的源泉
- **信宿**：信息的接受者
- **编码器**：将消息变换成适合于信道传输的形式
 - **信源编码**：压缩
 - **信道编码**：纠错
 - **保密编码**：保证信息的安全性
 - **调制**：将消息变换成适合信道传输的信号形式（物理的方法）
- **译码器**：编码的逆变换
- **信道**：将信号从发射端传到接受端的通道
- **干扰源（噪声源）**：信道中的噪声

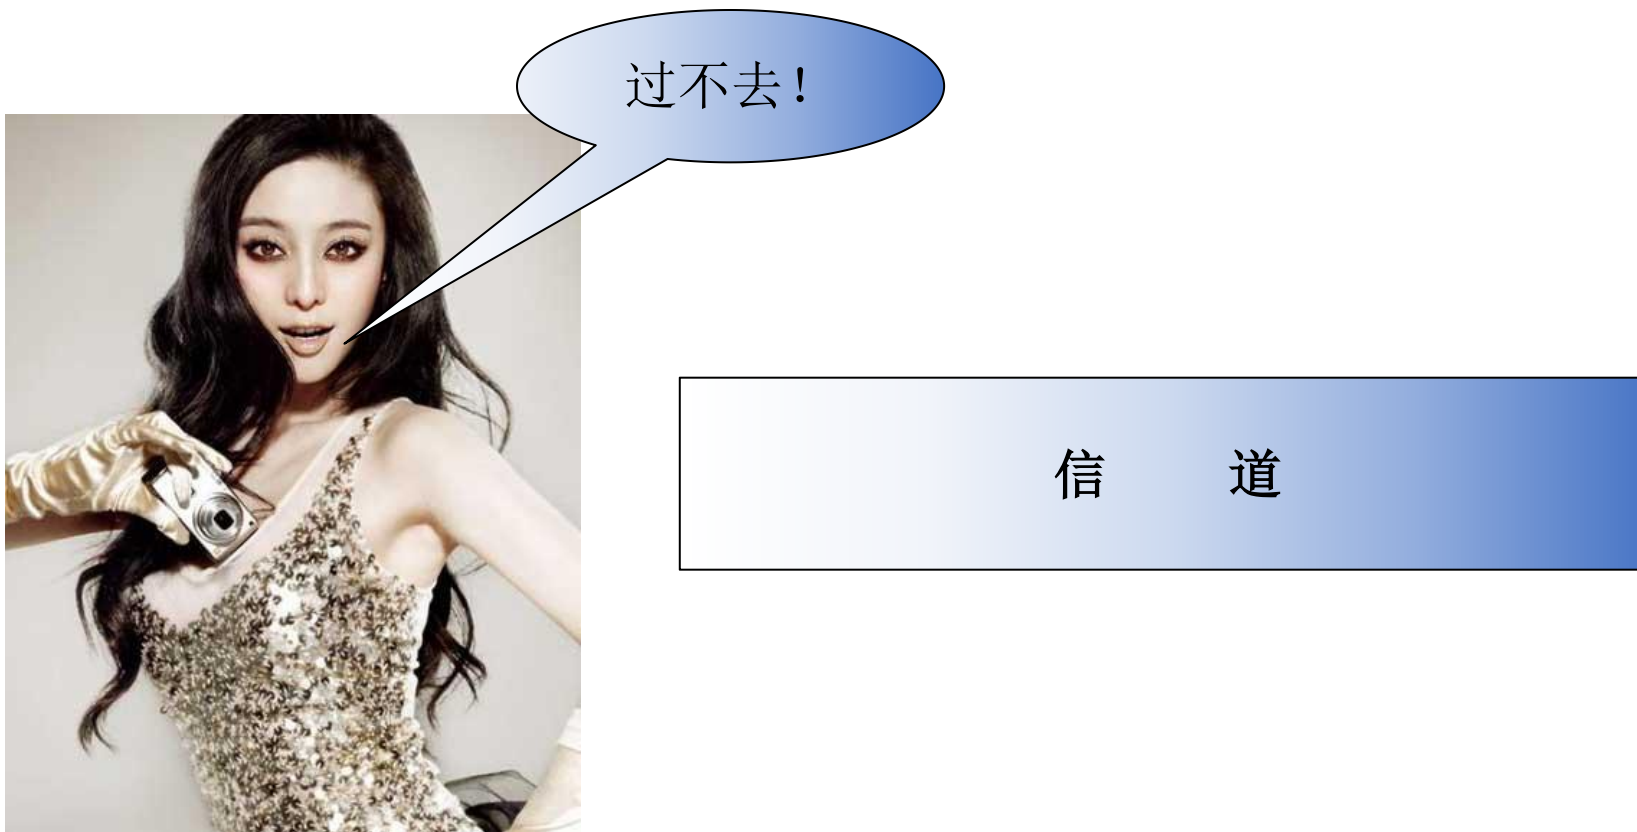
4.2 通信系统模型




4.2 通信系统模型



4.2 通信系统模型——信源编码的主要目的




4.2 通信系统模型——信源编码的主要目的




压缩！使信号能够更加有效地传输信息！

4.2 通信系统模型




细化的通信系统模型

4.2 通信系统模型——信道编码的主要目的




纠错！使信号能够更加可靠地传输信息！

4.2 通信系统模型




4.2 通信系统模型——调制的主要目的

使信号更加适合在信道中传输！




4.2 通信系统模型——调制的主要目的



调制示意图

4.2 通信系统模型



- **香农第一定理**——为了无失真地传输信源信息，信源编码的极限是什么？
- **香农第二定理**——在有噪信道中无失真地通信，信道编码的极限是多少？
- **香农第三定理**——如果允许一定量的失真，信源编码的极限是什么？

4.2 通信系统模型

- 信息论的研究目标：以通用的通信系统为研究对象，找到信息传输过程的共同规律，以提高信息传输的

有效性、可靠性、安全性

- 数字通信的三项基本技术：**数据压缩、数据纠错、数据加密**

香农奠定了这三项技术的理论基础！

4.3 自信息量

- 信源的**不肯定性**
 - 同学听课，要获得信息，必须从老师那里学到事先不知道的信息
 - 信源发出消息的状态存在某种程度的不肯定性，收到之后，消除了不肯定性
 - **信息的多少**与信源的不肯定性有关
- 例：有一个布袋，装99个红球，1个白球，随意拿出一个，猜测是红球还是白球？各40个呢？如果是红、白、黑、黄各24个呢？不肯定程度如何？与概率空间的状态数和概率有何关系？

4.3 自信息量

- 信息量与不确定度

- 事件发生的概率越大，它提供的信息量就越小。

- 事件“中国足球队0:1负于巴西足球队”

- 事件发生的概率越小，一旦该事件发生，它发生后提供的信息量越大

- 事件“中国足球队4:0力克巴西足球队”

事件 x_i 的信息量 $I(x_i)$ 应该是该事件的概率的函数


$$I(x_i) = f[P(x_i)].$$

4.3 自信息量

- 根据客观事实和人们的习惯，函数应满足：
 1. $f[P(x_i)]$ 应该是 $P(x_i)$ 的单调递减函数，
若 $P(x_1) > P(x_2)$ ， $f[P(x_1)] < f[P(x_2)]$
 2. 当 $P(x_i) = 1$ ， $f[P(x_i)] = 0$
 3. 当 $P(x_i) = 0$ ， $f[P(x_i)] = \infty$
 4. 两个独立事件的联合信息量应该等于各自信息量之和。

4.3 自信息量

- **定义4.3.1** 任意随机事件的**自信息量**定义为该事件发生概率的对数的负值。
- 假设事件 x_i 发生的概率为 $p(x_i)$ ，则其自信息定义为 $I(x_i) = -\log p(x_i)$
 - 自信息量的单位与log函数所选用的对数底数有关，如底数分别取 2、 e 、10，则自信息量单位分别为：**比特**、**奈特**、**哈特**
 - 事件 x_i 发生以前，表示事件发生的先验不确定性
 - 当事件 x_i 发生以后，表示事件 x_i 所能提供的最大信息量（在无噪情况下）



4.3 自信息量

- 1. $f[P(x_i)]$ 应该是 $P(x_i)$ 的单调递减函数,
- 若 $P(x_1) > P(x_2)$, $f[P(x_1)] < f[P(x_2)]$
- 2. 当 $P(x_i) = 1$, $f[P(x_i)] = 0$
- 3. 当 $P(x_i) = 0$, $f[P(x_i)] = \infty$
- 4. 两个独立事件的联合信息量应该等于各自信息量之和。

$$\begin{aligned} I(x_1, x_2) &= -\log P(x_1 x_2) \\ &= -\log P(x_1)P(x_2) \\ &= -[\log P(x_1) + \log P(x_2)] \\ &= I(x_1) + I(x_2). \end{aligned}$$

4.3 自信息量-随机事件的不确定性

举例：

- 假设事件“中国足球队0:1负于巴西足球队”
这个事件发生的概率是99 %，则该事件的自信息量为：

$$-\log(0.99) = 0.0145 \text{ bit}$$

- 该事件的不确定性小，自信息量小。

- 假设事件“中国足球队4:0力克巴西足球队”
发生的概率是1%，则该事件的自信息量为：

$$-\log(0.01) = 6.6439 \text{ bit}$$

- 该事件的不确定性大，自信息量大。

4.3 自信息量

- 设在甲袋中放入 n 个不同阻值的电阻 $x_1, x_2, \dots, x_n, x_i$ 的电阻值为 i , 每个电阻被取出的概率是相等的, 则事件“取出的电阻的阻值为 i ”的信息量是多少?
- 解: $\because p(x_i) = \frac{1}{n}, \therefore I(x_i) = -\log p(x_i) = -\log \frac{1}{n} = \log n.$
- 设在甲袋中放入 $\frac{1}{2}n(n+1)$ 个不同阻值的电阻, 其中 1Ω 的 1 个, 2Ω 的 2 个, ..., $n\Omega$ 的 n 个, 则事件“取出的电阻的阻值为 i ”的信息量是多少?
- 解: $\because p(x_i) = \frac{i}{\frac{1}{2}n(n+1)}, \therefore I(x_i) = -\log p(x_i) = -\log \frac{i}{\frac{1}{2}n(n+1)} = \log \frac{n(n+1)}{2i}.$

4.3 自信息量-信源描述

- **离散无记忆信源**(Discrete Memoryless Source, 简记为DMS)输出的是单个符号的消息, 不同时刻发出的符号之间彼此统计独立, 而且符号集中的符号数目是有限的或可数的。离散无记忆信源的数学模型为离散型的概率空间, 即

$$\begin{bmatrix} X \\ P(X) \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & \cdots & x_I \\ p(x_1) & p(x_2) & \cdots & p(x_I) \end{bmatrix}$$

- $p(x_i)$: 信源输出符号消息 x_i 的先验概率; 满足: $0 \leq p(x_i) \leq 1, \quad 1 \leq i \leq I$

4.3 自信息量-信源描述

- **离散平稳有记忆信源**用联合概率空间 $\{X, P(X)\}$ 来描述离散有记忆信源的输出。信源在 i 时刻发出什么符号与 i 时刻以前信源所发出的符号有关，即由条件概率 $p(x_i | x_{i-1} x_{i-2} \dots)$ 确定。如果该条件概率分布与时间起点无关，只与关联长度有关，则该信源为**平稳信源**。

对于离散平稳有记忆信源，有：

$$p(x_1 = a_1) = p(x_2 = a_1) = \dots$$

$$p(x_2 = a_2 | x_1 = a_1) = p(x_3 = a_2 | x_2 = a_1) = \dots$$

$$p(x_3 | x_2 x_1) = p(x_4 | x_3 x_2) = \dots$$

$$\vdots$$

$$p(x_{i+L} | x_{i+L-1} x_{i+L-2} \dots x_i) = p(x_{j+L} | x_{j+L-1} x_{j+L-2} \dots x_j) = \dots$$

$$\vdots$$

4.3 自信息量-信道描述

- 离散无记忆信道

- 离散无记忆信道的输入和输出消息都是离散无记忆的单个符号，输入符号 $x_i \in \{a_1, a_2, \dots, a_k\}$, $1 \leq i \leq I$, 输出符号 $y_j \in \{b_1, b_2, \dots, b_D\}$, $1 \leq j \leq J$, 信道的特性可表示为转移概率矩阵:


$$\mathbf{P} = \begin{bmatrix} p(y_1|x_1) & p(y_2|x_1) & \cdots & p(y_J|x_1) \\ p(y_1|x_2) & p(y_2|x_2) & \cdots & p(y_J|x_2) \\ \vdots & \vdots & \ddots & \vdots \\ p(y_1|x_I) & p(y_2|x_I) & \cdots & p(y_J|x_I) \end{bmatrix}$$

- $p(y_j|x_i)$ 对应为已知输入符号为 x_i , 当输出符号为 y_j 时的信道转移概率, 满足 $0 \leq p(y_j|x_i) \leq 1$

4.3 自信息量-信道描述-几种常见的离散无记忆信道

- **1. 二元对称信道** (Binary Symmetric Channel, 简记为BSC)

- 这是一种很重要的信道，它的输入符号 $x \in \{0, 1\}$ ，输出符号 $y \in \{0, 1\}$ ，转移概率 $p(y|x)$ 如图所示信道特性可表示为信道矩阵 $P = \begin{bmatrix} 1-p & p \\ p & 1-p \end{bmatrix}$ ，其中 p 称作信道错误概率。




4.3 自信息量-信道描述-几种常见的离散无记忆信道

• 2. 无干扰信道

- 这是一种最理想的信道，也称作无噪信道，信道的输入和输出符号间有确定的一一对应关系， $p(y|x) = \begin{cases} 1 & x = y \\ 0 & x \neq y \end{cases}$ ，如图三元无干扰信道中， $x, y \in \{0, 1, 2\}$ ，对应信道矩阵是单位矩阵

$$\mathbf{P} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$



无干扰信道

3. 二元删除信道

对于接收符号不能作出肯定或否定判决时，引入删除符号，表示对该符号存有疑问，作为有误或等待得到更多信息时再作判决。

二元删除信道如图所示，输入符号 $x \in \{0, 1\}$ ，输出符号 $y \in \{0, e, 1\}$ ，转移概率矩阵为 $P =$

$$\begin{bmatrix} p & 1-p & 0 \\ 0 & 1-p & p \end{bmatrix}$$

4. 二元Z信道

二元Z信道如图所示，信道输入符号 $x \in \{0, 1\}$ ，输出符号 $y \in \{0, 1\}$ 转移概率矩阵为 $P =$

$$\begin{bmatrix} 1 & 0 \\ p & 1-p \end{bmatrix}$$




图 二元删除信道




图 二元Z信道

4.3 自信息量

- 信息量
 - 受信者从不肯定到比较肯定或完全肯定，就是从不知道变成比较知道或完全知道
 - 通过通信来获得信息
 - 获得信息不够->比较肯定
 - 获得足够的信息->完全肯定
 - $I(\text{信息量}) = \text{不肯定程度的减少量}$
- 减少的原因？
 - 概率空间的概率分布改变所致

4.3 自信息量

- 假设信源 X 用概率空间描述为: $\begin{bmatrix} X \\ P(X) \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \\ p_1 & p_2 & \cdots & p_n \end{bmatrix}$, 任意事件 $x_i \in X$, 其自信息量为 $I(x_i) = -\log p_i$
- 从通信的角度, 信源发送消息 x_i , 受信者收到消息 Y 后, 不确定程度减少, 消息 Y 的概率空间描述为: $\begin{bmatrix} Y \\ P(X|Y) \end{bmatrix} = \begin{bmatrix} y_1 & y_2 & \cdots & y_n \\ p_1(x_1|y_1) & p_2(x_2|y_n) & \cdots & p_n(x_n|y_n) \end{bmatrix}$, 其不确定程度为: $H(X|Y) = H(P(X|Y))$
- $P(X), P(X|Y)$ 分别表示受信者收到信息前后的先验概率和后验概率, 这时候收到消息 y_j 后所获得的信息量表示为:

$$I_j = I(x_i) - I(x_i|y_j) = \log \left(\frac{p(x_i|y_j)}{p(x_i)} \right) = \log \left(\frac{\text{后验概率}}{\text{先验概率}} \right)$$

- 称之为互信息量
- 推广到联合自信息量和条件自信息量: $I(x_i, y_j) = -\log p(x_i, y_j)$, $I(x|y) = -\log p(x|y)$

4.3 自信息量-互信息量


- **定义2** 随机事件 y 的出现给出关于事件 x 的信息量，定义为**互信息量**。
定义式： $I(x; y) = \log \frac{p(x|y)}{p(x)}$
- 单位：同自信息量.
- 含义：本身的不确定性，减去知道事件 y 之后仍然保留的不确定性，就是**由 y 所提供的关于 x 的信息量**，或者说**由 y 所消除的关于 x 的不确定性**
- 互信息量=**原有的不确定性 - 尚存在的不确定性**
- **定义3** 则平均意义上来说，信源 X 的不确定程度可以表示为 **$H(X) = -\sum_{i=1}^n p_i \log p_i$** ，称为信源 X 的**熵**！
 - 等价于每个事件的自信息量的平均值（或期望）
 - $H(X) = E(I(x_i)) = E[-\log p(x_i)] = -\sum_{i=1}^n p(x_i) \log p(x_i)$

4.3 互信息量、熵

- 互信息量的性质

- 对称性 $I(x;y) = I(y;x)$: 由 y 所提供的关于 x 的信息量 = 由 x 所提供的关于 y 的信息量
- 当事件 x 、 y 统计独立时, 互信息量为 0: $p(x|y)=p(x)$, x 和 y 之间没有什么关系, 无论是否知道 y , 都对 x 出现的概率没有影响
- 可正可负: y 的出现有利/不利于确定 x 的发生
 - 正: $I(x;y) = \log \frac{p(x|y)}{p(x)} > 0 \Rightarrow \frac{p(x|y)}{p(x)} > 1 \Rightarrow p(x|y) > p(x)$, x : 张三病了。 y : 张三没来上课。
 - 负: $I(x;y) = \log \frac{p(x|y)}{p(x)} < 0 \Rightarrow \frac{p(x|y)}{p(x)} < 1 \Rightarrow p(x|y) < p(x)$, x : 李四考了全班第一名。 y : 李四没有复习功课。

- 互信息量不大于任一事件的自信息量 $I(x;y) = I(x) - I(x|y)$
 $I(y;x) = I(y) - I(y|x).$



4.4熵-离散信源最大熵定理

- 熵 (entropy)
 - 条件熵: $H(X|Y) = \sum_{XY} p(x, y) I(x|y) = - \sum_{XY} p(x, y) \log p(x|y)$
 - 若 X 表示输入, Y 表示输出, $H(X|Y)$ 表示信道损失
 - 联合熵 (共熵): $H(X, Y) = \sum_{XY} p(x, y) I(x, y) = - \sum_{XY} p(xy) \log p(x, y)$
- 熵的性质
- 1. 对称性: 与整体有关, 个体无关
- 2. 非负性: $H(X) \geq 0$; $H(X) = E[I(x_i)] = \sum_{i=1}^n p(x_i) \log \frac{1}{p(x_i)}$
- 3. 扩展性: $\lim_{\varepsilon \rightarrow 0} H_{q+1}(p_1, p_2, \dots, p_q - \varepsilon, \varepsilon) = H_q(p_1, p_2, \dots, p_q)$
 - 集合 X 有 q 个事件, 集合 Y 比 X 仅仅是多了一个概率接近0的事件, 则两个集合的熵值一样
 - 证明: $x \log x$ 在 $[0, \infty)$ 的连续性, $\lim_{x \rightarrow 0} x \log x = 0$
 - 含义: 集合中, 一个事件发生的概率比其它事件发生的概率小得多时, 这个事件对于集合的熵值的贡献可以忽略

4.4熵-离散信源最大熵定理

- 4. 可加性: 设 X 和 Y 为两个互相关联的随机变量, X 的概率分布为 $\{p_1, p_2, \dots, p_m\}$, Y 的概率分布为 $\{q_1, q_2, \dots, q_n\}$, 则 $H(Y|X)$.

$$H(XY) = H(X) +$$

- 当 X 、 Y 相互独立时, $H(X, Y) = H(X) + H(Y)$

- 5. 极值性: $H(p_1, p_2, \dots, p_n) \leq H(\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n}) = \log n$, $H(X) \leq 1$

- 离散信源最大熵定理: 各事件等概率发生时, 熵最大

- $$\begin{bmatrix} X \\ p \end{bmatrix} = \begin{bmatrix} x_1 & x_2 \\ p & 1-p \end{bmatrix}$$



- $$H(X) = -p \log p - (1-p) \log (1-p)$$

- $$\begin{bmatrix} X \\ p \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & x_3 \\ p_1 & p_2 & 1-p_1-p_2 \end{bmatrix}$$

- $$H(X) = -p_1 \log p_1 - p_2 \log p_2 - (1-p_1-p_2) \log (1-p_1-p_2)$$

- 6. 确定性


- 7. 上凸性



4.4熵-离散信源最大熵定理

- 问题：求熵的最大值 $H(X) = -\sum_{i=1}^n p_i \log p_i$,
subject to $\sum_{i=1}^n p_i = 1$
- **定义4.3.2** 如果 $f[\alpha x_1 + (1-\alpha)x_2] \geq \alpha f(x_1) + (1-\alpha)f(x_2)$, 其中 $0 < \alpha < 1$, 称 $f(x)$ 为**凹函数**
(上凸函数)。如果 $f[\alpha x_1 + (1-\alpha)x_2] > \alpha f(x_1) + (1-\alpha)f(x_2)$, 则称 $f(x)$ 为**严格凹函数**
(上凸函数)
- 类似的, 有凸函数 (下凸函数) 以及严格凸函数的定义
- 对于凹函数 (上凸函数), 有**詹森 (Jensen) 不等式**

$$f(E[x]) \geq E[f(x)]$$



4.4熵-离散信源最大熵定理

- **问题**: 求熵的最大值 $H(X) = -\sum_{i=1}^n p_i \log p_i$, subject to $\sum_{i=1}^n p_i = 1$
- **引理**: 如果 $\sum_{i=1}^n p_i = 1, \sum_{i=1}^n q_i = 1$, 则 $\sum_{i=1}^n p_i \log\left(\frac{1}{p_i}\right) \leq \sum_{i=1}^n p_i \log\left(\frac{1}{q_i}\right)$, 当前仅当对 $\forall i, p_i = q_i$ 时等号成立!
- **证明**: $\because \forall x > 0, \log x \leq x - 1$, 等号仅当 $x = 1$ 成立, $\therefore$
$$\sum_{i=1}^n p_i \log\left(\frac{1}{p_i}\right) - \sum_{i=1}^n p_i \log\left(\frac{1}{q_i}\right) = \sum_{i=1}^n p_i \log\left(\frac{q_i}{p_i}\right) \leq \sum_{i=1}^n p_i \left(\frac{q_i}{p_i} - 1\right) = \sum_{i=1}^n (q_i - p_i) = 0 \blacksquare$$
- 按照之前的思路, 需要证明 $H(X)$ 是概率的上凸函数, 即设 P_1, P_2 是两个概率分布, $0 < \alpha < 1$, 证明:
 $H[\alpha P_1 + (1 - \alpha)P_2] > \alpha H(P_1) + (1 - \alpha)H(P_2)$
- 证明: 根据引理, 令 $q_i = \alpha p_{1i} + (1 - \alpha)p_{2i}$, 因为 $0 < \alpha < 1$, 因此 $p_{1i} \neq q_i (\forall i)$, 不满足引理等号成立的条件。
 $\therefore \sum_{i=1}^n p_{1i} \log\left(\frac{1}{p_{1i}}\right) \leq \sum_{i=1}^n p_{1i} \log\left(\frac{1}{q_i}\right)$, 因此 $\sum_{i=1}^n p_{1i} \log\left(\frac{q_i}{p_{1i}}\right) < 0$, 代入 q_i ,
- $$H[\alpha P_1 + (1 - \alpha)P_2] - \alpha H(P_1) + (1 - \alpha)H(P_2) = -\sum_{i=1}^n (\alpha p_{1i} + (1 - \alpha)p_{2i}) \log(\alpha p_{1i} + (1 - \alpha)p_{2i}) +$$
$$\alpha \sum_{i=1}^n p_{1i} \log p_{1i} + (1 - \alpha) \sum_{i=1}^n p_{2i} \log p_{2i} = \alpha \sum_{i=1}^n p_{1i} \log\left(\frac{p_{1i}}{\alpha p_{1i} + (1 - \alpha)p_{2i}}\right) + (1 - \alpha) \sum_{i=1}^n p_{2i} \log\left(\frac{p_{2i}}{\alpha p_{1i} + (1 - \alpha)p_{2i}}\right) =$$
$$\alpha \sum_{i=1}^n p_{1i} \log\left(\frac{p_{1i}}{q_i}\right) + (1 - \alpha) \sum_{i=1}^n p_{2i} \log\left(\frac{p_{2i}}{q_i}\right) > 0$$
- 因此, 得证 $H(X)$ 是凹函数或上凸函数!

4.4熵-离散信源最大熵定理

- 求熵的最大值 $H(X) = -\sum_{i=1}^n p_i \log p_i$, subject to $\sum_{i=1}^n p_i = 1$
- **解**: 根据拉格朗日乘子法, 目标函数 $f(p_i, \lambda) = H(X) + \lambda(\sum p_i - 1)$, 对参数求偏导数, 并令其为0, 则有
$$\begin{cases} \frac{\partial f}{\partial p_i} = -\log p_i - p_i \cdot \frac{1}{p_i} + \lambda = 0 \\ \sum p_i - 1 = 0 \end{cases} \Rightarrow \begin{cases} \log p_i = \lambda - 1 \\ \sum p_i = 1 \end{cases} \Rightarrow \begin{cases} p_i = e^{\lambda-1} \\ n e^{\lambda-1} = 1 \end{cases} \text{从}$$
- 而, 可得 $p_i = \frac{1}{n}$
- 熵函数的形式除了一个常数倍外是唯一确定的!

4.4熵-离散信源最大熵定理

- **定理**: 设离散随机变量的概率空间为 $\left[\begin{matrix} X \\ P(X) \end{matrix} \right] = \left[\begin{matrix} x_1 & x_2 & \cdots & x_N \\ p_1 & p_2 & \cdots & p_N \end{matrix} \right]$, 函数 $f(p_1, p_2, \cdots, p_N)$ 是随机变量不确定的度量, 若此函数满足条件: 1) 连续性; 2) 单调性; 3) 可加性, 则此函数必为 $f(p_1, p_2, \cdots, p_N) = -C \sum_{i=1}^N p_i \log p_i$, 其中 C 为常数
- **证明**: (1) 考虑随机变量 X 为等概分布的情况, 这时有 $p_i = \frac{1}{N}, i = 1, \cdots, N$ 。由条件3) 可知:
 $g(MN) = f\left(\frac{1}{MN}, \frac{1}{MN}, \cdots, \frac{1}{MN}\right) = g(M) + \sum_{i=1}^M \frac{1}{M} g(N) = g(M) + g(N)$, 则有 $g(s^m) = mg(s), g(t^n) = ng(t)$, 其中 s, t, m, n 都是正整数
- 显然, 我们可以选择 m, n , 使之满足 $s^m \leq t^n < s^{m+1}$, 取对数则有:
- $m \log s \leq n \log t < (m+1) \log s$, 同时除以 $n \log s$, 则有 $\frac{m}{n} \leq \frac{\log t}{\log s} < \frac{m+1}{n}$, 因此有 $\left| \frac{m}{n} - \frac{\log t}{\log s} \right| < \frac{1}{n}$, 由条件2), $mg(s) \leq ng(t) \leq (m+1)g(s)$, 两边除以 $ng(s)$, 得: $\frac{m}{n} \leq \frac{g(t)}{g(s)} < \frac{m+1}{n}$, 因此有 $\left| \frac{m}{n} - \frac{g(t)}{g(s)} \right| < \frac{1}{n}$, 因此, 根据 $|a \pm b| \leq |a| + |b|$ 得: $\left| \frac{g(t)}{g(s)} - \frac{\log t}{\log s} \right| < \frac{2}{n}$, 由于 s, t 任意, n 可任意大, 因此有: $\frac{g(t)}{g(s)} = \frac{\log t}{\log s}$, 即 $g(t) = C \log t$, 其中 C 为常数!


4.4熵-离散信源最大熵定理

- 定理：设离散随机变量的概率空间为 $\left[\begin{matrix} X \\ P(X) \end{matrix} \right] = \left[\begin{matrix} x_1 & x_2 & \cdots & x_N \\ p_1 & p_2 & \cdots & p_N \end{matrix} \right]$, 函数 $f(p_1, p_2, \cdots, p_N)$ 是随机变量不确定的度量, 若此函数满足条件: 1) 连续性; 2) 单调性; 3) 可加性, 则此函数必为 $f(p_1, p_2, \cdots, p_N) = -C \sum_{i=1}^N p_i \log p_i$, 其中 C 为常数
- **证明:** (1) 考虑随机变量 X 为等概分布的情况, $g(t) = C \log t$, 其中 C 为常数!
- (2) 考虑随机变量 X 为非等概分布, 但此时概率为有理数的情况, 此时概率可表示为 $p_n = \frac{m_n}{\sum_{n=1}^N m_n}$, 其中 m_n 为整数。令 $M = \sum_{n=1}^N m_n$, 由条件3), $g(M)$ 可写为 $g(M) = f(p_1, p_2, \cdots, p_N) + \sum_{n=1}^N p_n g(m_n)$, 于是 $f(p_1, p_2, \cdots, p_N) = g(M) - \sum_{n=1}^N p_n g(m_n) = C \log M - \sum_{n=1}^N p_n C g(m_n) = C \log M (\sum_{n=1}^N p_n) - C \sum_{n=1}^N p_n g(m_n)$, 因此 $f(p_1, p_2, \cdots, p_N) = -C \sum_{n=1}^N p_n \log(m_n/M) = -C \sum_{n=1}^N p_n \log(p_n)$
- (3) 若 X 非等概分布, 但概率为无理数的情况, 根据无理数可以用有理数逼近以及条件1), 可以证明此情况下仍然有这个结论!

4.5 平均互信息量、相对熵

- 各种信息量之间的关系：平均互信息量与信源熵、条件熵的关系

- $I(X; Y) = H(X) - H(X|Y)$
- $I(X; Y) = H(Y) - H(Y|X)$
- $I(X; Y) = H(X) + H(Y) - H(X, Y)$



4.5 平均互信息量、相对熵

从通信的角度来讨论
平均互信息量 $I(X; Y)$
的物理意义

由第一等式 $I(X; Y) = H(X) - H(X|Y)$ 看 $I(X; Y)$ 的物理意义

设 X 为发送消息符号集， Y 为接收符号集， $H(X)$ 是输入集的平均不确定性， $H(X|Y)$ 是观察到 Y 后，集 X 还保留的不确定性，二者之差 $I(X; Y)$ 就是在接收过程中得到的关于 X, Y 的平均互信息量。

对于无扰信道， $I(X; Y) = H(X)$

对于强噪信道， $I(X; Y) = 0$

4.5 平均互信息量、相对熵

由第二等式 $I(X;Y) = H(Y) - H(Y|X)$ 看 $I(X;Y)$ 的物理意义

$H(Y)$ 是观察到 Y 所获得的信息量， $H(Y|X)$ 是发出确定消息 X 后，由于干扰而使 Y 存在的平均不确定性，二者之差 $I(X;Y)$ 就是一次通信所获得的信息量。

对于无扰信道，有 $I(X;Y) = H(X) = H(Y)$ 。

对于强噪信道，有 $H(Y|X) = H(Y)$ ，从而 $I(X;Y) = 0$ 。

4.5 平均互信息量、相对熵

由第三等式 $I(X;Y) = H(X) + H(Y) - H(X, Y)$ 看 $I(X; Y)$ 的物理意义

通信前，随机变量 X 和随机变量 Y 可视为统计独立，其先验不确定性为 $H(X) + H(Y)$ ，

通信后，整个系统的后验不确定性为 $H(XY)$ ，

二者之差 $H(X) + H(Y) - H(XY)$ 就是通信过程中不确定性减少的量，也就是通信过程中获得的平均互信息量 $I(X; Y)$ 。

4.5 平均互信息量、相对熵

$$H(P, Q) = - \sum_{x \in X} p(x) \log(q(x))$$

- **相对熵**: $D(p||q) = \sum_{x \in X} p(x) \log \left(\frac{p(x)}{q(x)} \right)$: 相对熵, 交叉熵, Kullback熵, K-L散度, K-L距离, 方向散度)
 - 相对熵非负, 互信息非负
 - **证明**: 1) 对任意 $x > 0$, 都有 $1 - \frac{1}{x} \leq \ln x \leq x - 1$ 成立, 等式成立的充要条件是 $x = 1$, 令 $f(x) = x - 1 - \ln x, x > 0$, 则 $f''(x) = \frac{1}{x^2} > 0$, 从而 $f(x)$ 为下凸函数, 且最小值 $x = 1$ 取得 $f(1) = 0$, 从而 $x - 1 \geq \ln x$, 然后令 $x := \frac{q_i}{p_i}$, 代入得证;
 - 2) $\log \left(\frac{q_i}{p_i} \right) = \log e \cdot \ln \left(\frac{q_i}{p_i} \right) \leq \log e \cdot \left(\frac{q_i}{p_i} - 1 \right)$, 从而:
$$\sum_i p_i \log \left(\frac{q_i}{p_i} \right) \leq \sum_i p_i \log e \cdot \left(\frac{q_i}{p_i} - 1 \right) = \log e \cdot \sum_i (q_i - p_i) = 0$$
 - 从而 $\sum_i p_i \log \left(\frac{p_i}{q_i} \right) \geq 0$, 等号成立当且仅当 $\frac{p_i}{q_i} = 1$

$$H(P, Q) = H(P) + KL(P || Q)$$

4.5 平均互信息量、相对熵

- 假设两个官员红绿蓝三颜色的离散概率分布：
- 事件 = ['红色', '绿色', '蓝色']
- $p = [0.10, 0.40, 0.50]$
- $q = [0.80, 0.15, 0.05]$
- $H(P, Q) = H(P) - KL(P||Q)$

```
plot of distributions
from matplotlib import pyplot
# define distributions
events = ['red', 'green', 'blue']
p = [0.10, 0.40, 0.50]
q = [0.80, 0.15, 0.05]
print('P=%0.3f Q=%0.3f' % (sum(p), sum(q)))
# plot first distribution
pyplot.subplot(2,1,1)
pyplot.bar(events, p)
# plot second distribution
pyplot.subplot(2,1,2)
pyplot.bar(events, q)
# show the plot
pyplot.show()
# calculate cross entropy
# example of calculating cross entropy
from math import log2

# calculate cross entropy
def cross_entropy(p, q):
    return -sum([p[i] * log2(q[i]) for i in
range(len(p))])
# calculate k-l Divergence
def kl_divergence(p, q):
    return sum(p[i] * log2(p[i]/q[i]) for i in
range(len(p)))
# calculate entropy H(P)
def entropy(p):
    return -sum([p[i] * log2(p[i]) for i in
range(len(p))])

def cross_entropy_kl(p, q):
    return entropy(p) + kl_divergence(p, q)
# calculate cross entropy H(P, Q)
# define data
p = [0.10, 0.40, 0.50]
q = [0.80, 0.15, 0.05]
# calculate cross entropy H(P, Q)
ce_pq = cross_entropy(p, q)
print('H(P, Q): %0.3f bits' % ce_pq)
# calculate cross entropy H(Q, P)
ce_qp = cross_entropy(q, p)
```

4.5 平均互信息量、相对熵

- 对数和不等式

- 对非负数 $a_1, a_2, \dots, a_n$ 以及非负数 $b_1, b_2, \dots, b_n$, 有: $\sum_{i=1}^n a_i \log \left(\frac{a_i}{b_i} \right) \geq \left(\sum_{i=1}^n a_i \right) \log \left(\frac{\sum_{i=1}^n a_i}{\sum_{i=1}^n b_i} \right)$,
等式当且仅当 $\frac{a_i}{b_i} = \text{常数}$ 成立 (注意 $0 \log 0 = 0$; $a \log \left(\frac{a}{0} \right) = \infty, a > 0$; $0 \log \left(\frac{0}{0} \right) = 0$)

- 利用该不等式, 可以证明相对熵的凸性:

- $D(p||q)$ 关于 (p, q) 对是凸的, 即 $\forall \lambda \in [0, 1]$, 二元组 $(p_1, q_1), (p_2, q_2)$, 有 $D(\lambda p_1 + (1 - \lambda)p_2 || \lambda q_1 + (1 - \lambda)q_2) \leq \lambda D(p_1 || q_1) + (1 - \lambda)D(p_2 || q_2)$

- 证明: 应用对数不等式到上式的左端项, $(\lambda p_1(x) + (1 - \lambda)p_2(x)) \log \left(\frac{\lambda p_1(x) + (1 - \lambda)p_2(x)}{\lambda q_1(x) + (1 - \lambda)q_2(x)} \right) \leq \lambda p_1(x) \log \left(\frac{\lambda p_1(x)}{\lambda q_1(x)} \right) + (1 - \lambda)p_2(x) \log \frac{(1 - \lambda)p_2(x)}{(1 - \lambda)q_2(x)} =$
 $\lambda D(p_1 || q_1) + (1 - \lambda)D(p_2 || q_2)$

4.5 平均互信息量、相对熵

- 数据处理不等式

- 如果随机变量 X, Y, Z 形成马尔可夫链, 即 $X \rightarrow Y \rightarrow Z$, $p(x, y, z) = p(x)p(y|x)p(z|y)$, 则 $I(X; Y) \geq I(X; Z)$
- 直观: 任何对数据进行高级操作都不可能改进由数据得到的推断
- **证明:** 马尔可夫链表明给定 Y 时, X, Z 条件独立, 从而 $I(X; Z|Y) = 0$. 由于 $I(X; Y|Z) \geq 0$, 由 $I(X; Y, Z) = I(X; Z) + I(X; Y|Z) = I(X; Y) + I(X; Z|Y)$, 可得 $I(X; Y) \geq I(X; Z)$
- 等式成立当且仅当 $I(X; Y|Z) = 0$, 也就是 $X \rightarrow Z \rightarrow Y$ 形成马尔可夫链. 类似可以证明 $I(Y; Z) \geq I(X; Z)$
- 且若 $Z = g(Y)$, 则 $I(X; Y) \geq I(X; g(Y))$, 表明数据 Y 的函数不能提高关于 X 的信息。

1024个样本：
老/中/青： 384/256/384
高/中/低： 288/480/256
是/否： 484/540
优/良： 352/672
买/不买： 383/641

4.6 决策树-信息熵的直接应用

• 决策树： 基于规则来进行分类， 典型的决策树算法ID3

计数	年龄	收入	学生	信誉	归类： 买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

- 1.计算决策属性的熵， 买/不买， 得 $H=0.9537$
- 2.计算条件属性的熵，
 - 2.1计算年龄属性， 分为3组，
 - 2.1.1青年： 买/不买:128/256， $H(A1) = 0.9183$,
 - 2.1.2中年： 买/不买:256/0， $H(A2) = 0$
 - 2.1.3老年： 买/不买:125/127, $H(A3) = 0.9157$
 - 计算根据年龄分组后熵的期望为 $H(A) = 0.6878$
 - 因此， 年龄熵的信息增益为：
 $0.9537 - 0.6878 = 0.2659$
- 同理， 收入属性的信息增益为：
 $0.9573 - 0.9361 = 0.0176$
- 同理， 学生属性的信息增益为：
 $0.9573 - 0.7811 = 0.1726$
- 同理， 信誉属性的信息增益为：
 $0.9573 - 0.9048 = 0.0453$
- 问题： 先选哪个属性进行分类？

4.6 决策树-信息熵的直接应用


- 学生膳食结构和缺钙调查表，判断学生是否缺钙

学生	鸡肉	猪肉	牛肉	羊肉	鱼肉	鸡蛋	青菜	番茄	牛奶	健康情况
1	0	1	1	0	1	0	1	0	1	不缺钙
2	0	0	0	0	1	1	1	1	1	不缺钙
3	1	1	1	1	1	0	1	0	0	缺钙
4	1	1	0	0	1	1	0	0	1	不缺钙
5	1	0	0	1	1	1	0	0	0	缺钙
6	1	1	1	0	0	1	0	1	0	缺钙
7	0	1	0	0	0	1	1	1	1	不缺钙
8	0	1	0	0	0	1	1	1	1	缺钙
9	0	1	0	0	0	1	1	1	1	不缺钙
10	1	0	1	1	1	1	0	1	1	不缺钙

问题：凭直觉，你觉得应该先判断哪种食物，更容易分类？为什么？


4.6 决策树-信息熵的直接应用

- 先从鸡肉开始?



4.6 决策树-信息熵的直接应用

- 还是从牛奶开始?



问题：决策树的重点在决策，还是在树？

4.6 决策树-信息熵的直接应用

- 定义 (信息增益):特征 A 对训练数据集 D 的信息增益, $g(D, A)$, 定义为集合 D 的经验熵 $H(D)$ 与特征 A 给定条件下 D 的经验条件熵 $H(D|A)$ 之差, 即:

$$g(D, A) = H(D) - H(D|A)$$

- (Information gain)表示得知特征 X 的信息而使得类别 Y 的信息的不确定性减少的程度
 - $H(Y) - H(Y|X)$
- 决策树学习中的信息增益等价于训练数据集中类与特征的互信息

4.6 决策树-信息熵的直接应用

- 假设训练集为 D , $|D|$ 表示样本个数, 共 K 类, 每类的样本集合表示为 $C_k, k = 1, \dots, K$; 样本中 A 特征或属性的取值集合为 $\{a_1, a_2, \dots, a_n\}$, 根据 A 的取值, 将训练集合划分为 $D_1, D_2, \dots, D_n$ 个子集, $|D_i|$ 表示集合 D_i 中样本的个数; 假设子集 D_i 中属于类别 C_k 的样本集合为 D_{ik} , 则根据上页的讨论, 决策树的**基本步骤**如下:

- 1. 数据集 D 的经验熵:

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \left(\frac{|C_k|}{|D|} \right)$$

- 2. 通过特征 A 的取值后分成了 n 个子集, 这时候特征 A 对数据集 D 的经验条件熵:

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \left(\sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \left(\frac{|D_{ik}|}{|D_i|} \right) \right)$$

- 3. 计算信息增益

$$g(D, A) = H(D) - H(D|A)$$

问题: 如何构建决策树?

以信息增益最大的特征作为划分训练数据集的优先特征!

4.6 决策树-信息熵的直接应用

- 但存在一个小问题：取值多的特征，其对应的条件熵更大，因此，偏向于优先选取取值多的特征来构建决策树！
 - 解决办法：用信息增益比值，
 - **信息增益比**：特征A对训练数据集D的信息增益比定义为信息增益与训练数据集D关于特征A的值的熵之比：
$$g_R(D, A) = \frac{g(D, A)}{H_A(D)}$$
 - 其中 $H_A(D) = -\sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \left(\frac{|D_i|}{|D|} \right)$, n 为特征A取值的个数

2023年图灵奖

- 普林斯顿数学教授Avi Wigderson! 作为理论计算机科学领域的领军人物，他对于理解计算中的随机性和伪随机性的作用，做出了开创性贡献。

1994年图灵奖得主: Edward Feigenbaum & Raj Reddy
贡献领域: 大规模人工智能系统, 专家系统之父

2011年图灵奖得主: Judea Pearl, 通过概率论和因果推理对人工智能领域作出的根本性贡献, “贝叶斯网络之父”

2018年图灵奖得主: Yoshua Bengio & Geoffrey Hinton & Yann LeCun, 深度学习, “深度学习之父”, “卷积网络之父”



历届图灵奖得主 (1999-2022) https://zhuanlan.zhihu.com/p/638821030?utm_id=0

作业

- 1.阅读ID3,CART,C45等决策树方法，理解其中的关键性质
- 2.理解并掌握信息论中离散信源最大熵定理
- 3.理解数据压缩的信息论原理



谢 谢!

哈尔滨工业大学计算学部 刘绍辉

2026年4月

