



人工智能数学基础

Essential Math for AI

第5章 贝叶斯公式与检测准则

哈尔滨工业大学计算学部人工智能专业 刘绍辉

shliu@hit.edu.cn

微信: shliu13503627854

2026年4月



内容介绍

- 5.1 基本概率论
- 5.2 贝叶斯公式
- 5.3 检测理论

问题

- 某人有两个孩子， 其中至少有一个是男孩， 那么另一个孩子也是男孩的概率是多少？
 - 答案是多少？ $1/3$
- 假设你现在知道这个人至少有一个出生在星期二的男孩， 那么另一个孩子也是男孩的概率是多少？
 - $13/27$
- 蒙蒂·霍尔问题
- 20 世纪 60 年代由蒙蒂·霍尔主持的一个叫作《达成协议》 (*Let's Make a Deal*) 的美国电视游戏节目。 在节目的最后， 参赛者必须在三道门帘中选一道。 其中一道门帘之后有一辆汽车， 其余两道门帘后面是山羊。 参赛者选择之后， 蒙蒂·霍尔会增加悬念： 在参赛者没有选择的门帘之中， 至少有一道门帘背后是山羊。 然后， 蒙蒂·霍尔会将这道背后是山羊的门帘打开。
- 现在剩下两道门帘， 其中一道后面有汽车， 另一道后面则有山羊。 这时， 蒙蒂·霍尔就会向参赛者提出一个新选择： 他可以维持自己的选择或者换一道门帘。 这位参赛者应该怎么做？ 他应该遵循一开始的直觉， 还是应该改变主意？

蒙蒂·霍尔问题



- 在英国广播公司 (**BBC**) 的一部出色的纪录片中， 数学家马库斯·杜·索托伊向喜剧演员阿兰·戴维斯提出了蒙蒂·霍尔问题。 一脸怀疑的阿兰·戴维斯相信， 在重复进行的蒙蒂·霍尔游戏中不改变门帘的选择会有优势， 跟绝对会改变的马库斯·杜·索托伊正好相反。
 - 在 **20** 次尝试中， 阿兰·戴维斯只赢了 **2** 次， 而马库斯·杜·索托伊赢了 **16** 次。 当然， 这些数字似乎不符合贝叶斯理论预言的 **$1/3$** 和 **$2/3$** ——这都是小数定律的错！ 但好处就是这说服了阿兰·戴维斯自己错了， 或者说他至少做到了这一点， 因为他似乎并没有明白马库斯·杜·索托伊的解释。

萨莉·克拉克的审判

- **1996** 年， 萨莉·克拉克的新生儿在出生两周后就去世了。 一年之后历史重演， 她生下的第二名婴儿也去世了。 萨莉·克拉克被控两宗谋杀罪。 儿科医生罗伊·梅多出庭作证， 他宣称两名新生儿接连由于自然原因死亡的概率是 **7300** 万分之一， 这段证词给萨莉·克拉克定了罪。
- 然而在三年之后， 人们发现负责尸检的医生阿兰·威廉斯当时没有报告他的分析结果： 第二个新生儿的的确确死于自然原因。 萨莉·克拉克最终被释放了， 但并非毫无遗患， 她的精神受到了极大的创伤， 四年后死于饮酒过量导致的昏迷。

视觉错觉

- 贝叶斯大脑在无意识中应用了贝叶斯公式（的一个近似），以此推断出后面的透视平面上的人像很有可能比看上去更大。这个视错觉可以通过贝叶斯推断来解释
- 阴影中的白色格子看起来比照明之下的黑色格子颜色更浅，但实际上并不是这样的。虽然如此，我们的贝叶斯大脑在无意识中进行的贝叶斯推断也会考虑照明的效应，由此得到“有用”的结论，也就是被照亮的黑色格子的颜色比阴影中的白色格子更深



具体请参考：《贝叶斯的博弈：数学、思维与人工智能》

5.1 基本概率论

- **定义1**: 设 Ω 是实验 S 的样本空间, 用 F 表示 Ω 的某些子集构成的集合, 如果 F 满足: (1) $\Omega \in F$ (2) 如果 $A \in F$, 则 $\bar{A} \in F$ (3) 若 $A_j \in F$, 则 $\bigcup_{j=1}^n A_j \in F$, 就称 F 是 Ω 的**事件域**或 **σ 域**(σ -field 或 σ -algebra), 称 F 中的元素为**事件**, 称 (Ω, F) 是**可测空间**。
- **定义2**: 设 (Ω, F) 是可测空间, P 是定义在 F 上的函数, 如果 P 满足下面的条件: (1) 非负性: for any $A \in F$, $P(A) \geq 0$ (2) 完全性: $P(\Omega) = 1$ (3) 可列可加性: 对于 F 中互不相容的事件 $A_1, A_2, \dots$,

$$P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} P(A_j)$$

就称 P 为 F 上的**概率测度**, 简称**概率**, 称 (Ω, F, P) 为**概率空间**。

- 设 $A \in F, P(A) \geq 0$, 若 $P(A) > 0, B \in F$, 定义 $P_A(B) = P(B|A) = \frac{P(A \cap B)}{P(A)}$, 则 P_A 也是可测空间 (Ω, F) 上的概率, 我们称 P_A 为**条件概率测度**, 简称**条件概率**

5.1 基本概率论

- 例：掷两颗骰子，已知它们的和是7，则其中一颗骰子是1的概率是多少？
 - 条件概率： $P(B|A)$ 表示已知A发生的条件下，B发生的概率(条件概率)。我们知道两颗骰子和是7的可能情况 $A = \{(1, 6), (2, 5), (3, 4), (6, 1), (5, 2), (4, 3)\}$, 一个骰子是1的是 $AB = \{(1, 6), (6, 1)\}$,
 - 因此 $P(B|A) = \frac{P(A,B)}{P(A)} = \frac{\#AB}{\#A} = \frac{1}{3}$
- 性质：设A, B, $\mathbf{A}_1$, $\mathbf{A}_2$, $\cdots$, $\mathbf{A}_n$ 是事件，则：
 - (1) $P(A, B) = P(B|A)P(A) = P(A|B)P(B)$;
 - (2)当 $P(\mathbf{A}_1\mathbf{A}_2 \cdots \mathbf{A}_n) \neq 0$, 有: $P(A_1, A_2, \cdots, A_n) = P(A_1)P(A_2|A_1)\cdots P(A_n|A_1, A_2, \cdots, A_{n-1})$
 - (3)如果 $P(A, B) > 0$, 则 $P_A(C|B) = P(C|B|A) = \frac{P(C,B,A)}{P(B,A)} = P(C|A, B)$

5.1 基本概率论

- 全概率公式

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

- 贝叶斯公式

$$P(A_j|B) = \frac{P(A_j)P(B|A_j)}{\sum_{i=1}^n P(A_i)P(B|A_i)},$$
$$P(A|B) = \frac{P(A)P(B|A)}{P(A)P(B|A) + P(\bar{A})P(B|\bar{A})}$$

5.2 贝叶斯公式

- 例子：想象一下，化验结果显示张三感染了埃博拉病毒，而张三知道自己刚从某个国家度假归来。他自然会询问化验的可靠程度。别人告诉他，健康的人得到正确的化验结果的概率是 90%。张三是不是应该开始写遗嘱了？
 - 纯粹贝叶斯主义者的回答只有一个：不急。即使在受这种病毒影响最大的撒哈拉以南的非洲，感染埃博拉病毒的人也万中无一。所以张三这个只在某国短暂停留过的人，感染这个病毒的可能性显然不足万分之一。
 - 请给出其贝叶斯分析的基本推理过程

5.2 贝叶斯公式

- 按照贝叶斯公式

$$P[\text{得病} | \text{化验阳性}] = \frac{P[\text{化验阳性} | \text{得病}] P[\text{得病}]}{P[\text{化验阳性} | \text{得病}] P[\text{得病}] + P[\text{化验阳性} | \text{健康人}] P[\text{健康人}]}$$

得病

化验阳性

感染埃博拉病毒的人来说化验结果的可靠性

健康人化验结果出错的概率

健康人

5.2 贝叶斯公式

- 我们现在差不多知道了等式右边所有的项。我们已经看到得病的概率约为1/10 000，健康的概率约为9999/10000,健康人化验出错的概率1/10
- 感染埃博拉病毒的人来说化验结果的可靠性:注意到一个简单的事实：这一项是一个概率，不能大于 1

$$\mathbb{P}[\text{😞} | \text{💬}] \approx = \frac{1 \times 0.0001}{1 \times 0.0001 + 0.1 \times 0.9999} \approx 0.001$$

张三还不需要立刻开始写遗嘱


5.2 贝叶斯公式

- 例：(疾病普查问题) 一种新方法对某种特定疾病的诊断准确率是90%(有病被正确诊断和没病被正确诊断的概率都是90 %). 如果群体中这种病的发病率是0.1%, 甲在身体普查中被诊断患病, 问甲的确患病的概率是多少? 如果甲复查时又被诊断有病, 则他的确有病的概率是多少?
- 解： 设 A = 甲患病, B = 甲被诊断有病. 我们有 $P(A) = 0.001$, $P(B|A) = 0.9$, $P(B|\bar{A}) = 0.1$
- 使用贝叶斯公式：
$$P(A|B) = \frac{P(A)P(B|A)}{P(A)P(B|A) + P(\bar{A})P(B|\bar{A})} = \frac{0.001 \times 0.9}{0.001 \times 0.9 + 0.999 \times 0.1} = 0.0089 < 1\%$$
- 问：如果连续检查两次, 则如何? 假设两次检查是独立的!

5.2 贝叶斯公式

- $$P(A|B, B) = \frac{P(B, B|A)P(A)}{P(B, B|A)P(A) + P(B, B|\bar{A})P(\bar{A})} =$$
$$\frac{P(B|A)^2 P(A)}{P(B|A)^2 P(A) + P(B|\bar{A}) P(\bar{A})} = \frac{0.99^2 \times 0.001}{0.99^2 \times 0.001 + 0.1^2 \times 0.999} = 7.5\%$$
- 倒数第二个等式是因为两次检查是独立的，另一方面我们还发现 $P(B, B|A) + P(B, B|\bar{A}) \neq 1$ ，而 $P(B|A) + P(B|\bar{A}) = 1$ 。
(请解释原因) 实际上 $P(B|A) + P(B|\bar{A})$ 不一定是1。


5.2 贝叶斯公式-贝叶斯分类



- 分类问题
 - 无监督-聚类：将集合分成 n 组或 n 类
 - 有监督-分类：已知类别或标签，找到映射关系
- 概率观点的有监督分类
 - 给定属性 $A_1, A_2, \dots, A_n$ 和类别 $C = \{c_1, c_2, \dots, c_m\}$,使得给定属性下最大化概率MAP:
 $\arg_c [\max P(C|A_1, A_2, \dots, A_n)]$
 - 令 $A = \{A_1, A_2, \dots, A_n\}$,则为 $\arg_c \max P(C|A)$
- Bayesian 分类器
 - $P(C|A_1, A_2, \dots, A_n) = P(C)P(A_1, A_2, \dots, A_n|C)/P(A_1, \dots, A_n)$
 - 紧凑表示为: $P(C|A) = P(C)P(A|C)/P(A)$
 - 因此分类器问题表示为: $\arg_c \max \left[\frac{P(C)(A|C)}{P(A)} \right]$

5.2 贝叶斯公式-贝叶斯分类

- 注意：一般假定属性之间相互独立，则 $P(A_j|A_i, C) = P(A_j|C), \forall j \neq i$
 - 从专家或者数据都可以估计 $P(c_i) \sim N_i/N, P(A_{jk}|c_i) \sim N_{jki}/N_i$
 - 其中 N 为样本数， N_i 为样本中为 c_i 发生的次数， N_{jki} 为样本属性 A_j 从第 i 类中属性值为 k 的样本数目
 - 一旦估计出参数，后验概率就可以通过先验来乘上每种属性的似然性来得到
 - 给定对每类 c_i 的 m 中属性值 $a_1, a_2, \dots, a_m$ ，则后验概率：
 - $P(c_i|a_1, a_2, \dots, a_m) \sim P(c_i)P(a_1|c_i) \cdots P(a_m|c_i)$
 - 然后选择类别 c_k 来最大化上面的式子即得到类别标签
- 进一步，根据单调性，可以表示成很多等价形式(类别属性不会变化， $P(A)$ 为常数)
- $\arg_c [\max [P(C)P(A|C)]]$
- $\arg_c [\max [\log (P(C)P(A|C))]]$
- $\arg_c [\max (\log P(C) + \log P(A|C))]$



5.2 贝叶斯公式-图模型

- 在概率推理中，最主要的就涉及到求取 $P(\mathbf{x}, \mathbf{y})$, $P(\mathbf{x}|\mathbf{y})$
 - 一般直接求取 $P(\mathbf{x}, \mathbf{y})$ 称为产生式模型，而求取 $P(\mathbf{x}|\mathbf{y})$ 则称为判别式模型
 - 显然，产生式模型可以转化为判别式模型，但反之不行

- 例子：高尔夫的例子

一系列变量导致结果：如何根据这些体征变量来进行疾病诊断；如何从一些变量推导另外一些变量的变化情况：基本都可以由边缘分布计算得到！

Outlook	Temperature	Humidity	Windy	Play
Sunny	High	High	False	No
Sunny	High	High	True	No
Overcast	High	High	False	Yes
Rain	Medium	High	False	Yes
Rain	Low	Normal	False	Yes
Rain	Low	Normal	True	No
Overcast	Low	Normal	True	Yes
Sunny	Medium	High	False	No
Sunny	Low	Normal	False	Yes
Rain	Medium	Normal	False	Yes
Sunny	Medium	Normal	True	Yes
Overcast	Medium	High	True	Yes
Overcast	High	Normal	False	Yes
Rain	Medium	High	True	No

5.2 贝叶斯公式-图模型

- 假设考虑天气和温度的关系,其联合概率分布为

Outlook	Temp.		
	H	M	L
S	0.143	0.143	0.071
O	0.143	0.071	0.071
R	0	0.214	0.143

- 对其每行求和, 相当于边际化温度, 获得天气的边际分布 $P(\textit{outlook}) = [0.357, 0.286, 0.357]$; 对其每列求和, 则获得温度的边际分布 $P(\textit{Temp}) = [0.286, 0.428, 0.286]$
- 因此最可能的天气是**S, R**, 最可能的温度是**M**
 - 下面计算给定温度情况下的天气分布
 - $P(\textit{Outlook}|\textit{Temp.} = L) = \frac{P(\textit{Outlook} \& \textit{Temp.}=L)}{P(\textit{Temp.}=L)} = [0.25, 0.25, 0.5]$
 - $P(\textit{Temp.}|\textit{Outlook} = R) = \frac{P(\textit{Temp.}\&\textit{Outlook}=R)}{P(\textit{Outlook}=R)} = [0, 0.6, 0.4]$

下雨天最可能的温度是**M**, 低温下最可能的天气是下雨

5.2 贝叶斯公式-图模型

- 对于少量样本或变量的情况下，都可以这么操作，是否可以推广到所有的情形呢？
 - 模型变量增多后，计算边缘分布和条件概率导致其计算量呈指数增长
 - 如果想从数据获得对联合概率较好的估计，如果变量很多，则需要查询一个海量的数据库
 - 一般记录数目至少应该是变量组合数目的10倍量级
 - 如果有50个二值变量，则要求 10×2^{50} 个记录
 - 并且给定联合概率表后，人也无法直接从中得到直观的认识
- 直接导致了基于概率图模型的发展
 - 基于概率论，用一种计算有效的方式来管理不确定性的一种框架，只考虑对问题有效的独立关系，根据内存要求和计算时间在模型中只考虑这些关系来减少复杂性

5.2 贝叶斯公式-图模型

- 而在变量之间表示相关和独立关系的自然表示就是图，直接相关的变量进行连接，独立关系隐含在这种相关图中
 - 概率图模型是联合概率的紧凑表达，从中可以获得边缘概率和条件概率
 - 相对于一般的表达：具有更紧凑、更有效、易于理解和交流、易于从数据学习或者基于专家知识来进行构造
 - $G(V, E)$ 和局部函数集 $f(Y_i)$,其中 Y_i 是变量的子集，联合概率通过局部函数(定义其参数)的乘积来获得： $P(X_1, X_2, \dots, X_N) = K \prod_{i=1}^m f(Y_i)$,其中 K 为归一化常数，使得概率为1
 - 这些局部函数有时称为势函数(Potentials)是概率图模型(PGM)中推理和学习的基础
 - 推理：给定任何其它子集 Y ，来获取子集 Z 的边缘概率或条件概率
 - 学习：给定任何 X 的数据集(可能不完全)，来估计图的结构和模型的参数

5.2 贝叶斯公式-图模型PGM

- 分类
 - 有向、无向：无向表示对称关系
 - 静态、动态：某一个时刻点、还是跨不同时刻
 - 概率、决策：包括随机变量，包括决策和应用变量

Type	Directed/Undirected	Static/Dynamic	Prob./Decisional
Bayesian classifiers	D/U	S	P
Markov chains	D	D	P
Hidden Markov models	D	D	P
Markov random fields	U	S	P
Bayesian networks	D	S	P
Dynamic Bayesian networks	D	D	P
Influence diagrams	D	S	D
Markov decision processes (MDPs)	D	D	D
Partially observable MDPs	D	D	D

5.2 贝叶斯公式-图模型PGM

- 表达、推理、学习
 - 表达：包括哪些实体、如何相关，图定义模型的结构，局部函数描述其参数，不同类型的模型其图和局部函数就不一样
 - 推理：基于模型或证据回答不同的概率查询，例如，给定一些变量的分布后，计算某个变量或者集合的后验概率。其挑战是：如何更加有效的去做！
- 构造模型有两种可选方案
 - 领域专家手工建立
 - 从数据推导出模型：近年从机器学习来推导模型。获取参数一般都是从数据来进行学习得到，人一般认为对概率估计比较差
- 从应用的观点来看，这些技术的一个特点就是将推理和学习与模型分开
 - 技术具有泛化性，不同应用的不同模型中均可使用

5.2 贝叶斯公式-贝叶斯分类-二项逻辑回归模型

- 二项逻辑回归模型的条件概率分布如下
- $P(X = 1|Z) = \frac{1}{1+e^{-\theta^T z}}; P(X = 0|Z) = 1 - \frac{1}{1+e^{(-\theta)^T x}}$
- $z \in R^n$ 是输入, $X \in \{0, 1\}$ 是输出, θ^T 是参数, 应用时, 根据两个条件概率值的大小将实例分到概率值较大的一类
- 问题, 如何具体求解?
- $h_{\theta} = \frac{1}{1+e^{(-\theta)^T z}}$ 作为似然函数, 采用梯度下降法来进行求解

5.2 贝叶斯公式-逻辑回归模型

- $L(\theta) = \prod_{i=1}^m P(x_i|z_i; \theta) = \prod_{i=1}^m (h_{\theta}(z_i))^x (1 - h_{\theta}(z_i))^{1-x}$
- 取对数, 乘以 $(-\frac{1}{m})$ 将求最大值问题转化为求最小值的问题
- $L(\theta) = -\frac{1}{m} \sum_{i=1}^m [x_i \log h_{\theta}(z_i) + (1 - x_i) \log(1 - h_{\theta}(z_i))]$
- 如何求解?
- $\theta_{j+1} = \theta_j - \alpha \frac{\partial L(\theta)}{\partial(\theta)} = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m z_i [h_{\theta}(z_i) - x_i]$
- 逻辑回归算法

5.2 贝叶斯公式-逻辑回归算法

- **输入**：训练数据集 $T = \{(z_i, x_i), i = 1, \dots, N\}$, $z_i \in \mathcal{Z} \subseteq R^n, x_i \in \mathcal{X} \subseteq R^n$, 损失函数 $Cost(x, f(z))$
- **输出**：逻辑回归模型 $\hat{f}(z)$
- 1.随机初始化参数 θ ;
- 2.对样本 $i = 1, 2, \dots, N$,
- 计算 $\theta_{j+1} = \theta_j - \alpha \frac{\partial L(\theta)}{\partial (\theta)} = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m z_i [h_{\theta}(z_i) - x_i]$
- 递归得到逻辑回归模型

	产生式模型 (generative model)	判别式模型 (discriminative model)
特点	对后验概率建模，从统计的角度表示数据的分布情况，能够反映同类数据本身的相似度	寻找不同类别之间的最优分类面，反映的是异类数据之间的差异
区别(输入x类别标签y)	估计的是联合概率分布 (joint probability distribution: $p(x, y)$,	估计的是条件概率分布(conditional distribution) : $p(y x)$
联系	由产生式模型可以得到判别式模型， 但由判别式模型得不到产生式模型。	
常见模型	-Gaussians, Naive Bayes -Mixtures of Gaussians, Mixtures of experts, HMMs -Sigmoidal belief networks, Bayesian networks -Markov random fields	-logistic regression - SVMs - traditional neural networks - Nearest neighbor
优点	实际上带的信息要比判别模型丰富； 研究单类问题比判别模型灵活性强； 模型可以通过增量学习得到； 能用于数据不完整（ missing data）情况。	分类边界更灵活，比使用纯概率方法或产生式模型更高级； 能清晰的分辨出多类或某一类与其他类之间的差异特征； 在聚类、viewpoint changes, partial occlusion and scale variations中的效果较好 适用于较多类别的识别； 判别模型的性能比产生式模型要简单，比较容易学习。
缺点	Tend to produce a significant number of false positives. This is particularly true for object classes which share a high visual similarity such as horses and cows	不能反映训练数据本身的特性。能力有限,可以告诉你的是1还是2,但没有办法把整个场景描述出来; Lack elegance of generative: Priors,结构,不确定性;Alternative notions of penalty functions,

机器学习中的生成式和判别式模型描述正确的是 ()

- ☒ A 生成式是计算联合概率分布 $P(X, Y)$
- ☒ B 判别式是计算条件概率 $P(Y|X)$
- ☒ C 生成式可以转化为判别式模型
- ☐ D 判别式可以转化为生成式模型

提交

5.3检测准则


- 将分类问题转化为以下的通信问题来讨论，假设接收端收到的信号为 $x(t) = s(t) + n(t)$,这时候，接收端信号有以下3种类型
 - $x(t) = s(t) + n(t)$ 或者 $x(t) = n(t)$ ，这时的信号检测就成为假设检验，此时只有两种情况， $\begin{cases} H_0: s = 0 \\ H_1: s \neq 0 \end{cases}$ ，二择一问题，就是一个分类问题！
 - 如果信号参量不止一个非零值，这时有多种可能，这时候相对于 H_0, H_1 成为符合假设，为复合二择一检测；
 - 如果在需要进一步确定复合假设中的某一个，出现 $H_0, H_1, \dots, H_M$ 多分类问题

5.3检测准则

- 当分类错误的时候有代价，假设对应代价如下
 - C_{00} :表示假设为0正确，判别也是0正确，所引起的损失，一般为0或负值
 - C_{10} :表示由假设0实际正确,而判别为假设1正确所引起的损失（虚报);
 - C_{11} :表示由假设1正确而判别也是1正确所引起的损失:一般为0或负值
 - C_{01} :表示由假设1实际正确而判别为假设0正确所引起的损失（漏报)

真实情况	预测结果					
	第 1 类	第 2 类	...	第 i 类	...	第 n 类
第 1 类	$C_{1,1}$	$C_{1,2}$	...	$C_{1,i}$	...	$C_{1,n}$
第 2 类	$C_{2,1}$	$C_{2,2}$	...	$C_{2,i}$	...	$C_{2,n}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	$\vdots$
第 i 类	$C_{i,1}$	$C_{i,2}$	...	$C_{i,i}$	...	$C_{i,n}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	$\ddots$	$\vdots$
第 n 类	$C_{n,1}$	$C_{n,2}$	...	$C_{n,i}$	...	$C_{n,n}$


5.3检测准则



- 检测（或**分类**）的问题变为如何将接收空间按判决界（**阈值**）划分为不同的区域,判决界有很多划分办法，那种对观察者而言损失最小的判决界就是最佳判决界。假设转移概率密度分布 $p(y|x)$ 已知。
- 如何根据不同的已知条件来获得最佳判决阈值呢？
- 损失函数、转移概率分布和事件的先验概率都为已知，就能确定使平均损失为最小的最佳判决准则。假设发送信号为 x_0, x_1 ,接收区域 s_y ,待定判决界将其分为两个区域 s_{y_0} 和 s_{y_1} ，转移概率分布为 $p(y|x_0), p(y|x_1)$,表明了每个发送信号转移到 s_y 中任一点的概率。

5.3检测准则-贝叶斯准则

- 假设发送是 x_1 ,接收落入 s_{y_0} 区域,这时候判别为 x_0 ,这种出错概率为 α ,则
- $\alpha = \int_{s_{y_0}} p(y|x_1)dy, x_1 \rightarrow x_0$
- $\beta = \int_{s_{y_1}} p(y|x_0)dy, x_0 \rightarrow x_1$
- 如果记发送一个 x_0 或 x_1 的平均损失为 C_0 和 C_1 , 则:
- $C_1 = (1 - \alpha)C_{11} + \alpha C_{01}$
- $C_0 = (1 - \beta)C_{00} + \beta C_{10}$
- 当知道先验概率 $p(x_0)$ 和 $p(x_1)$, 则发送一个信号的平均损失 C_M 可以表示为:
- $C_M = p(x_0)C_0 + p(x_1)C_1 = p(x_0)[(1 - \beta)C_{00} + \beta C_{10}] + p(x_1)[(1 - \alpha)C_{11} + \alpha C_{01}] = p(x_0)C_{00} + p(x_1)C_{11} + p(x_0) \cdot \beta(C_{10} - C_{00}) + p(x_1) \cdot \alpha(C_{01} - C_{11})$



5.3检测准则-贝叶斯准则


- 显然 $\int_{s_{y_1}} p(y|x_0)dy = 1 - \int_{s_{y_0}} p(y|x_0)dy$
- $C_M = p(x_0)C_{00} + p(x_1)C_{11} + \int_{s_{y_0}} [(C_{01} - C_{11}) p(x_1)p(y|x_1)]dy + \int_{s_{y_1}} [(C_{10} - C_{00})p(x_0)p(y|x_0)] dy$
- 简记为: $C_M = p(x_0)C_{10} + p(x_1)C_{11} + \int_{s_{y_0}} [B(y) - A(y)] dy$
- 假定 $B(y)$ 和 $A(y)$ 均不小于0, 这时找判决阈值等价于最小化风险, 即:
- $\min \left\{ \int_{s_{y_0}} [B(y) - A(y)] dy \right\}$
- 这等价于 $\min \left\{ \int_{-\infty}^y [B(y) - A(y)] dy \right\}$, 等价于 $\max \left\{ \int_{-\infty}^y [A(y) - B(y)] dy \right\}$
- 思考: 什么条件下, 能取最大值?

$$\begin{aligned} \text{令 } A(y) &= (C_{10} - C_{00})p(x_0)p(y|x_0) \\ B(y) &= (C_{01} - C_{11})p(x_1)p(y|x_1) \end{aligned}$$

$$\min \left\{ \int_{s_{y_0}} [B(y) - A(y)] dy \right\}$$

$$\begin{aligned} \text{令 } A(y) &= (C_{10} - C_{00})p(x_0)p(y|x_0) \\ B(y) &= (C_{01} - C_{11})p(x_1)p(y|x_1) \end{aligned}$$

$$\max \left\{ \int_{-\infty}^y [A(y) - B(y)] dy \right\}$$



5.3检测准则-贝叶斯准则

- **显然**，当 $A(y) = B(y)$ 是满足条件，即
- $(C_{01} - C_{11}) p(x_1)p(y|x_1) = (C_{10} - C_{00})p(x_0)p(y|x_0)$
- 此时的 y 值即称为最佳判决界（或者最佳阈值），这时得到最小的平均损失！
- 因此，最佳判决准则为：
- $$y = \begin{cases} 1, & (C_{01} - C_{11}) p(x_1)p(y|x_1) > (C_{10} - C_{00})p(x_0)p(y|x_0) \\ 0, & (C_{01} - C_{11}) p(x_1)p(y|x_1) \leq (C_{10} - C_{00})p(x_0)p(y|x_0) \end{cases}$$
- 二维时简化！

5.3检测准则-贝叶斯准则

- $(C_{01} - C_{11}) p(x_1)p(y|x_1) - (C_{10} - C_{00})p(x_0)p(y|x_0) > 0$ 等价于
- $y = \begin{cases} 1, & \frac{p(y|x_1)}{p(y|x_0)} > \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)} \\ 0, & \frac{p(y|x_1)}{p(y|x_0)} \leq \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)} \end{cases}$
- 令 $L(y) = \frac{p(y|x_1)}{p(y|x_0)}$ 为似然比, $\lambda = \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)}$ 为检测阈值, 则条件转化为
- $L(y) \geq \lambda$ 来判断接收的类别!
- 这就是贝叶斯准则!

5.3检测准则-贝叶斯准则

- 如果两边取对数，则为对数似然比
- **例：**设有一个二元系统发送信号 $x_0 = 0$ 和 $x_1 = 1$ ，发送的先验概率分别为 0.3 和 0.7，传输过程中受到平均功率为 1/8 瓦的加性高斯噪声的干扰，假设传送过程中四种损失函数 C_{00} , C_{10} , C_{11} 和 C_{01} 大小分别为 -1, 5, -1, 10，试求最佳贝叶斯判决界和相应的平均损失或贝叶斯风险？

$$\bullet \lambda = \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)} = \frac{(5+1)0.3}{(10+1)0.7} = \frac{18}{77}$$

$$\bullet L(y) = \frac{p(y|x_1)}{p(y|x_0)} = \frac{\frac{1}{\sqrt{2\pi \cdot \frac{1}{8}}} e^{-\frac{(y-1)^2}{2 \cdot \frac{1}{8}}}}{\frac{1}{\sqrt{2\pi \cdot \frac{1}{8}}} e^{-\frac{(y-0)^2}{2 \cdot \frac{1}{8}}}} = e^{4(2y-1)} = \frac{18}{77} \Rightarrow y_T = \frac{[\log_e(\frac{18}{77}) + 4]}{8} = 0.3183$$

5.3检测准则-贝叶斯准则

- 而对贝叶斯风险，先计算 α 和 β

- $\alpha = \int_{-\infty}^{y_T} \frac{1}{\sqrt{2\pi \cdot \frac{1}{8}}} e^{-\frac{(y-1)^2}{2 \cdot \frac{1}{8}}} dy = 0.0269$

- $\beta = \int_{y_T}^{\infty} \frac{1}{\sqrt{2\pi \cdot \frac{1}{8}}} e^{-\frac{(y-0)^2}{2 \cdot \frac{1}{8}}} dy = 0.1840$,最后计算:

- $C_M = p(x_0)C_{00} + p(x_1)C_{11} + p(x_0) \cdot \beta(C_{10} - C_{00}) + p(x_1) \cdot \alpha(C_{01} - C_{11})$ 即可

5.3检测准则-最大后验概率准则

- 贝叶斯准则要求损失函数、转移概率分布和事件的先验概率都为已知，但有些情况无法或者不必要知道损失函数时，可以简单假设错误判决的损失为1而正确判决的损失为0，即 $C_{00} = C_{11} = 0$ ， $C_{01} = C_{10} = 1$ ，这时贝叶斯准则中右边的常数
- $\lambda = \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)} = \frac{p(x_0)}{p(x_1)}$
- 根据贝叶斯公式：
- $\frac{p(y|x_1)}{p(y|x_0)} \geq \frac{p(x_0)}{p(x_1)} \Leftrightarrow \frac{p(y|x_1)}{p(y|x_0)} = \frac{p(x_1|y)p(y)}{p(x_0|y)p(y)} \cdot \frac{p(x_0)}{p(x_0|y)p(y)} \geq \frac{p(x_0)}{p(x_1)} \Leftrightarrow$
 $\frac{p(x_1|y)}{p(x_0|y)} \geq 1$

5.3检测准则-最大似然准则

- 如果不仅损失函数不知道，先验概率也不知道，那么这时候，就只能假定两种判决出错的概率和代价基本相同
- 这种最合理的假设就是假定常数 $\lambda = \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)}$ ，这时判决准则变为
- $\frac{p(y|x_1)}{p(y|x_0)} \gtrless 1$

5.3检测准则-Neyman-Pearson准则

- 如果不仅损失函数不知道，先验概率也不知道，并且已知判决错误中有一类较另一类更为重要，因此需要对这类错误进行限制，例如 x_1 错为 x_0 ，这类错误更重要（例如：错判与漏盘的后果不一样），这时规定 $\alpha < \alpha_M$ ，在此条件下，再去确定能使其它类错误概率最小的判决界
- 例如，雷达系统中，确定先验概率和各类错误的代价都很困难，Neyman-Pearson准则：给定虚警概率的条件下，使检测概率最大
- 如果是二维的，则给定 α_M ，则判决界就确定了！

5.3检测准则-极小极大检测准则

- $C_M = p(x_0)C_{00} + p(x_1)C_{11} + p(x_0) \cdot \beta(C_{10} - C_{00}) + p(x_1) \cdot \alpha(C_{01} - C_{11}) = C_{11}p(x_1) + C_{00}[1 - p(x_1)] + \alpha(C_{01} - C_{11})p(x_1) + \beta[(C_{10} - C_{00})(1 - p(x_1))]$ --(C_{MB})
- 当损失函数 $C_{00}, C_{11}, C_{01}, C_{10}$,转移概率分布 $p(y|x_1), p(y|x_0)$ 都已知时, 贝叶斯风险就只与先验概率分布 $p(x_1)$ 有关,给定一个 $\mathbf{p}(\mathbf{x}_1)$,就可确定一个判决界,从而确定相应的错误概率 α, β ,然后计算可得到贝叶斯风险
- 这样就得到 C_M 与 $p(x_1)$ 的关系曲线
 - $C_M = [C_{11} - C_{00} + \alpha(C_{01} - C_{11}) - \beta(C_{10} - C_{00})]p(x_1) + C_{00} + \beta(C_{10} - C_{00})$
 - 这样确定了 $\mathbf{p}(\mathbf{x}_1)$ 与贝叶斯风险的函数关系。但事实上, 并不知道 $\mathbf{p}(\mathbf{x}_1)$, 因此选择平均贝叶斯风险最大的先验概率 $\mathbf{p}'(\mathbf{x}_1)$ 作为假设的先验概率, 并确定阈值, 确定贝叶斯判决界

5.3检测准则-极小极大检测准则

- $C'_M = [(C_{11} - C_{00}) + \alpha(p')(C_{01} - C_{11}) - \beta(p')(C_{10} - C_{00})]p(x_1) + C_{00} + \beta(p')(C_{10} - C_{00})$
- 思考：一旦假想先验概率 $p'(x_1)$ 后，平均贝叶斯风险 C'_M 与 $p(x_1)$ 的关系是否为一 条直线？
- 极小极大准则
 - 选使贝叶斯风险具有最大值时的先验概率作为假想的先验概率，这时真正风险 C_{MT} （极小极大的平均损失）应不小于贝叶斯风险 C_{MB} 。
 - 当 $p(x_1)$ 与 $p'_0(x_1)$ 一致时，两者相同。保守，但保险！
 - 如果实际 $p(x_1)$ 接近于1（实际贝叶斯风险很小），此时选择 $p'_0(x_1)$ 作为先验概率所引起的平均风险 C'_M 很大！但按照极小极大准则选择，平均风险 C_{MT} 为与 C_{MB} 最大点相切的一条水平直线，无论实际先验概率为多少，其平均风险保持不变，若接近1，则 $C_{MT} \ll C'_M$
 - $\frac{dC_{MB}(p)}{dp(x_1)} = 0$ 或者 $\frac{dC'_M(p)}{dp(x_1)} = 0$ 求得假想先验概率，从而确定阈值和判决界，最后确定平均分险
 - 将其代入，可得： $(C_{11} - C_{00}) + \alpha(p')(C_{01} - C_{11}) - \beta(p')(C_{10} - C_{00}) = 0$

5.3检测准则-极小极大检测准则

- $(C_{11} - C_{00}) + \alpha(p')(C_{01} - C_{11}) - \beta(p')(C_{10} - C_{00}) = 0$

- 令 $C_{11} = C_{00}$, 则上式成为:

$$\alpha(p')(C_{01} - C_{11}) = \beta(p')(C_{10} - C_{00}) \text{--- (等风险条件)}$$

- 从中可求出 $p'_0(x_1)$, 于是可求出极小极大准则下的最佳阈值 λ :

- $$\lambda = \frac{[1 - p'_0(x_1)](C_{10} - C_{00})}{p'_0(x_1)(C_{01} - C_{11})}$$

$$y = \begin{cases} 1, & \frac{p(y|x_1)}{p(y|x_0)} > \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)} \\ 0, & \frac{p(y|x_1)}{p(y|x_0)} \leq \frac{(C_{10} - C_{00})p(x_0)}{(C_{01} - C_{11})p(x_1)} \end{cases}$$

本章小结

- 基本概率公式
- 贝叶斯公式
- 概率图模型
- 检测准则-模式识别中常用

作业

- 理解生成式、判别式方法，理解求联合概率如何利用独立性分解为极大团上的势函数的乘积！
- 理解贝叶斯准则的基本原理，以及其他衍生的准则与贝叶斯准则的关系！
- 尝试阅读隐马尔可夫模型，理解其中的原理！



谢 谢!

哈尔滨工业大学计算学部 刘绍辉

2026年4月

