



哈爾濱工業大學
HARBIN INSTITUTE OF TECHNOLOGY

4. 特征检测

张宏志

机器学习研究中心, 计算学部
2026 春

zhanghz@hit.edu.cn 390684271@qq.com




哈爾濱工業大學
HARBIN INSTITUTE OF TECHNOLOGY

动机: 创建一个全景图像



如何创建全景图像？


➤ 我们需要匹配图像



規格嚴格 功夫到家

特征匹配


• 在两个图像中检测特征点



規格嚴格 功夫到家

特征匹配

- 在两个图像中检测特征点
- 寻找对应的特征点对



規格嚴格 功夫到家

特征匹配

- 在两个图像中检测特征点
- 寻找对应的特征点对
- 使用这些特征点对来匹配图像

真的有看起来
这么简单么
??




規格嚴格 功夫到家

特征匹配

➤ 挑战一：特征的稳定检测

➤ 如何在不同的视角、光照下，在两幅图像中独立检测出同一个物理点？



否则无法匹配！


这就需要一个**可复现**的检测器/特征。无论图像如何变化，好的特征点都应该被稳定地检测出来。

规格严格 功夫到家

特征匹配

➤ 挑战二：特征的唯一描述

➤ 检测到特征点后，我们如何准确识别出它在另一幅图像中的“孪生兄弟”？




这就需要一个**独特性或显著性强**的描述符。我们需要给每个特征点一个独特的“身份标识”，让它在众多点中能够被精确地识别出来。

规格严格 功夫到家

特征匹配

➤ 挑战三：错误匹配的鲁棒处理

- 由于重复纹理、遮挡等原因，匹配过程不可避免地会产生一些错误对应。如何排除这些“害群之马”的干扰？




这就需要匹配算法足够鲁棒，即使面对大量的错误匹配，依然能够准确估计出正确的图像变换关系。

规格严格 功夫到家

优秀特征应具备的特点

- 可复现性：应对挑战一，在不同变换下均可被检测
- 显著性：应对挑战二，特征的描述符应足够独特
- 高效性：特征数量远少于像素总量，计算高效



规格严格 功夫到家

应用场景

特征点可用于以下任务：

- 运动跟踪
- 图像配准
- 三维重建
- 物体识别
- 图像检索与数据库检索
- 机器人导航

規格嚴格 功夫到家

目录

- 角点 (哈里斯角点, Harris Corner)
- 斑点
- 描述符


規格嚴格 功夫到家

目录

- 角点 (哈里斯角点, Harris Corner)
- 斑点
- 描述符

規格嚴格 功夫到家

寻找角点




- 关键性质: 在角点附近区域, 图像梯度有两个或多个主要方向
- 角点具有可复现性和独特性

C.Harris and M.Stephens. "[A Combined Corner and Edge Detector.](#)" *Proceedings of the 4th Alvey Vision Conference*: pages 147--151.


規格嚴格 功夫到家

角点检测：基本思想


- 通过一个小窗口应能轻松识别出该点
- 向任何方向移动窗口，都应导致强度发生显著变化



平坦区域 的灰度值在窗口移动时几乎不变



边缘区域 在沿着边缘方向移动时灰度变化很小，但垂直边缘方向移动时变化剧烈



角点区域 在窗口向各个方向移动时，灰度都会发生显著变化

规格严格 功夫到家

角点检测：数学推导


考虑将窗口 W 移动 (u, v)

- W 内的像素如何变化？如何衡量这种变化？

—通过逐像素比较移动前后 W 内像素的平方差之和

(SSD误差)。定义 $E(u, v)$:

$$E(u, v) = \sum_{(x, y) \in W} [I(x + u, y + v) - I(x, y)]^2$$



规格严格 功夫到家

小运动假设

I 的泰勒级数展开:

$$I(x+u, y+v) = I(x, y) + \frac{\partial I}{\partial x}u + \frac{\partial I}{\partial y}v + \text{higher order terms}$$

若移动 (u, v) 较小, 则 **一阶近似** 效果良好

$$\begin{aligned} I(x+u, y+v) &\approx I(x, y) + \frac{\partial I}{\partial x}u + \frac{\partial I}{\partial y}v \\ &\approx I(x, y) + [I_x \ I_y] \begin{bmatrix} u \\ v \end{bmatrix} \end{aligned}$$

shorthand: $I_x = \frac{\partial I}{\partial x}$

将其代入上一页的 $E(u, v)$


规格严格 功夫到家

角点检测: 数学推导

► 将窗口 W 移动 (u, v) , 像素的变化 (SSD),

亦即 $E(u, v)$:

$$\begin{aligned} E(u, v) &= \sum_{(x, y) \in W} [I(x+u, y+v) - I(x, y)]^2 \\ &\approx \sum_{(x, y) \in W} [I(x, y) + [I_x \ I_y] \begin{bmatrix} u \\ v \end{bmatrix} - I(x, y)]^2 \\ &\approx \sum_{(x, y) \in W} \left[[I_x \ I_y] \begin{bmatrix} u \\ v \end{bmatrix} \right]^2 \end{aligned}$$



规格严格 功夫到家

角点检测：数学推导

这可以改写为：

$$E(u, v) = \sum_{(x,y) \in W} [u \ v] \underbrace{\begin{bmatrix} I_x^2 & I_x I_y \\ I_y I_x & I_y^2 \end{bmatrix}}_H \begin{bmatrix} u \\ v \end{bmatrix}$$

$\sum_{(x,y) \in W} \left[[I_x \ I_y] \begin{bmatrix} u \\ v \end{bmatrix} \right]^2$

$E(u, v)$ 的最小值是多少？


直觉答案可能是： $u=0, v=0 \Rightarrow E=0$

但这是一个退化解，没有任何判别意义。

规格严格 功夫到家

角点检测：数学推导

$$E(u, v) = \sum_{(x,y) \in W} [u \ v] \underbrace{\begin{bmatrix} I_x^2 & I_x I_y \\ I_y I_x & I_y^2 \end{bmatrix}}_H \begin{bmatrix} u \\ v \end{bmatrix}$$




而我们真正关心的是：

- 固定“位移大小”，看哪个方向变化最大/最小？
- 也就是说，将窗口中心移动到蓝色单位圆上的任意位置上，哪些方向会导致E值最大和最小？

规格严格 功夫到家

角点检测：数学推导

$$E(u, v) = \sum_{(x,y) \in W} [u \ v] \underbrace{\begin{bmatrix} I_x^2 & I_x I_y \\ I_y I_x & I_y^2 \end{bmatrix}}_H \begin{bmatrix} u \\ v \end{bmatrix}$$



引入约束： $\|\mathbf{d}\|^2 = u^2 + v^2 = 1$

问题变成： $\min_{\|\mathbf{d}\|=1} \mathbf{d}^T H \mathbf{d} \quad \max_{\|\mathbf{d}\|=1} \mathbf{d}^T H \mathbf{d}$

带约束的优化问题

规格严格 功夫到家

拉格朗日乘子法

1. 构造拉格朗日函数

约束条件是单位位移：

$$u^2 + v^2 = 1$$

误差函数二次型：

$$E(u, v) = [u \ v] H \begin{bmatrix} u \\ v \end{bmatrix} = u^2 H_{11} + 2uv H_{12} + v^2 H_{22}$$

构造拉格朗日函数：

$$\mathcal{L}(u, v, \lambda) = E(u, v) - \lambda(u^2 + v^2 - 1)$$

代入：

$$\mathcal{L}(u, v, \lambda) = u^2 H_{11} + 2uv H_{12} + v^2 H_{22} - \lambda(u^2 + v^2 - 1)$$

2. 对 u 求偏导

$$\frac{\partial \mathcal{L}}{\partial u} = 2H_{11}u + 2H_{12}v - 2\lambda u$$

令其为 0：

$$2H_{11}u + 2H_{12}v - 2\lambda u = 0 \Rightarrow (H_{11} - \lambda)u + H_{12}v = 0$$

3. 对 v 求偏导

$$\frac{\partial \mathcal{L}}{\partial v} = 2H_{12}u + 2H_{22}v - 2\lambda v$$

令其为 0：

4. 得到线性方程组

$$\begin{cases} (H_{11} - \lambda)u + H_{12}v = 0 \\ H_{12}u + (H_{22} - \lambda)v = 0 \end{cases}$$

$$\begin{bmatrix} H_{11} & H_{12} \\ H_{12} & H_{22} \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \lambda \begin{bmatrix} u \\ v \end{bmatrix}$$

规格严格 功夫到家

特征值与特征向量简要回顾

矩阵A的特征向量x满足:

$$Ax = \lambda x$$

标量 λ 为对应于x的特征值

$$\det(A - \lambda I) = 0$$

➤ 通过求解以下方程得到特征值:

➤ 在我们的例子中, $A = H$ 是一个2x2矩阵 $\det \begin{bmatrix} h_{11} - \lambda & h_{12} \\ h_{21} & h_{22} - \lambda \end{bmatrix} = 0$

➤ 解为: $\lambda_{\pm} = \frac{1}{2} \left[(h_{11} + h_{22}) \pm \sqrt{4h_{12}h_{21} + (h_{11} - h_{22})^2} \right]$

一旦求得 λ , 通过求解以下方程得到x $\begin{bmatrix} h_{11} - \lambda & h_{12} \\ h_{21} & h_{22} - \lambda \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 0$



$$Hx_+ = \lambda_+ x_+$$

$$Hx_- = \lambda_- x_-$$

规格严格 功夫到家

角点检测: 数学推导:

$$E(u, v) = \sum_{(x, y) \in W} [u \ v] \underbrace{\begin{bmatrix} I_x^2 & I_x I_y \\ I_y I_x & I_y^2 \end{bmatrix}}_H \begin{bmatrix} u \\ v \end{bmatrix}$$



H的特征值与特征向量

- 定义变化最小和最大的移动方向 (E值)
- x_+ = E增加最大的方向
- λ_+ = 在 x_+ 方向上的增加量
- x_- = E增加最小的方向
- λ_- = 在 x_- 方向上的增加量

$$Hx_+ = \lambda_+ x_+$$

$$Hx_- = \lambda_- x_-$$




规格严格 功夫到家

λ_+ , x_+ , λ_- , x_- 与角点检测之间的关系？

角点检测：数学推导

希望 $E(u, v)$ 在所有方向上对于微小移动响应都很大

- $E(u, v)$ 在所有单位向量 $[u \ v]$ 上的最小值也应较大
- 该最小值由 H 的较小特征值 (λ_-) 给出




 I  λ_+  λ_-

规格严格 功夫到家

步骤如下：


角点检测总结

- 计算图像中每一点的梯度
- 根据梯度项创建 H 矩阵
- 计算特征值
- 寻找响应较大的点 ($\lambda_- > \text{阈值}$)
- 选择 λ_- 为局部最大值的点作为特征

 I  λ_+  λ_-

规格严格 功夫到家

角点响应函数



规格严格 功夫到家

$$R = \det(H) - \alpha \text{trace}(H)^2 = \lambda_1 \lambda_2 - \alpha (\lambda_1 + \lambda_2)^2$$

α : constant (0.04 to 0.06)

- 在**角点**区域, λ_1 和 λ_2 都很大且相当, 它们的乘积 $\lambda_1 \lambda_2$ 会远大于它们的和 $(\lambda_1 + \lambda_2)$ 的平方 (乘以 α)。因此, R 会得到一个很大的正值。
- 在**边缘**区域, λ_1 很大而 λ_2 很小, 乘积 $\lambda_1 \lambda_2$ 会较小, 而 $(\lambda_1 + \lambda_2)^2$ 主要受 λ_1 主导, 相对较大。因此, R 会得到一个较小的值 (通常是负值)。
- 在**平坦**区域, λ_1 和 λ_2 都很小, 乘积和和都很小, 因此 R 的绝对值很小, 接近零。

规格严格 功夫到家

哈里斯检测器：步骤

1. 计算每个像素的导数
2. 计算每个像素的矩阵 H
3. 计算角点响应函数 R
4. 对 R 进行阈值处理
5. 寻找响应函数的局部最大值 (非极大值抑制)

C.Harris and M.Stephens. "[A Combined Corner and Edge Detector.](#) "
Proceedings of the 4th Alvey Vision Conference, pages 147—151, 1988.

规格严格 功夫到家


哈里斯检测器：示例



规格严格 功夫到家

哈里斯检测器:

计算角点相应 R



规格严格 功夫到家

哈里斯检测器:

寻找角点响应较大的点: $R > \text{閾值}$



规格严格 功夫到家

哈里斯检测器

仅选取R的局部极大值点



规格严格 功夫到家

哈里斯检测器



规格严格 功夫到家

目录


➤ 角点

➤ 斑点

➤ 描述符


規格嚴格 功夫到家

帶尺度选择的斑点检测



規格嚴格 功夫到家

回顾：一维高斯函数及其导数




$$G_{\sigma}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

$$G'_{\sigma}(x) = -\frac{x}{\sigma^2} G_{\sigma}(x)$$

$$G''_{\sigma}(x) = \left(\frac{x^2}{\sigma^4} - \frac{1}{\sigma^2} \right) G_{\sigma}(x)$$

规格严格 功夫到家

回顾：边缘检测




边缘

高斯导数滤波器 (DoG)

边缘 = 导数的最大值

规格严格 功夫到家


回顾：边缘检测



规格严格 功夫到家

从边缘到斑点


- 边缘 = 波纹
- 斑点 = 两个波纹的叠加



空间选择：如果拉普拉斯算子的尺度与斑点的尺度“匹配”，则拉普拉斯响应的幅度将在斑点的中心达到最大值。


规格严格 功夫到家

从边缘到斑点



规格严格 功夫到家

尺度归一化的效果



规格严格 功夫到家

斑点检测尺度匹配与归一化

第一部分：一维信号中的斑点检测与尺度匹配

1. 信号与滤波器的数学模型

假设一维的“斑点”信号，为了数学推导的严谨和简便，其建模为一个高斯信号，其“真实尺度”（宽度）由参数 r 决定：

$$f(x) = e^{-\frac{x^2}{2r^2}}$$

定义一维高斯滤波器，其“探测尺度”由参数 σ 决定：

$$g(x; \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

2. 滤波器响应的推导

计算高斯信号与高斯滤波器的卷积。两个高斯函数卷积的结果仍然是高斯函数，其方差相加：

$$f(x) * g(x; \sigma) = \frac{r}{\sqrt{r^2 + \sigma^2}} e^{-\frac{x^2}{2(r^2 + \sigma^2)}}$$

对其求二阶导数，得到滤波器响应：

$$\begin{aligned} R(x; \sigma) &= \frac{\partial^2}{\partial x^2} \left[\frac{r}{\sqrt{r^2 + \sigma^2}} e^{-\frac{x^2}{2(r^2 + \sigma^2)}} \right] \\ &= \frac{r}{\sqrt{r^2 + \sigma^2}} \left(\frac{x^2}{(r^2 + \sigma^2)^2} - \frac{1}{r^2 + \sigma^2} \right) e^{-\frac{x^2}{2(r^2 + \sigma^2)}} \end{aligned}$$

斑点的中心在 $x = 0$ ，中心点的峰值响应：

$$R(0; \sigma) = \frac{r}{\sqrt{r^2 + \sigma^2}} \cdot \left(-\frac{1}{r^2 + \sigma^2} \right) = -\frac{r}{(r^2 + \sigma^2)^{\frac{3}{2}}}$$

3. 为什么需要尺度归一化？

我们希望通过改变 σ 来寻找最大响应，从而匹配斑点大小。但观察上面的响应幅度 $|R(0; \sigma)| = \frac{r}{(r^2 + \sigma^2)^{\frac{3}{2}}}$ ：

无论斑点的真实大小 r 是多少，该表达式在 $\sigma \rightarrow 0$ 时总是取得最大值。这意味着如果不加处理，滤波器总是倾向于对无穷小的噪声产生最大响应，而无法真正匹配信号尺度。这是因为随着 σ 增大，高斯二阶导数的振幅呈 $\frac{1}{\sigma^2}$ 的速度剧烈衰减。

规格严格 功夫到家

斑点检测尺度匹配与归一化

3. 为什么需要尺度归一化？

我们希望通过改变 σ 来寻找最大响应，从而匹配斑点大小。但观察上面的响应幅度 $|R(0; \sigma)| = \frac{r}{(r^2 + \sigma^2)^{\frac{3}{2}}}$ ：

无论斑点的真实大小 r 是多少，该表达式在 $\sigma \rightarrow 0$ 时总是取得最大值。这意味着如果不加处理，滤波器总是倾向于对无穷小的噪声产生最大响应，而无法真正匹配信号尺度。这是因为随着 σ 增大，高斯二阶导数的振幅呈 $\frac{1}{\sigma^2}$ 的速度剧烈衰减。

4. 尺度归一化的数学推导

为了抵消二阶导数带来的幅度衰减，Lindeberg 提出了尺度归一化理论：**将 k 阶微分算子乘以 σ^k 。**

对于二阶导数 (LoG)，需要乘以 σ^2 。

归一化后的中心响应变为：

$$R_{norm}(0; \sigma) = \sigma^2 \cdot \left(-\frac{r}{(r^2 + \sigma^2)^{\frac{3}{2}}} \right) = -\frac{r\sigma^2}{(r^2 + \sigma^2)^{\frac{3}{2}}}$$

寻找使得 $|R_{norm}(0; \sigma)|$ 最大的探测尺度 σ 。令 $E(\sigma) = \frac{\sigma^2}{(r^2 + \sigma^2)^{\frac{3}{2}}}$ ，对其求导并令为 0：

$$\frac{dE}{d\sigma} = \frac{2\sigma(r^2 + \sigma^2)^{\frac{3}{2}} - \sigma^2 \cdot \frac{3}{2}(r^2 + \sigma^2)^{\frac{1}{2}} \cdot 2\sigma}{(r^2 + \sigma^2)^3} = 0$$

只看分子部分：

$$2\sigma(r^2 + \sigma^2) - 3\sigma^3 = 0$$

$$2\sigma r^2 + 2\sigma^3 - 3\sigma^3 = 0$$

$$2\sigma r^2 - \sigma^3 = 0$$

解得极值点：

$$\sigma = \sqrt{2}r$$

一维结论：经过 σ^2 归一化后，当探测尺度 σ 等于 $\sqrt{2}r$ 时，滤波器响应达到最大。这在数学上证明了，**可以通过寻找归一化 LoG 响应的局部极值，来匹配斑点的真实大小 r 。**

规格严格 功夫到家

斑点检测尺度匹配与归一化

第二部分：二维信号中的斑点检测与尺度匹配

1. 二维模型设定

定义一个二维高斯斑点（例如图像上的一个圆形亮斑），真实尺度为 r ：

$$f(x, y) = e^{-\frac{x^2 + y^2}{2r^2}}$$

二维各向同性高斯滤波器：

$$G(x, y; \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2 + y^2}{2\sigma^2}}$$

2. 二维归一化响应推导

二维信号与高斯的卷积：

$$f(x, y) * G(x, y; \sigma) = \frac{r^2}{r^2 + \sigma^2} e^{-\frac{x^2 + y^2}{2(r^2 + \sigma^2)}}$$

对其求二阶导数，得到滤波器响应：

$$\begin{aligned} R(x, y; \sigma) &= \nabla^2(f * G) = \frac{\partial^2(f * G)}{\partial x^2} + \frac{\partial^2(f * G)}{\partial y^2} \\ &= \frac{r^2}{r^2 + \sigma^2} \left(\frac{x^2 + y^2}{(r^2 + \sigma^2)^2} - \frac{2}{r^2 + \sigma^2} \right) e^{-\frac{x^2 + y^2}{2(r^2 + \sigma^2)}} \end{aligned}$$

求中心 $(0, 0)$ 的响应：

$$R(0, 0; \sigma) = \frac{r^2}{r^2 + \sigma^2} \cdot \left(-\frac{2}{r^2 + \sigma^2} \right) = -\frac{2r^2}{(r^2 + \sigma^2)^2}$$

同样，如果不归一化，最大响应依然在 $\sigma \rightarrow 0$ 处。

按照理论，无论一维还是二维，空间二阶导数的归一化因子都是 σ^2 。乘以 σ^2 得到归一化响应：

$$R_{norm}(0, 0; \sigma) = -\frac{2r^2\sigma^2}{(r^2 + \sigma^2)^2}$$

3. 匹配二维斑点大小

寻找使二维归一化响应绝对值最大化的 σ 。令 $E(\sigma) = \frac{\sigma^2}{(r^2 + \sigma^2)^2}$ ，对 σ 求导并令为 0：

$$\frac{dE}{d\sigma} = \frac{2\sigma(r^2 + \sigma^2)^2 - \sigma^2 \cdot 2(r^2 + \sigma^2) \cdot 2\sigma}{(r^2 + \sigma^2)^4} = 0$$

解得极值点：

$$\sigma = r$$


规格严格 功夫到家

尺度空间斑点检测示例



规格严格 功夫到家

尺度空间斑点检测示例



$\sigma = 11.9912$

規格嚴格 功夫到家

尺度空间斑点检测示例



規格嚴格 功夫到家

目录

➤ 角点

➤ 斑点


➤ 描述符

规格严格 功夫到家

特征匹配

➤ 挑战二：特征的唯一描述

➤ 检测到特征点后，我们如何准确识别出它在另一幅图像中的“孪生兄弟”？



这就需要**一个独特性或显著性强的描述符**。我们需要给每个特征点一个独特的“身份标识”，让它在众多点中能够被精确地识别出来。


规格严格 功夫到家

哈里斯角点检测

Harris & Stephens, 1988

SIFT 描述符


David Lowe, 1999




- **SIFT (尺度不变特征变换)**
算是计算机视觉领域中使用的
一种强大算法。
- **它旨在从图像中提取独特特征，从而实现强大的图像匹配和物体识别。**



总引用量:
22563



总引用量:
27343



失到家

尺度不变特征变换 (SIFT)

1. 尺度不变特征变换(Scale-invariant feature transform, SIFT)是一种用来检测与描述图像中的局部性特征的计算机视觉算法，它在空间尺度中寻找极值点，并提取出其位置、尺度、旋转不变量。

2. SIFT算法的特点：

- SIFT特征是图像的局部特征，其对旋转、尺度缩放、亮度变化保持不变性，对视角变化、仿射变换、噪声也保持一定程度的稳定性；
- 独特性，信息量丰富，适用于在特征数据库中进行快速、准确的匹配；
- 多量性，即使少数的几个物体也可以产生大量的SIFT特征向量；
- 高速性，经优化的SIFT匹配算法甚至可以达到实时的要求。

规格严格 功夫到家

尺度不变特征变换 (SIFT)

3. SIFT算法的步骤:

- 1) **尺度空间极值检测**: 搜索所有尺度上的图像位置。通过高斯差分函数来识别潜在的对于尺度和旋转不变的候选点。
- 2) **关键点定位**: 在每个候选的位置上, 通过一个拟合精细的模型来确定位置和尺度。
- 3) **关键点方向分配与描述**: 在每个关键点周围的邻域内, 以选定的尺度测量图像局部的梯度, 构建方向直方图, 作为关键点的描述符。

規格嚴格 功夫到家

尺度空间极值检测

規格嚴格 功夫到家

1. 通用尺度计算公式

对于高斯金字塔中第 o 组 (Octave)、第 s 层 (Level) 的图像，其对应的尺度 $\sigma(o, s)$ 计算公式为：

$$\sigma(o, s) = \sigma_0 \cdot k^{s+o-S}$$

其中：


- σ_0 ：初始尺度基准 (通常取 1.6)。
- k ：尺度间隔倍乘因子， $k = 2^{1/S}$ 。
- S ：每组包含的有效层数 (Levels per Octave)，通常取 3。
- o ：组索引 (0, 1, 2...)，代表图像分辨率降低的倍数。
- s ：组内层索引 (0, 1, ..., $S, S+1, S+2$)。

1.1 组内尺度变化 (层与层之间)

在同一个组 (Octave) 内部，图像尺寸不变， σ 按照固定比例 k 递增。
若第 s 层的尺度为 σ_s ，则下一层 σ_{s+1} 为：

$$\sigma_{s+1} = k \cdot \sigma_s$$

- **物理意义**：随着 s 增加，图像的高斯模糊程度逐渐加大，模拟“由近及远”观察物体的效果。
- **参数设定**：为了覆盖一个完整的倍频程 (即尺度翻倍)，设 $k = 2^{1/S}$ 。



1. 通用尺度计算公式

对于高斯金字塔中第 o 组 (Octave)、第 s 层 (Level) 的图像，其对应的尺度 $\sigma(o, s)$ 计算公式为：

$$\sigma(o, s) = \sigma_0 \cdot k^{s+o-S}$$

其中：

- σ_0 ：初始尺度基准 (通常取 1.6)。
- k ：尺度间隔倍乘因子， $k = 2^{1/S}$ 。
- S ：每组包含的有效层数 (Levels per Octave)，通常取 3。
- o ：组索引 (0, 1, 2...)，代表图像分辨率降低的倍数。
- s ：组内层索引 (0, 1, ..., $S, S+1, S+2$)。


为什么组内层数是 $S+3$?

当从一个组进入下一个组 (例如从 Octave 0 到 Octave 1) 时，图像会进行下采样，分辨率变为原来的 1/2。此时尺度的变化遵循以下逻辑：

- **对应关系**：下一组 ($o+1$) 的第 0 层，其实际物理尺度等于上一组 (o) 的第 S 层 (即尺度翻倍后的层)。
- **公式推导**：


$$\sigma(o+1, 0) = 2 \cdot \sigma(o, 0)$$

高斯金字塔的总组数 (Octave) 如何确定？



高斯差分金字塔构建:


- 1) **LoG作用**: 利用高斯拉普拉斯 (LoG, 二阶导数) 在多尺度空间中检测图像的特征点。
- 2) **问题**: LoG计算复杂度高, 效率较低。
- 3) **解决方案**: 用高斯差分 (DoG) 近似LoG, 提高计算效率。
- 4) **DoG金字塔构建**: 基于高斯金字塔, 在每个Octave内, 将相邻两层图像相减得到对应的DoG层。



规格严格 功夫到家

基于DoG尺度空间的关键点检测:

- 1) **关键点检测阶段**: 在DoG尺度空间中搜索局部极值点。
- 2) **比较范围**: 每个像素需与自身同层的8邻域以及上下相邻尺度的18个邻点进行比较 (共26个点)。
- 3) **判定条件**: 若该点是局部最大值或最小值, 则可作为候选关键点。
- 4) **意义**: 关键点是在对应尺度空间中对图像结构的最佳表征。



当 $S = 3$ 时, 生成的 6 层高斯图像 ($S + 3 = 6$) 如下:

高斯层索引	尺度 (σ)	作用	生成的 DoG 层	是否用于极值检测?
L_1	σ_0	缓冲层 (下)	$D_1 = L_2 - L_1$	否 (没有 D_0 来比较)
L_2	$k\sigma_0$	有效层 1	$D_2 = L_3 - L_2$	是 (与 D_1, D_3 比较)
L_3	$k^2\sigma_0$	有效层 2	$D_3 = L_4 - L_3$	是 (与 D_2, D_4 比较)
L_4	$k^3\sigma_0 = 2\sigma_0$	有效层 3	$D_4 = L_5 - L_4$	是 (与 D_3, D_5 比较)
L_5	$k^4\sigma_0$	缓冲层 (上)	$D_5 = L_6 - L_5$	否 (没有 D_6 来比较)
L_6	$k^5\sigma_0$	缓冲层 (上+1)	(无)	仅用于生成 D_5

- 为了得到中间那 3 个 (S) 有效的特征尺度 (L_2, L_3, L_4), 必须计算 6 层 ($S + 3$) 高斯图像。
- L_4 的尺度恰好是 $2\sigma_0$ (因为 $k = 2^{1/3}$, 所以 $k^3 = 2$)。
- 所以, L_4 既是有效特征层的最后一层, 也是尺度翻倍的那一层, 同时它还是整个 6 层序列中的“倒数第三层”。

规格严格 功夫到家

关键点定位

规格严格 功夫到家

4.1 角点

4.2 斑点

4.3 描述符


一、关键点定位的必要性

1. 离散极值点的局限性

- 尺度空间极值检测阶段仅能获得**整数坐标的候选关键点**（像素级精度），但真实极值通常位于连续空间中。
- 直接使用离散点会导致后续特征描述子累积误差，**降低匹配鲁棒性**。

2. 定位目标

- 实现关键点的**亚像素级定位**。



离散空间与连续空间极值点的差别

二、亚像素级关键点优化过程

1. 泰勒展开建模

设DoG函数在离散极值点 $\mathbf{x} = (x, y, \sigma)^T$ 处的响应为 $D(\mathbf{x})$ ，其连续空间中的精确极值点可表示为 $\mathbf{x} + \hat{\mathbf{x}}$ 。通过**二阶泰勒展开**近似DoG函数：

$$D(\mathbf{x} + \hat{\mathbf{x}}) \approx D(\mathbf{x}) + \left(\frac{\partial D}{\partial \mathbf{x}} \right)^T \hat{\mathbf{x}} + \frac{1}{2} \hat{\mathbf{x}}^T \left(\frac{\partial^2 D}{\partial \mathbf{x}^2} \right) \hat{\mathbf{x}}$$

其中：

- $\frac{\partial D}{\partial \mathbf{x}}$ 为一阶梯度向量 (3×1)，
- $\frac{\partial^2 D}{\partial \mathbf{x}^2}$ 为Hessian矩阵 (3×3 二阶偏导矩阵)。

2. 最优偏移量求解

为了寻找**连续空间中的精确极值**，对展开式求 $\hat{\mathbf{x}}$ 的导数并令梯度为零，得到极值条件：

$$\frac{\partial D}{\partial \mathbf{x}} + \left(\frac{\partial^2 D}{\partial \mathbf{x}^2} \right) \hat{\mathbf{x}} = 0$$

解得**最优偏移量** $\hat{\mathbf{x}}$ 的解析解：

$$\hat{\mathbf{x}} = - \left(\frac{\partial^2 D}{\partial \mathbf{x}^2} \right)^{-1} \frac{\partial D}{\partial \mathbf{x}}$$

该公式将离散极值点修正为连续空间中的精确位置。

规格严格 功夫到家

关键点方向分配与描述

规格严格 功夫到家

1) **目标**: 实现描述符的旋转不变性。

2) **方法**: 利用关键点的局部图像特征, 为每个关键点分配基准方向, 最终生成描述符。

3) **具体操作**:


① 在对应高斯金字塔中, 以关键点为中心, 取约 3σ 邻域窗口, 统计该区域内像素的梯度幅值与方向分布。

$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2}$$

$$\theta(x, y) = \tan^{-1}((L(x, y+1) - L(x, y-1)) / (L(x+1, y) - L(x-1, y)))$$

② 将邻域窗口划分为 $4 \times 4 = 16$ 个子块, 每个子块内部构建一个 8-bin 方向直方图 (0-360°)。

子块内的像素方向决定“投给哪个bin”, 像素幅值决定“投票权重”。



3) 具体操作:

① 在对应高斯金字塔中，以关键点为中心，取约 3σ 邻域窗口，统计该区域内像素的梯度幅值与方向分布。

$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2}$$

$$\theta(x, y) = \tan^{-1}((L(x, y+1) - L(x, y-1)) / (L(x+1, y) - L(x-1, y)))$$

② 将邻域窗口划分为 $4 \times 4 = 16$ 个子块，每个子块内部构建一个 8-bin 方向直方图 (0–360°)。子块内的像素方向决定“投给哪个bin”，像素幅值决定“投票权重”。



③ 关键点描述符就是在关键点尺度空间内 4×4 的窗口中计算的 8 个方向的直方图信息，共 $4 \times 4 \times 8 = 128$ 维向量表征。

尺度不变特征变换 (SIFT)

SIFT算法详解：关键点匹配

两个关键点匹配，可通过计算两个关键点描述符的距离来实现。可能会产生大量的误匹配点。

