

## 5. 拟合与匹配

张宏志

机器学习研究中心, 计算学部  
2026 春

zhanghz@hit.edu.cn 390684271@qq.com




动机: 创建一个全景图像



Matthew Brown, David G. Lowe: Recognising Panoramas, ICCV 2003: 1218-1227

规格严格 功夫到家

### 基于特征的图像拼接流程



规格严格 功夫到家


### 基于特征的图像拼接流程



- 提取特征点

规格严格 功夫到家


### 基于特征的图像拼接流程



- 提取特征点
- 计算粗略特征匹配

规格严格 功夫到家

### 基于特征的图像拼接流程




- 提取特征点
- 计算粗略特征匹配
- RANSAC 筛选内点

规格严格 功夫到家



### 基于特征的图像拼接流程



- 提取特征点
- 计算粗略特征匹配
- RANSAC 筛选内点
- 最小二乘法估计最优单应性矩阵

$$w \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

规格严格 功夫到家



### 基于特征的图像拼接流程



- 提取特征点
  - 计算粗略特征匹配
  - RANSAC 筛选内点
  - 最小二乘法估计最优单应性矩阵
- 之前的课程

$$w \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- 图像拼接

规格严格 功夫到家



### 目录

#### 5.1 拟合技术

- 最小二乘法
- 总体最小二乘法

#### 5.2 随机采样一致性 (RANSAC)

#### 5.3 将匹配视为拟合问题

#### 5.4 霍夫变换

规格严格 功夫到家



### 目录

#### 5.1 拟合技术

- 最小二乘法
- 总体最小二乘法

#### 5.2 随机采样一致性 (RANSAC)

#### 5.3 将匹配视为拟合问题

#### 5.4 霍夫变换

规格严格 功夫到家



#### 5.1 拟合技术

#### 5.2 RANSAC

#### 5.3 将匹配视为拟合

#### 5.4 霍夫变换

### 最小二乘线性拟合

- 数据:  $(x_1, y_1), \dots, (x_n, y_n)$
- 线性方程:  $y_i = mx_i + b$
- 寻找  $(m, b)$  来最小化以下误差


$$E = \sum_{i=1}^n (y_i - mx_i - b)^2$$

对  $m$  和  $b$  求偏导并令其为 0 (必要极值条件):

$$\frac{\partial E}{\partial m} = -2 \sum_{i=1}^n x_i (y_i - mx_i - b) = 0, \quad \frac{\partial E}{\partial b} = -2 \sum_{i=1}^n (y_i - mx_i - b) = 0$$

➡  $\begin{bmatrix} m \\ b \end{bmatrix} = ?$

规格严格 功夫到家



#### 5.1 拟合技术

#### 5.2 RANSAC

#### 5.3 将匹配视为拟合

#### 5.4 霍夫变换

### 最小二乘线性拟合

对  $m$  和  $b$  求偏导并令其为 0 (必要极值条件):

$$\frac{\partial E}{\partial m} = -2 \sum_{i=1}^n x_i (y_i - mx_i - b) = 0,$$

$$\frac{\partial E}{\partial b} = -2 \sum_{i=1}^n (y_i - mx_i - b) = 0.$$

化简得到两条线性方程:

$$\sum_{i=1}^n x_i y_i - m \sum_{i=1}^n x_i^2 - b \sum_{i=1}^n x_i = 0,$$

$$\sum_{i=1}^n y_i - m \sum_{i=1}^n x_i - nb = 0.$$

简化记号:  $S_x = \sum x_i, S_y = \sum y_i, S_{xx} = \sum x_i^2, S_{xy} = \sum x_i y_i,$

$$\begin{cases} S_{xx} m + S_x b = S_{xy} \\ S_x m + nb = S_y \end{cases} \Rightarrow A \begin{bmatrix} m \\ b \end{bmatrix} = B$$

$$\begin{bmatrix} m \\ b \end{bmatrix} = A^{-1} B$$

规格严格 功夫到家

5.1 拟合技术5.2 RANSAC5.3 随机采样一致性5.3 霍夫变换

### 最小二乘线性拟合

➢数据:  $(x_1, y_1), \dots, (x_n, y_n)$

➢线性方程:  $y_i = mx_i + b$

➢寻找  $(m, b)$  来最小化以下误差:

$$E = \sum_{i=1}^n (y_i - mx_i - b)^2$$

对  $m$  和  $b$  求偏导并令其为 0 (必要极值条件):

$$\frac{\partial E}{\partial m} = -2 \sum_{i=1}^n x_i (y_i - mx_i - b) = 0,$$
$$\frac{\partial E}{\partial b} = -2 \sum_{i=1}^n (y_i - mx_i - b) = 0.$$

➡  $\begin{bmatrix} m \\ b \end{bmatrix} = ?$

“垂直”最小二乘法的问题:

无法拟合垂直线, 且由于误差采用的是垂直误差, 导致越接近垂直线, 拟合效果越差。

规格严格 功夫到家

5.1 拟合技术5.2 RANSAC5.3 随机采样一致性5.3 霍夫变换

### 目录

- 5.1 拟合技术
  - 最小二乘法
  - 总体最小二乘法
- 5.2 随机采样一致性 (RANSAC)
- 5.3 将匹配视为拟合问题
- 5.4 霍夫变换

规格严格 功夫到家

5.1 拟合技术5.2 RANSAC5.3 随机采样一致性5.3 霍夫变换

### 总体最小二乘法

•定义直线  $L: ax+by=d$  ( $a^2+b^2=1$ )

•直线  $L$  与点  $(x_i, y_i)$  的距离表示为:  $|ax_i + by_i - d|$

•寻找  $(a, b, d)$  来最小化法向距离的平方和:

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$

定义样本均值:  $\bar{x} = \frac{1}{n} \sum x_i, \bar{y} = \frac{1}{n} \sum y_i$ .

中心化分解:  $ax_i + by_i - d = a(x_i - \bar{x}) + b(y_i - \bar{y}) + (a\bar{x} + b\bar{y} - d)$ .

展开平方:  $E = \sum_i [a(x_i - \bar{x}) + b(y_i - \bar{y})]^2 + 2[a(x_i - \bar{x}) + b(y_i - \bar{y})](a\bar{x} + b\bar{y} - d) + (a\bar{x} + b\bar{y} - d)^2$ .

分配和号:  $E = \underbrace{\sum_i [a(x_i - \bar{x}) + b(y_i - \bar{y})]^2}_{(1)} + 2 \underbrace{[a(x_i - \bar{x}) + b(y_i - \bar{y})]}_{(2)} \underbrace{(a\bar{x} + b\bar{y} - d)}_{(3)} + \underbrace{(a\bar{x} + b\bar{y} - d)^2}_{(3)}$ .

整理得到:  $E = \sum_i [a(x_i - \bar{x}) + b(y_i - \bar{y})]^2 + n(a\bar{x} + b\bar{y} - d)^2$ .

规格严格 功夫到家

5.1 拟合技术5.2 RANSAC5.3 随机采样一致性5.3 霍夫变换

### 总体最小二乘法

•定义直线  $L: ax+by=d$  ( $a^2+b^2=1$ )

•直线  $L$  与点  $(x_i, y_i)$  的距离表示为:  $|ax_i + by_i - d|$

•寻找  $(a, b, d)$  来最小化法向距离的平方和:

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$

定义样本均值:  $\bar{x} = \frac{1}{n} \sum x_i, \bar{y} = \frac{1}{n} \sum y_i$ .

中心化分解:  $ax_i + by_i - d = a(x_i - \bar{x}) + b(y_i - \bar{y}) + (a\bar{x} + b\bar{y} - d)$ .

整理得到:  $E = \sum_i [a(x_i - \bar{x}) + b(y_i - \bar{y})]^2 + n(a\bar{x} + b\bar{y} - d)^2$ .

因此, 对于固定的  $a, b$ , 关于  $d$  的最小值由二次项给出

$$\frac{\partial E}{\partial d} = 2n(d - a\bar{x} - b\bar{y}) = 0 \Rightarrow d = a\bar{x} + b\bar{y}$$

➡  $E(a, b) = \sum_i [a(x_i - \bar{x}) + b(y_i - \bar{y})]^2$ .

规格严格 功夫到家

5.1 拟合技术5.2 RANSAC5.3 随机采样一致性5.3 霍夫变换

### 总体最小二乘法

•定义直线  $L: ax+by=d$  ( $a^2+b^2=1$ )

•直线  $L$  与点  $(x_i, y_i)$  的距离表示为:  $|ax_i + by_i - d|$

•寻找  $(a, b, d)$  来最小化法向距离的平方和:

$$E = \sum_{i=1}^n (ax_i + by_i - d)^2$$

➡  $E(a, b) = \sum_i [a(x_i - \bar{x}) + b(y_i - \bar{y})]^2$ .

展开平方:  $E(a, b) = \sum_i [a^2(x_i - \bar{x})^2 + 2ab(x_i - \bar{x})(y_i - \bar{y}) + b^2(y_i - \bar{y})^2]$ .

分配和号:  $E(a, b) = a^2 \sum_i (x_i - \bar{x})^2 + 2ab \sum_i (x_i - \bar{x})(y_i - \bar{y}) + b^2 \sum_i (y_i - \bar{y})^2$ .

符号定义:  $S_{xx} = \sum_i (x_i - \bar{x})^2, S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}), S_{yy} = \sum_i (y_i - \bar{y})^2$ .

整理得到:  $E(a, b) = a^2 S_{xx} + 2ab S_{xy} + b^2 S_{yy}$ .

写成矩阵形式:  $E(a, b) = (a, b) \begin{pmatrix} S_{xx} & S_{xy} \\ S_{xy} & S_{yy} \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \mathbf{u}^T \mathbf{S} \mathbf{u}$  其中  $\mathbf{u} = \begin{pmatrix} a \\ b \end{pmatrix}, \mathbf{S} = \begin{pmatrix} S_{xx} & S_{xy} \\ S_{xy} & S_{yy} \end{pmatrix}$

规格严格 功夫到家

5.1 拟合技术5.2 RANSAC5.3 随机采样一致性5.3 霍夫变换

### 回顾: 拉格朗日乘子法

- 构造拉格朗日函数
- 对  $u$  求偏导
- 对  $v$  求偏导
- 得到线性方程组

约束条件是单位位移:  $u^2 + v^2 = 1$

误差函数二次型:  $E(u, v) = \begin{bmatrix} u & v \end{bmatrix} H \begin{bmatrix} u \\ v \end{bmatrix} = u^2 H_{11} + 2uv H_{12} + v^2 H_{22}$

构造拉格朗日函数:  $\mathcal{L}(u, v, \lambda) = E(u, v) - \lambda(u^2 + v^2 - 1)$

代入:  $\mathcal{L}(u, v, \lambda) = u^2 H_{11} + 2uv H_{12} + v^2 H_{22} - \lambda(u^2 + v^2 - 1)$

令其为零:  $\frac{\partial \mathcal{L}}{\partial u} = 2H_{11}u + 2H_{12}v - 2\lambda u = 0$

令其为零:  $\frac{\partial \mathcal{L}}{\partial v} = 2H_{12}u + 2H_{22}v - 2\lambda v = 0$

令其为零:  $(H_{11} - \lambda)u + H_{12}v = 0$

令其为零:  $H_{12}u + (H_{22} - \lambda)v = 0$

得到线性方程组:  $\begin{bmatrix} H_{11} - \lambda & H_{12} \\ H_{12} & H_{22} - \lambda \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \mathbf{0}$

➡  $\begin{bmatrix} H_{11} & H_{12} \\ H_{12} & H_{22} \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \lambda \begin{bmatrix} u \\ v \end{bmatrix}$

规格严格 功夫到家



5.1 拟合技术

5.2 RANSAC

5.3 匹配距离拟合

5.3 霍夫变换

## 总体最小二乘法

• 定义直线  $L: ax+by=d$  ( $a^2+b^2=1$ )

• 直线  $L$  与点  $(x_i, y_i)$  的距离表示为:  $|ax_i + by_i - d|$

• 寻找  $(a, b, d)$  来最小化法向距离的平方和:  $E = \sum_{i=1}^n (ax_i + by_i - d)^2$

写成矩阵形式:  $E(a, b) = b \begin{pmatrix} S_{xx} & S_{xy} \\ S_{xy} & S_{yy} \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} u^T S u$  其中  $u = \begin{pmatrix} a \\ b \end{pmatrix}$ ,  $S = \begin{pmatrix} S_{xx} & S_{xy} \\ S_{xy} & S_{yy} \end{pmatrix}$


求解约束优化问题 -> 拉格朗日乘数法  $Su = \lambda u$

$(a, b)$  = 归一化的特征向量, 对应矩阵  $S$  的最小特征值.

$$d = a\bar{x} + b\bar{y}$$

总体最小二乘法可以解决无法拟合垂直直线问题

规格严格 功夫到家



5.1 拟合技术

5.2 RANSAC

5.3 匹配距离拟合

5.3 霍夫变换

## 目录

5.1 拟合技术

5.2 随机采样一致性 (RANSAC)

5.3 将匹配视为拟合问题

5.4 霍夫变换

规格严格 功夫到家



5.1 拟合技术

5.2 RANSAC

5.3 匹配距离拟合

5.3 霍夫变换

## RANSAC

• 随机采样一致性 (Random sample consensus, RANSAC): 在存在**异常值**的情况下, 非常通用的模型拟合框架

• 流程:

➢ 均匀随机地选择一小部分点

➢ 为这个子集拟合一个模型

➢ 找出剩余点中所有与模型“接近”的点作为**内点**, 计数 (投票), 并将其余点视为**外点** (异常值)

➢ 多次循环, 并选择内点累计数量 (投票) 最多的模型

规格严格 功夫到家




5.1 拟合技术

5.2 RANSAC

5.3 匹配距离拟合

5.3 霍夫变换

## 用于直线拟合的 RANSAC



规格严格 功夫到家



5.1 拟合技术

5.2 RANSAC

5.3 匹配距离拟合

5.3 霍夫变换

## 选择参数

### 1. 基础定义与符号规范

- 总样本数:  $N$
- 最小样本数:  $s = 2$  (二维直线拟合需 2 个点唯一确定模型)
- 距离阈值:  $t$  (用于判定内点)
- 内点比例:  $\epsilon$  (指单个点为内点的概率  $\epsilon$ )
- 置信度:  $p_{conf}$  (算法成功找到最优模型的概率, 如 0.99)
- 迭代次数:  $k$

### 2. 迭代次数的理论计算

迭代次数  $k$  需保证以高概率 (置信度  $p_{conf}$ ) 抽到内点样本。单次采样得到内点概率为  $\epsilon^s$ 。

• 至少一次成功采样的概率:

$$p_{conf} = 1 - (1 - \epsilon^s)^k$$

• 最小迭代次数公式:

$$k = \left\lceil \frac{\log(1 - p_{conf})}{\log(1 - \epsilon^s)} \right\rceil$$

例如: 若  $\epsilon = 0.7$  (内点占 70%),  $s = 2$ ,  $p_{conf} = 0.99$ , 则:

$$k = \left\lceil \frac{\log(0.01)}{\log(1 - 0.7^2)} \right\rceil \approx \left\lceil \frac{-4.605}{-0.619} \right\rceil = 8$$

### 数学上的“3-σ 原则”

在统计学中, 测量误差通常假设服从高斯分布 (正态分布)。大部分真实的点, 会集中在直线附近, 离直线越远, 概率越低。

- 1 标准差 ( $\sigma$ ): 约 68% 的真实内点会落在距离直线  $\sigma$  的范围内。
- 2 标准差 ( $2\sigma$  或  $1.96\sigma$ ): 约 95% 的真实内点会落在距离直线  $2\sigma$  的范围内。
- 3 标准差 ( $3\sigma$ ): 约 99.7% 的真实内点都会落在里面。

### 3. 距离阈值 $t$ 的设置依据

$t$  决定了内点判定的严格性。其理论依据是噪声分布假设:

- 若测量误差服从  $N(0, \sigma^2)$ , 则点到直线的距离平方  $d^2$  服从自由度为 1 的  $\chi^2$  分布。
- 设内点判定的置信概率为  $\alpha$  (如  $\alpha = 0.95$ ), 则:

$$t^2 = \chi_{1-\alpha}^2(1) \cdot \sigma^2$$

其中  $\chi_{0.95}^2(1) \approx 3.84$ , 故  $t \approx 1.96\sigma$ 。



5.1 拟合技术

5.2 RANSAC

5.3 匹配距离拟合

5.3 霍夫变换

## RANSAC 的优缺点

### • 优点

- 简单而通用
- 适用于许多不同的问题
- 实践中通常效果良好

### • 缺点

- 有很多参数需要调整
- 并非总能基于最少样本数量获得良好的模型初始化结果
- 有时需要进行过多的迭代
- 极低的内点比率可能导致失败

规格严格 功夫到家

5.1 拟合技术

5.2 随机采样一致性 (RANSAC)

5.3 将匹配视为拟合问题

5.4 霍夫变换

图像对齐

• 两种常用的方法：


➢ 直接（基于像素的）对齐

➢ 寻找大多数像素一致的对齐方式

➢ 基于特征的对齐


➢ 寻找提取的特征一致的对齐方式

➢ 可使用基于像素的对齐来验证



作为拟合的对齐

- 之前：数据点拟合为一条直线




寻找能最小化以下残差的模型  $M$ ：

$$\sum_i \text{residual}(x_i, M)$$

作为拟合的对齐


- 之前：数据点拟合为一条直线  $M$



寻找能最小化以下残差的模型  $M$ ：

$$\sum_i \text{residual}(x_i, M)$$

- 对齐：拟合两幅图像中匹配的特征对（匹配对）之间的变换  $T$



寻找能最小化以下残差的变换  $T$

$$\sum_i \text{residual}(T(x_i), x'_i)$$

单应性变换

1. 相似变换 (Similarity Transformation)

相似变换保持形状不变，只改变位置、方向和大小。它包含三个基本操作：

- 平移 (Translation)
- 旋转 (Rotation)
- 均匀缩放 (Uniform Scale)

数学表示：在齐次坐标下，相似变换矩阵为：

$$H_s = \begin{bmatrix} s \cos \theta & -s \sin \theta & t_x \\ s \sin \theta & s \cos \theta & t_y \\ 0 & 0 & 1 \end{bmatrix}$$

其中：

- $s$ ：缩放因子 ( $s > 0$ )
- $\theta$ ：旋转角度
- $(t_x, t_y)$ ：平移向量

自由度分析：相似变换有 4 个自由度：

- 1 个缩放参数  $s$
- 1 个旋转参数  $\theta$
- 2 个平移参数  $t_x, t_y$

变换公式：点对  $(x, y)$  应用相似变换后：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s \cos \theta & -s \sin \theta & t_x \\ s \sin \theta & s \cos \theta & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$



相似变换  
(平移、缩放、旋转)

单应性变换

2. 仿射变换 (Affine Transformation)

仿射变换保持平行性，但不保持角度和长度比例。它在相似变换基础上增加了剪切操作。

数学表示：在齐次坐标下，仿射变换矩阵为：

$$H_a = \begin{bmatrix} a & b & t_x \\ c & d & t_y \\ 0 & 0 & 1 \end{bmatrix}$$

其中：

- $a, b, c, d$ ：控制旋转、缩放和剪切
- $(t_x, t_y)$ ：平移向量

与相似变换的关系：当满足以下条件时，仿射变换退化为相似变换：

- $a = d = s \cos \theta$
- $b = -c = -s \sin \theta$


自由度分析：仿射变换有 6 个自由度：

- 4 个参数 ( $a, b, c, d$ ) 控制线性变换
- 2 个平移参数 ( $t_x, t_y$ )

变换公式：点对  $(x, y)$  应用仿射变换后：

$$\begin{cases} x' = ax + by + t_x \\ y' = cx + dy + t_y \end{cases}$$

关键特性：仿射变换中  $w = 1$  始终成立，因此无需齐次坐标的归一化步骤。



仿射变换  
(仅保持平行性)

哈尔滨工业大学 HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合框架 5.2 RANSAC 5.3 匹配视为拟合 5.3 霍夫变换

## 单应性变换

### 3. 投影变换/单应性变换 (Projective Transformation / Homography)

单应性变换是最一般的2D到2D的线性变换, 能表示透视效果 (如倾斜拍摄的平面物体)。

数学表示: 单应性矩阵是一个  $3 \times 3$  的非奇异矩阵:

$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix}$$

由于齐次坐标的等价性 ( $H$  与  $\lambda H$  表示同一变换,  $\lambda \neq 0$ ), 通常将  $h_{33}$  归一化为 1, 因此单应性矩阵有 **8个自由度**。

变换过程:

- 齐次坐标变换:

$$\begin{bmatrix} x'_h \\ y'_h \\ 1 \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

几何意义: 单应性变换描述了两平面在两个不同视角下的投影关系。例如:

- 仿射变换是单应性变换的特例: 当  $h_{31} = h_{32} = 0$  时, 分母变为常数  $h_{33}$ , 归一化后退化为线性变换。
- 相似变换是仿射变换的特例: 进一步满足  $h_{11} = h_{22}$  且  $h_{12} = -h_{21}$ 。
- 拍摄一张平放的纸张, 从不同角度得到的两幅图像间存在单应性关系。
- 分母  $h_{31}x + h_{32}y + h_{33}$  体现了**透视效果**: 当分母趋近于0时, 点会“趋于无穷远”, 模拟了近大远小的视觉效果。

投影/单应性变换 (能表示透视效果)

规格严格 功夫到家

哈尔滨工业大学 HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合框架 5.2 RANSAC 5.3 匹配视为拟合 5.3 霍夫变换

## 拟合单应性变换

### 1. 单应性变换的基本定义

设单应性矩阵为:

$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix}$$

对于一对对应点  $(x, y)$  和  $(x', y')$ , 其齐次坐标关系为:

$$w \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = H \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

其中  $w$  是比例因子 (因齐次坐标具有尺度不变性)。

展开后得到:

$$\begin{cases} wx' = h_{11}x + h_{12}y + h_{13} \\ wy' = h_{21}x + h_{22}y + h_{23} \\ w = h_{31}x + h_{32}y + h_{33} \end{cases}$$

将上述方程写为矩阵形式:

$$\begin{bmatrix} x & y & 1 & 0 & 0 & 0 & -xx' & -yy' & -x' \\ 0 & 0 & 0 & x & y & 1 & -xy' & -yy' & -y' \end{bmatrix} \begin{bmatrix} h_{11} \\ h_{12} \\ h_{13} \\ h_{21} \\ h_{22} \\ h_{23} \\ h_{31} \\ h_{32} \\ h_{33} \end{bmatrix} = 0$$

### 3. 构造线性方程组

将上述方程写为矩阵形式:

设  $\mathbf{h} = [h_{11}, h_{12}, h_{13}, h_{21}, h_{22}, h_{23}, h_{31}, h_{32}, h_{33}]^T$ , 则每对对应点提供两个方程。

规格严格 功夫到家

哈尔滨工业大学 HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合框架 5.2 RANSAC 5.3 匹配视为拟合 5.3 霍夫变换

## 拟合单应性变换

### 4. 最小化二乘拟合原理

若有  $n$  对对应点 ( $n \geq 4$ ), 可构造  $2n \times 9$  的系数矩阵  $A$ :

$$A = \begin{bmatrix} x_1 & y_1 & 1 & 0 & 0 & 0 & -x_1x'_1 & -y_1y'_1 & -x'_1 \\ 0 & 0 & 0 & x_1 & y_1 & 1 & -x_1y'_1 & -y_1y'_1 & -y'_1 \\ x_2 & y_2 & 1 & 0 & 0 & 0 & -x_2x'_2 & -y_2y'_2 & -x'_2 \\ 0 & 0 & 0 & x_2 & y_2 & 1 & -x_2y'_2 & -y_2y'_2 & -y'_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_n & y_n & 1 & 0 & 0 & 0 & -x_nx'_n & -y_ny'_n & -x'_n \\ 0 & 0 & 0 & x_n & y_n & 1 & -x_ny'_n & -y_ny'_n & -y'_n \end{bmatrix}$$

目标是求解齐次线性方程组:

$$A\mathbf{h} = 0$$

由于单应性矩阵有 **8个自由度** (整体比例可归一化, 通常令  $h_{33} = 1$ ), 需添加约束 ( $\|\mathbf{h}\| = 1$  避免平凡解  $\mathbf{h} = 0$ ).

### 5. 最小化二乘解的推导

#### 5.1 问题形式化

最小化代数误差:  $\min_{\mathbf{h}} \|A\mathbf{h}\|^2$  subject to  $\|\mathbf{h}\| = 1$

#### 5.2 拉格朗日乘数法

构造拉格朗日函数:

$$\mathcal{L}(\mathbf{h}, \lambda) = \mathbf{h}^T A^T A \mathbf{h} - \lambda (\mathbf{h}^T \mathbf{h} - 1)$$

对  $\mathbf{h}$  求导并令导数为零:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}} = 2A^T A \mathbf{h} - 2\lambda \mathbf{h} = 0$$

得到特征方程:

$$A^T A \mathbf{h} = \lambda \mathbf{h}$$

#### 5.3 最优解

- $A^T A$  是  $9 \times 9$  的对称半正定矩阵。
- 最小化  $\|A\mathbf{h}\|^2$  等价于最小化  $\mathbf{h}^T A^T A \mathbf{h}$ 。
- 最优解  $\mathbf{h}$  是  $A^T A$  的最小特征值对应的特征向量。

规格严格 功夫到家

哈尔滨工业大学 HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合框架 5.2 RANSAC 5.3 匹配视为拟合 5.3 霍夫变换

## 目录

### 5.1 拟合技术

### 5.2 随机采样一致性 (RANSAC)

### 5.3 将匹配视为拟合问题

### 5.4 霍夫变换

规格严格 功夫到家

哈尔滨工业大学 HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合框架 5.2 RANSAC 5.3 匹配视为拟合 5.3 霍夫变换

## 自动驾驶车辆 (车道线检测)

规格严格 功夫到家

哈尔滨工业大学 HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合框架 5.2 RANSAC 5.3 匹配视为拟合 5.3 霍夫变换


## 拟合直线

规格严格 功夫到家



为什么需要拟合直线？

直线特征在自然图像中非常常见。



规格严格 功夫到家

## 直线拟合的难点

已知构成一条直线的点，求这条直线。


- 一共有多少条直线？
- 哪些点属于哪条线？

霍夫变换是一种投票技术


- 可以回答上述问题。
- 记录每条可能线上每个边缘点的投票结果。
- 寻找获得许多投票的线

规格严格 功夫到家

## 噪声问题



最小二乘误差拟合



均方误差很容易受到离群点的影响

规格严格 功夫到家

## 线参数化

规格严格 功夫到家

## 直线斜截式

$$y = mx + b$$


↑      ↑  
斜率   Y轴截距

规格严格 功夫到家

## 直线斜截式

$$y = mx + b$$

↑      ↑  
斜率   Y轴截距



规格严格 功夫到家

## 直线双截式

$$\frac{x}{a} + \frac{y}{b} = 1$$


X轴截距      Y轴截距

规格严格 功夫到家

## 直线双截式

$$\frac{x}{a} + \frac{y}{b} = 1$$

X轴截距      Y轴截距



规格严格 功夫到家

## 直线法线式

$$x \cos \theta + y \sin \theta = \rho$$

What are rho and theta?

规格严格 功夫到家

## 直线法线式


$$x \cos \theta + y \sin \theta = \rho$$

推导:

$$\begin{aligned} \cos \theta = \frac{\rho}{a} &\rightarrow a = \frac{\rho}{\cos \theta} \\ \sin \theta = \frac{\rho}{b} &\rightarrow b = \frac{\rho}{\sin \theta} \end{aligned}$$

插入:  $\frac{x}{a} + \frac{y}{b} = 1$

$$x \cos \theta + y \sin \theta = \rho$$



规格严格 功夫到家

## 霍夫变换

### Hough transformation

规格严格 功夫到家

## 霍夫变换

- 霍夫变换将直线等几何形状建模为 **参数化形式** (例如, 直线用极坐标参数  $\rho$  和  $\theta$  表示), 并提供一种通用方法进行检测。
- 优势: 即使图像中的边缘点不连续 (例如, 因噪声或断裂导致), 也能通过投票机制检测出完整直线。
- 优势: 能处理部分被遮挡的直线 (例如, 物体遮挡导致直线段缺失), 因为投票过程依赖全局边缘信息, 而非局部连续性。
- 核心: 每个边缘点在参数空间中对所有可能的直线模型进行 **“投票”**, 投票累积的峰值位置即对应实际检测到的直线。


规格严格 功夫到家



## 图像和参数空间

$$y = mx + b$$

变量  $y$  和  $x$  是变量， $m$  和  $b$  是参数。




图像空间

规格严格 功夫到家

## 图像和参数空间

$$y = mx + b$$

变量  $y$  和  $x$  是变量， $m$  和  $b$  是参数。




图像空间

一条线  
变成了  
一个点

$$y - mx = b$$

变量  $b$  是变量， $m$  是参数。



参数空间

规格严格 功夫到家

## 图像和参数空间

$$y = mx + b$$

变量  $y$  和  $x$  是变量， $m$  和  $b$  是参数。




Image space

图像空间中的一个点在参数空间中会变成什么?

规格严格 功夫到家

## 图像和参数空间

$$y = mx + b$$

变量  $y$  和  $x$  是变量， $m$  和  $b$  是参数。





Image space

一个点  
变成了一  
条线

$$y - mx = b$$

变量  $b$  是变量， $m$  是参数。



Parameter space

规格严格 功夫到家

## 图像和参数空间

$$y = mx + b$$

变量  $y$  和  $x$  是变量， $m$  和  $b$  是参数。





Image space

$$y - mx = b$$

变量  $b$  是变量， $m$  是参数。



Parameter space

规格严格 功夫到家

## 图像和参数空间

$$y = mx + b$$

变量  $y$  和  $x$  是变量， $m$  和  $b$  是参数。





Image space

一个点  
变成了一  
条线

$$y - mx = b$$


变量  $b$  是变量， $m$  是参数。




Parameter space

规格严格 功夫到家


图像和参数空间




图像和参数空间




图像和参数空间



图像和参数空间




如何找到最佳拟合直线?




基于霍夫变换的直线检测

1. 量化参数空间  $(m, c)$   
将直线参数 (斜率  $m$  和  $y$  截距  $c$ ) 的连续空间离散化为有限的网格单元。
2. 创建累加器数组  $A(m, c)$   
初始化一个二维数组  $A$ , 其维度对应量化后的  $m$  和  $c$  参数范围, 用于统计投票结果。
3. 初始化累加器: 对所有  $m, c$ , 设  $A(m, c) = 0$   
将累加器数组中所有元素的值重置为 0, 准备接收投票。
4. 遍历图像边缘点并投票
  - 对每个图像边缘点  $(x, y)$ :
    - 对累加器数组中的每个参数对  $(m, c)$ :
      - 若点  $(x, y)$  位于由  $(m, c)$  定义的直线上 (即满足直线方程  $c = y - m \cdot x$ ), 则将累加器值增加 1:  $A(m, c) \leftarrow A(m, c) + 1$ 。
5. 检测局部最大值  
在累加器数组  $A(m, c)$  中寻找局部峰值点 (即投票数显著高于邻域的  $(m, c)$  组合), 这些峰值对应图像中检测到的直线。




## 参数化的问题

 $(m, c)$  参数化需要多大的累加器？

规格严格 功夫到家

## 参数化的问题

 $(m, c)$  参数化需要多大的累加器？ $m$  的空间是巨大的！

$$-\infty \leq m \leq \infty$$


 $c$  的空间是巨大的！

$$-\infty \leq c \leq \infty$$

规格严格 功夫到家

## 更好的参数化方法

规格严格 功夫到家



- 经过变换，图像空间中的每个点  $(x, y)$  就被映射为一个  $(r, \theta)$  极坐标空间中的正弦曲线。
- 而图像空间中共线的点所对应的  $(r, \theta)$  空间中正弦曲线相交于一点  $(r', \theta')$ 。

规格严格 功夫到家

## 更好的参数化方法

使用直线法线式：

$$x \cos \theta + y \sin \theta = \rho$$


给定点  $(x_i, y_i)$  寻找  $(\rho, \theta)$ 

霍夫空间正弦波

$$0 \leq \theta \leq 2\pi$$

$$0 \leq \rho \leq \rho_{\max}$$

(有限累加器数组大小)




规格严格 功夫到家

## 图像和参数空间


$$x \cos \theta + y \sin \theta = \rho$$

variables:  $x, y$   
parameters:  $\theta, \rho$

一个点  
变成什么？


$$x \cos \theta + y \sin \theta = \rho$$

parameters:  $\theta, \rho$   
variables:  $x, y$




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间



规格严格 功夫到家


## 图像和参数空间



规格严格 功夫到家


| 角度 (°) | 弧度 (rad)         | cos θ                 | sin θ                |
|--------|------------------|-----------------------|----------------------|
| 0      | 0                | 1                     | 0                    |
| 45     | $\frac{\pi}{4}$  | $\frac{\sqrt{2}}{2}$  | $\frac{\sqrt{2}}{2}$ |
| 90     | $\frac{\pi}{2}$  | 0                     | 1                    |
| 135    | $\frac{3\pi}{4}$ | $-\frac{\sqrt{2}}{2}$ | $\frac{\sqrt{2}}{2}$ |
| 180    | $\pi$            | -1                    | 0                    |

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间




规格严格 功夫到家

## 图像和参数空间



规格严格 功夫到家

## 图像和参数空间



规格严格 功夫到家

## 基于霍夫变换的直线检测

### 1. 初始化累加器

将累加器数组  $H$  的所有元素置为 0 (即  $H(\theta, \rho) = 0$ , 其中  $\theta$  和  $\rho$  是离散化参数)。

### 2. 遍历图像边缘点并投票

对于图像中的每个边缘点  $(x, y)$ :

- 对于角度  $\theta$  从  $0^\circ$  到  $180^\circ$  (通常以  $1^\circ$  为步长遍历):
    - 计算参数  $\rho = x \cos \theta + y \sin \theta$ 。
    - 在累加器中对应位置投票:  $H(\theta, \rho) = H(\theta, \rho) + 1$ 。
- (注: 此步骤通过参数空间  $(\theta, \rho)$  累计共线边缘点的投票数)

### 3. 检测局部最大值

在累加器  $H$  中, 找出所有满足  $H(\theta, \rho)$  为局部最大值的点  $(\theta, \rho)$ 。




(注: 局部最大值点对应图像中潜在的直线)

### 4. 输出检测到的直线

每个局部最大值点  $(\theta, \rho)$  定义一条检测到的直线, 其方程为:

$$\rho = x \cos \theta + y \sin \theta$$

(注: 该方程即直线法线式, 直接描述图像中直线的几何位置)




规格严格 功夫到家



规格严格 功夫到家


## 更复杂图像



规格严格 功夫到家




实际上，测量是带噪声的




规格严格 功夫到家

真实世界的例子



规格严格 功夫到家



规格严格 功夫到家

霍夫圆检测

规格严格 功夫到家

假设半径已知

$$(x-a)^2 + (y-b)^2 = r^2$$
  
parameters:  $a, b$ ; variables:  $x, y$

$$(x-a)^2 + (y-b)^2 = r^2$$
  
parameter:  $a$ ; variables:  $x, y, b$

参数空间的维数是多少?

规格严格 功夫到家

$$(x-a)^2 + (y-b)^2 = r^2$$
  
parameters:  $a, b$ ; variables:  $x, y$

$$(x-a)^2 + (y-b)^2 = r^2$$
  
parameters:  $a, b$ ; variables:  $x, y$

$(x, y)$

Image space

Parameter space

图像空间中的一个点在参数空间中对应于什么?

规格严格 功夫到家



哈尔滨工业大学  
HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合数据

5.2 RANSAC

5.3 匹配数据拟合

5.3 霍夫变换

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables



规格严格 功夫到家



哈尔滨工业大学  
HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合数据

5.2 RANSAC

5.3 匹配数据拟合

5.3 霍夫变换

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables



规格严格 功夫到家



哈尔滨工业大学  
HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合数据

5.2 RANSAC

5.3 匹配数据拟合

5.3 霍夫变换

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables



规格严格 功夫到家



哈尔滨工业大学  
HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合数据

5.2 RANSAC

5.3 匹配数据拟合

5.3 霍夫变换

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables



规格严格 功夫到家



哈尔滨工业大学  
HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合数据

5.2 RANSAC

5.3 匹配数据拟合

5.3 霍夫变换

半径固定

$$(x-a)^2 + (y-b)^2 = r^2$$


parameters

variables

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables



规格严格 功夫到家



哈尔滨工业大学  
HARBIN INSTITUTE OF TECHNOLOGY

5.1 拟合数据

5.2 RANSAC

5.3 匹配数据拟合

5.3 霍夫变换

如果半径未知？

$$(x-a)^2 + (y-b)^2 = r^2$$


parameters

variables

$$(x-a)^2 + (y-b)^2 = r^2$$

parameters

variables



规格严格 功夫到家


如果半径未知：3D 霍夫空间！  
使用累加器数组  $A(a,b,r)$   
霍夫空间中的曲面形状复杂

## 如果半径未知？

如果半径未知：3D 霍夫空间！

使用累加器数组  $A(a, b, r)$ 

霍夫空间中的曲面形状很复杂



规格严格 功夫到家

## 如果半径未知？

## 1. 参数空间维度灾难


- 圆的方程  $(x-a)^2 + (y-b)^2 = r^2$  包含 3 个自由参数（圆心  $a, b$  和半径  $r$ ），需在三维参数空间  $(a, b, r)$  中构建累加器。
- 每个边缘点  $(x, y)$  会对应参数空间中一个圆锥面轨迹（所有可能的  $(a, b, r)$  组合），需对每个点遍历所有半径和圆心位置进行投票。
- 计算量随图像分辨率和半径范围指数级增长，例如  $500 \times 500$  图像搜索  $r \in [1, 100]$  时，累加器规模可达  $500 \times 500 \times 90 = 2.25 \times 10^7$ ，效率极低。

## 2. 噪声敏感性与误检风险

- 三维累加器中噪声点也会参与无效投票，导致虚假峰值（误检圆）。
- 非极大值抑制（NMS）在三维空间难以精准区分相邻圆心，尤其对密集或部分遮挡的圆形目标鲁棒性差。

规格严格 功夫到家

## 霍夫梯度法检测圆形



(1) 首先对图像应用边缘检测。


(2) 使用 sobel 算子计算所有像素的梯度

(3) 遍历边缘检测之后的所有非 0 的像素点，沿着梯度方向画线，每个点有一个累加器，有一条线经过该点，累加器加 1，对所有累加器进行排序，根据阈值找到所有可能的圆心

(4) 计算边缘图像中所有的非 0 像素点距离圆心的距离，距离从小到大排序，选取合适的半径

规格严格 功夫到家

## Example



规格严格 功夫到家