



哈爾濱工業大學
HARBIN INSTITUTE OF TECHNOLOGY

6. 计算机视觉中的深度学习

张宏志

机器学习研究中心，计算学部
2026 春

zhanghz@hit.edu.cn 390684271@qq.com



本章内容

- 深度学习基础
 - 深度学习基本介绍
 - 人工神经网络基础
 - 经典网络结构
- 视觉神经网络与典型训练范式
 - 视觉Transformer
 - 神经网络的典型训练范式
 - 典型深度学习框架

规格严格 功夫到家

本节内容

- 深度学习基础
 - 深度学习基本介绍
 - 人工神经网络基础
 - 经典网络结构
- 视觉神经网络与典型训练范式
 - 视觉Transformer
 - 神经网络的典型训练范式
 - 典型深度学习框架

规格严格 功夫到家

本节内容 – 深度学习基础

- 深度学习基本介绍
- 人工神经网络基础
- 经典网络结构

规格严格 功夫到家

深度学习与人工智能的关系

人工智能 (Artificial Intelligence)

人工智能是通过计算机程序或机器来模拟、实现人类智能的技术和方法。

机器学习 (Machine Learning)

机器学习是在无需明确编程的情况下赋予计算机学习能力的研究领域。

深度学习 (Deep Learning)


神经网络的发展阶段 (感知机 → 多层感知机 → 深度学习)

通过深度神经网络学习数据的分布和规律，通常由较多的网络层（如卷积、全连接、激活层等）组成，因其高度非线性的结构设计而具有较强的拟合能力。


规格严格 功夫到家

机器学习内涵

➤ 传统编程范式 (计算思维)



➤ 机器学习范式 (智能思维)



规格严格 功夫到家

机器学习要素



- 模型：输入 $\rightarrow$ 输出 $\mathcal{F} = \{f(\mathbf{x}; \theta) | \theta \in \mathbb{R}^D\}$
- 学习准则 (以监督学习为例)
 - 训练数据集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$
 - 回归问题 $\mathcal{L}(y, f(\mathbf{x}; \theta)) = \frac{1}{2}(y - f(\mathbf{x}; \theta))^2$
 - 分类问题 $\mathcal{L}(y, f(\mathbf{x}; \theta)) = -\mathbf{y}^T \log f(\mathbf{x}; \theta)$

$$= -\sum_{c=1}^C y_c \log f_c(\mathbf{x}; \theta)$$
- 优化算法：SGD、AdaGrad、RMSProp、Adam、...

规格严格 功夫到家


线性回归与线性分类

- 线性： $y = kx + b$




规格严格 功夫到家

机器学习任务示例 - 分类问题



第一类




第二类




这是哪一类

规格严格 功夫到家


机器学习任务示例 - 分类问题



第一类




第二类




这是哪一类

规格严格 功夫到家


机器学习任务示例 - 分类问题



第一类




第二类




这是哪一类

规格严格 功夫到家


机器学习任务示例 - 分类问题



第一类




第二类



这是哪一类

规格严格 功夫到家

机器学习任务示例 - 分类问题



规格严格 功夫到家

什么是分类?

➤ 分类

➤ 分类是机器学习的一种形式，通过训练模型来预测某个项属于哪个类别。

- 例如，健康诊所可能会使用患者的身高、体重、血压和血糖水平等诊断数据来预测该患者是否患有糖尿病。

➤ 分类数据具有类别标签，而不是数值。某些类型的数据可以是数值的，也可以是类别标签。

- 例如，比赛时间可以是以秒为单位的数字时间，也可以是分类的类（快、中等或慢）。其他类型的数据只能是分类的，例如一种形状 - “圆形”、“三角形”或“方形”。

规格严格 功夫到家

贝叶斯公式

似然（类条件概率）：
给定特定类别，观察到数
据的倾向性（分布）

先验：在看到数据之
前，我们对标签分布
的认知

$$P(w_i|x) = \frac{P(x|w_i)P(w_i)}{P(x)}$$

后验：观察到数据后，
对标签分布的认知

数据分布：在特定问
题中通常固定，因此
一般问题中忽略该项

规格严格 功夫到家

贝叶斯决策 —— 最小错误率判别

➤ 最小错误率判别

➤ 观察到特征 x 时作出判别的**错误率**：

$$P(error|x) = \begin{cases} P(\omega_1|x), & \text{判定 } \omega_2 \\ P(\omega_2|x), & \text{判定 } \omega_1 \end{cases}$$

➤ 两类问题**最小错误率判别准则**：

$$\begin{cases} \text{如果 } P(\omega_1|x) > P(\omega_2|x), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|x) < P(\omega_2|x), & \mathbf{x} \in \omega_2 \end{cases}$$

规格严格 功夫到家

贝叶斯决策 —— 最小错误率判别

➤ 举例

对一大批人进行癌症普查，设 w_1 代表患癌症， w_2 代表正常人。

已知先验概率：

$$P(w_1) = 0.005, P(w_2) = 0.995$$

以一个化验结果作为特征 x : {阳性, 阴性}, 患癌症的人和正常人化验结果为阳性的概率分别为：

$$P(x = \text{阳性} | w_1) = 0.95, P(x = \text{阳性} | w_2) = 0.01$$

现有一人化验结果为阳性，问此人是否患癌症？

$$P(w_1 | x = \text{阳性}) = P(x = \text{阳性} | w_1)P(w_1) = 0.95 \times 0.005 = 0.00475$$

$$P(w_2 | x = \text{阳性}) = P(x = \text{阳性} | w_2)P(w_2) = 0.01 \times 0.995 = 0.00995$$

➤ 忽略分母项 ($P(x)$ 相同)，在最小错误率判别中比较大小时不会影响结论

规格严格 功夫到家

贝叶斯决策 —— 最小平均风险判别

➤ 最小平均风险判别

➤ 有 c 个类别 $w_1, w_2, \dots, w_c$ ，将 w_i 类的样本判别为 w_j 类的**代价 (Cost)**为 λ_{ij} 。

➤ 则将未知模式 x 判别为 w_j 类的**平均风险**为：

$$\gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(w_i | \mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\mathbf{x} | w_i) P(w_i)$$

➤ 判别准则： $i = \arg \min_{1 \leq j \leq c} \gamma_j(\mathbf{x})$ ，则 $\mathbf{x} \in w_i$

规格严格 功夫到家

贝叶斯决策 —— 最小平均风险判别

➤ 举例

➤ 对一大批人进行癌症普查，设 w_1 代表患癌症， w_2 代表正常人。已知先验概率：

$$P(w_1) = 0.005, P(w_2) = 0.995$$

➤

以一个化验结果作为特征 x : {阳性, 阴性}, 患癌症的人和正常人化验结果为阳性的概率分别为：

$$P(x=\text{阳性}|w_1) = 0.95, P(x=\text{阳性}|w_2) = 0.01$$

实际是患癌
判断为患癌

$\lambda_{11} = 0, \lambda_{22} = 0, \lambda_{12} = 10$,
患癌症?

实际是正常
判断为患癌

有一人化验结果为阳性，问

$$\gamma_1 = \lambda_{11}P_{11} + \lambda_{21}P_{21} = 0 \times P(w_1|x=\text{阳性}) + 1 \times P(w_2|x=\text{阳性}) = 1 \times P(x=\text{阳性}|w_2)P(w_2) = 1 \times 0.01 \times 0.995 = 0.00995$$

$$\gamma_2 = \lambda_{22}P_{22} + \lambda_{12}P_{12} = 0 \times P(w_2|x=\text{阳性}) + 10 \times P(w_1|x=\text{阳性}) = 10 \times P(x=\text{阳性}|w_1)P(w_1) = 10 \times 0.95 \times 0.005 = 0.0475$$

实际是正常
判断为正常

实际是患癌
判断为正常

规格严格 功夫到家

最大似然估计与最大后验估计

➤ 优化目标

➤ 贝叶斯公式

$$P(w_i|x) = \frac{P(x|w_i)P(w_i)}{P(x)}$$

➤ 最（极）大似然估计（Maximum Likelihood Estimation）

$$\arg \max_w P(x|w)$$

➤ 最大后验估计（Maximum A Posterior Estimation）

$$\arg \max_w P(w|x) = \arg \max_w p(x|w)p(w)$$

规格严格 功夫到家

什么是回归？

➤ 回归

- 回归是一种简单、通用且非常有用的数据分析技术，俗称为“**拟合趋势线**”。回归标识一个或多个特征与单个标签之间的关系的强度。它的简单性、可预测的行为、预测能力和高级别的可解释性意味着此技术可用于财务、商务、社会科学、流行病学和医学等领域。
- 最简单的形式是回归在一个变量（特征）和另一个变量（标签）之间拟合一条直线。在更复杂的形式中，回归可以找到单个标签与多个特征之间的非线性关系。

规格严格 功夫到家

什么是回归？

➤ 回归方法目标

➤ 线性回归

$$y = b_0 + b_1x_1$$

➤ 多元线性回归

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$

➤ 多项式回归

$$y = b_0 + b_1x_1 + b_2x_1^2 + \dots + b_nx_1^n$$

➤ 其他回归


- 逻辑回归（Logistics Regression）、逐步回归（Stepwise Regression）、岭回归（Ridge Regression）、套索回归（Lasso Regression）、弹性回归（Elastic Regression）

规格严格 功夫到家

线性回归

- 优化目标 (期望得到一条直线 $y = w_0x + w_1$)

$$\min_w \|Xw - y\|_2^2, \text{ where } X = [x, 1], w = [w_0, w_1]^T$$



规格严格 功夫到家


多项式回归

- 多维泰勒公式

- 由泰勒公式可知，多项式可以拟合任何函数


$$f(X) = f(P) + \sum_{i=1}^m (X_i - P_i) f'_i(X) + \frac{1}{2!} \sum_{i,j=1}^m (X_i - P_i)(X_j - P_j) f''_{ij}(X) + O(X^2)$$

$$f(X) = b + \sum w_i^{(1)} X_i + \sum w_{i,j}^{(2)} X_i X_j + \sum w_{i,j,k}^{(3)} X_i X_j X_k + \dots$$



规格严格 功夫到家

欠拟合 vs 过拟合



规格严格 功夫到家

正则化

► 优化目标

- 岭回归 (Ridge Regression) 添加了 ℓ_2 正则化项

$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_2^2$$

- 套索回归 (Lasso Regression) 添加了 ℓ_1 正则化项


$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_1$$

- 弹性回归 (ElasticNet Regression) 同时添加了 ℓ_1/ℓ_2 正则化项

$$\min_w \|Xw - y\|_2^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$

规格严格 功夫到家

分类与回归的统一：学习一个函数映射



逻辑回归（二分类问题）

规格严格 功夫到家

机器学习要素

- 模型：输入 $\rightarrow$ 输出 $\mathcal{F} = \{f(\mathbf{x}; \theta) | \theta \in \mathbb{R}^D\}$
- 学习准则（以监督学习为例）
 - 训练数据集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$
 - 回归问题 $\mathcal{L}(y, f(\mathbf{x}; \theta)) = \frac{1}{2} (y - f(\mathbf{x}; \theta))^2$
 - 分类问题 $\mathcal{L}(y, f(\mathbf{x}; \theta)) = -\mathbf{y}^\top \log f(\mathbf{x}; \theta)$

$$= -\sum_{c=1}^C y_c \log f_c(\mathbf{x}; \theta)$$
- 优化算法：SGD、AdaGrad、RMSProp、Adam、...

规格严格 功夫到家

本节内容 – 深度学习基础

- 深度学习基本介绍
- 人工神经网络基础
- 经典卷积神经网络结构


規格嚴格 功夫到家

神经网络发展的三个阶段

- 一、感知器
 - McCulloch & Pitts / Hebb / Rosenblatt
 - Minski
- 二、多层感知器感知器
 - Hinton / LeCun
 - Minski
- 三、深度学习 (Hinton、LeCun、Bengio)

規格嚴格 功夫到家


人脑：神经元及其连接





规格严格 功夫到家

神经网络、感知器、人工神经网络

➤ 神经元、突触





➤ 神经网络



规格严格 功夫到家

人工神经网络

- 出发点
 - 模拟人类智能
- 建模方法
 - 神经元-突触
 - 网络结构、函数形式
 - 模型参数？
- 学习方法
 - 参数学习（BP，反向传播）
 - 结构学习（NAS，网络结构搜索）



约·冯·诺依曼，《**计算机与人脑**》，商务出版社（1958, 1965, 2011）

规格严格 功夫到家

实际场景：面试评分



规格严格 功夫到家

实际场景：面试评分


$$0.6 + 0.3 + 0.4 = 1.3$$



規格嚴格 功夫到家

实际场景：面试评分


$$1 * 0.6 + 1 * 0.3 + 1 * 0.4 = 1.3$$



規格嚴格 功夫到家



实际场景：面试评分

$$0.5 \times 0.6 + 2 \times 0.3 + 0.5 \times 0.4 = 1.1$$



规格严格 功夫到家



标准感知器结构



规格严格 功夫到家

感知器算法: 历史


- 1957年, Rosenblatt提出感知器算法
- 1969年, Minsky和Papert出版《Perceptrons》一书, 分析感知器的能力和局限性 (XOR问题)



規格嚴格 功夫到家

感知器的局限性


- 手工提取的特征
 - 对性能有显著的影响
 - 需要巨大的代价寻找合适的特征
- 线性分类器
 - 无法区分非线性数据, 例如异或问题



正例和负例无法通过
线性分类器区分开

規格嚴格 功夫到家


多层感知器




D. E. Rumelhart, G. E. Hinton & R. J. Williams, **Learning representations by back-propagating errors**, *Nature* 323, 533 - 536 (09 October 1986)

规格严格 功夫到家

解决异或问题的多层感知器




$$f(x; W, c, w, b) = w^\top \max\{0, W^\top x + c\} + b.$$



x_1, x_2	h_1, h_2	h_1^+, h_2^+
0, 0	0, -1	0, 0
0, 1	1, 0	1, 0
1, 0	1, -1	1, 0
1, 1	2, 1	2, 1

规格严格 功夫到家

激活函数




$$y = f(\mathbf{w}^T \mathbf{x}) = f\left(\sum_{i=1}^d w_i x_i\right), \quad f \text{ 称为激活函数}$$

ReLU $\max(0, x)$	GELU $\frac{x}{2} \left(1 + \tanh\left(\sqrt{\frac{2}{\pi}}(x + ax^3)\right)\right)$	PRelu $\max(0, x)$
ELU $\begin{cases} x & \text{if } x > 0 \\ \alpha(x \exp x - 1) & \text{if } x < 0 \end{cases}$	Swish $\frac{x}{1 + \exp(-x)}$	SELU $\alpha(\max(0, x) + \min(0, \beta(\exp x - 1)))$
SoftPlus $\frac{1}{\beta} \log(1 + \exp(\beta x))$	Mish $x \tanh\left(\frac{1}{\beta} \log(1 + \exp(\beta x))\right)$	RRelu $\begin{cases} x & \text{if } x \geq 0 \\ ax & \text{if } x < 0 \text{ with } a \sim \mathcal{R}(l, u) \end{cases}$
HardSwish $\begin{cases} 0 & \text{if } x \leq -3 \\ x & \text{if } x \geq 3 \\ x(x+3)/6 & \text{otherwise} \end{cases}$	Sigmoid $\frac{1}{1 + \exp(-x)}$	SoftSign $\frac{x}{1 + x }$
Tanh $\tanh(x)$	Hard tanh $\begin{cases} a & \text{if } x \geq a \\ b & \text{if } x \leq b \\ x & \text{otherwise} \end{cases}$	Hard Sigmoid $\begin{cases} 0 & \text{if } x \leq -3 \\ 1 & \text{if } x \geq 3 \\ x/6 + 1/2 & \text{otherwise} \end{cases}$
Tanh Shrink $x - \tanh(x)$	Soft Shrink $\begin{cases} x - \lambda & \text{if } x > \lambda \\ x + \lambda & \text{if } x < -\lambda \\ 0 & \text{otherwise} \end{cases}$	Hard Shrink $\begin{cases} x & \text{if } x > \lambda \\ x & \text{if } x < -\lambda \\ 0 & \text{otherwise} \end{cases}$

规格严格 功夫到家

ReLU (Rectified Linear Units)



$$\sum_{i=1}^N \sigma(x - i + 0.5) \approx \log(1 + e^x)$$



Vinod Nair, Geoffrey E. Hinton, **Rectified Linear Units Improve Restricted Boltzmann Machines**, **ICML** 2010.

规格严格 功夫到家

ReLU (Rectified Linear Units)




A Krizhevsky, I Sutskever, GE Hinton, Imagenet classification with **deep convolutional neural networks**, **NIPS** 2012

規格嚴格 功夫到家

ReLU变体

➤ Leaky ReLU & PReLU




K He, X Zhang, S Ren, J Sun, **Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification**, **ICCV** 2015


規格嚴格 功夫到家

ReLU变体

➤ ELU: Exponential Linear Units



• GELU



D.-A. Clevert, T. Unterthiner, S. Hochreiter, **Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)**, **ICLR 2016**


規格嚴格 功夫到家

感知器的限制

- 稀疏交互 sparse interactions
- 参数共享 parameter sharing
- 等变表示 equivariant representation
- 不变表示 invariant representation

規格嚴格 功夫到家

稀疏交互 (稀疏连接)




卷积
(一维)

感知器
(全连接)


规格严格 功夫到家

感受野 (Receptive Field)

➤ 层1:




➤ 层2:



规格严格 功夫到家

参数共享



规格严格 功夫到家

等变表示 (Equivariant Representation)

- 如果一个函数满足输入改变，输出也以同样方式进行改变的话，我们称它是等变的
- 卷积：平移等变
- 不变表示 (Transform-invariant)


规格严格 功夫到家

等变与不变表示 (Equivariant/Invariant)




Invariance

$$f(\rho_g(x)) = f(x)$$



Equivariance

$$f(\rho_g(x)) = \rho'_g(f(x))$$





规格严格 功夫到家

卷积：参数共享、稀疏连接与平移等变

➤ 二维卷积


$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n)$$



规格严格 功夫到家

池化：形变不敏感


➤ 作用：增大感受野、形变不敏感



規格嚴格 功夫到家

(对比度)归一化：光照不敏感


- 每个channel或所有channel归一化
- 池化前或池化后归一化



- 常用其他 Normalization (如Batch Norm/Layer Norm等) 方法

規格嚴格 功夫到家

卷积神经网络示例：LeNet5 (1998)



规格严格 功夫到家

一般求解方法 — 梯度下降法

➤ 求解不等式组采用的最优化方法：

1. 定义一个**准则函数** $J(\mathbf{w})$ ，当 $\mathbf{w}$ 是解向量时， $J(\mathbf{w})$ 为最小；
2. 采用最优化方法求解标量函数 $J(\mathbf{w})$ 的极小值。

➤ 最优化方法采用最多的是**梯度下降法**，设定初始权值向量 $\mathbf{w}(1)$ ，然后沿梯度的负方向迭代计算


$$\mathbf{w}(k+1) = \mathbf{w}(k) - \eta(k) \nabla J(\mathbf{w}(k))$$

其中 $\eta(k)$ 称为**学习率**，或称**步长**。

规格严格 功夫到家


一般求解方法 — 梯度下降法

Minimum of a function is found by following the slope of the function




規格嚴格 功夫到家

一般求解方法 — 梯度下降法




規格嚴格 功夫到家

一般求解方法 — 梯度下降法




規格嚴格 功夫到家

一般求解方法 — 梯度下降法



規格嚴格 功夫到家


一般求解方法 — 梯度下降法



規格嚴格 功夫到家

一般求解方法 — 梯度下降法

➤ 问题1: 步长 (学习率) 的确定




規格嚴格 功夫到家

一般求解方法 — 梯度下降法

➤ 问题1：步长（学习率）的确定

- 设置较小的初始学习率
- 随着训练逐渐增大
- 直到性能基本稳定，则该学习率是较为合适的初始学习率




Smith L.N. Cyclical learning rates for training neural networks[C]//2017 IEEE Winter Conference on Applications of Computer Vision (WACV). IEEE, 2017: 464-472.

规格严格 功夫到家

一般求解方法 — 梯度下降法

➤ 问题2：震荡效应



规格严格 功夫到家

一般求解方法 — 梯度下降法

➤ Solver/Optimizer (部分列举)

➤ SGD: 经历了BGD→SGD→MSGD, $g_t = \nabla_{\theta_{t-1}} f(\theta_{t-1})$, $\Delta\theta_t = -\eta * g_t$

➤ Momentum (Nesterov): $m_t = \mu * m_{t-1} + g_t$, $\Delta\theta_t = -\eta * m_t = -\eta * \mu * m_{t-1} - \eta * g_t$

➤ Adagrad (Adadelta, RMSprop): $n_t = n_{t-1} + g_t^2$, $\Delta\theta_t = -\frac{\eta}{\sqrt{n_t + \epsilon}} * g_t$



➤ Adam (Nadam, Adamax):

$$m_t = \mu * m_{t-1} + (1 - \mu) * g_t, n_t = v * n_{t-1} + (1 - v) * g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \mu^t}, \hat{n}_t = \frac{n_t}{1 - v^t}, \Delta\theta_t = -\eta * \frac{\hat{m}_t}{\sqrt{\hat{n}_t + \epsilon}}$$

规格严格 功夫到家

一般求解方法 — 梯度下降法



规格严格 功夫到家

一般求解方法 — 梯度下降法

➤ 问题3：停止策略

➤ 一维形式

$$|f'(x)| \leq \varepsilon$$

➤ 高维形式

$$\|\nabla f\| \leq \varepsilon$$

- 实践中较少直接使用一定的停止策略，而是采用**足够大的迭代**，使**损失函数（优化目标）足够小**，然后根据验证集的性能选用合适的参数

规格严格 功夫到家

本节内容 — 深度学习基础

➤ 深度学习基本介绍

➤ 人工神经网络基础

➤ 经典卷积神经网络结构


规格严格 功夫到家

代表性卷积神经网络

- AlexNet (Krizhevsky et al. NIPS 2012)
- ZeilerNet (Zeiler & Fergus, ECCV 2014)
- VGGNet (Simonyan & Zisserman, ICLR 2015)
- GoogLeNet (Szegedy et al., CVPR 2015)
- U-Net (MICCAI, 2015)
- Deep Residual Network (He et al., CVPR 2016)
- DenseNet (CVPR 2017)
- SENet (CVPR 2018)

規格嚴格 功夫到家

AlexNet (2012)




- Five convolutional and three fully-connected layers
- 60 million parameters
- +ReLU+Dropout
- Group Conv

規格嚴格 功夫到家

ZeilerNet (2014)

➤ 改进

- 首层卷积核由11x11降至7x7
- 卷积步长由4降维2



规格严格 功夫到家

VGGNet (2015)

➤ VGG16 & VGG19

- 更小的感受野: 3×3
- 更多层
- 步长为2的最大池化

➤ +ReLU+Dropout

Table 2: Number of parameters (in millions).


Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64	conv3-64	conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128	conv3-128	conv3-128
maxpool					
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256
conv3-256	conv3-256	conv3-256	conv3-256 conv1-256	conv3-256 conv3-256	conv3-256
maxpool					
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512 conv1-512	conv3-512 conv3-512	conv3-512
maxpool					
conv3-512	conv3-512	conv3-512	conv3-512 conv1-512	conv3-512 conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512 conv1-512	conv3-512 conv3-512	conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

规格严格 功夫到家

GoogLeNet (2015)


➤ Inception: Basic structure



- (Arora et al., Arxiv 2013): Layer-by layer construction to analyze the correlation statistics of the last layer and **cluster them into groups of units with high correlation**.

规格严格 功夫到家


GoogLeNet (2015)



规格严格 功夫到家

U-Net (2015)

➤ 跳跃连接 (细节保留)




规格严格 功夫到家

ResNet (2016)

➤ 网络退化问题 (非过拟合)

➤ 如何在提升网络深度的同时不对网络能力造成退化



Training error (left) and test error (right) on CIFAR-10

规格严格 功夫到家

ResNet (2016)

➤ 想要学习的映射


$$\mathcal{H}(\mathbf{x})$$

➤ 残差映射

$$\mathcal{F}(\mathbf{x}) := \mathcal{H}(\mathbf{x}) - \mathbf{x}$$

➤ 残差学习

$$\mathcal{F}(\mathbf{x}) + \mathbf{x}$$



Residual learning: a building block.

规格严格 功夫到家


ResNet (2016)

➤ 网络结构

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
		3×3 max pool, stride 2				
conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

规格严格 功夫到家



DenseNet (2017)



規格嚴格 功夫到家

空域注意力模型


$$\alpha = \text{softmax}(\mathbf{W}_i \mathbf{a} + b_i)$$



規格嚴格 功夫到家


通道注意力模型 (SENet, 2018)

➤ Squeeze-and-Excitation Networks (最后一年ImageNet竞赛冠军)



规格严格 功夫到家


与主流网络的结合



规格严格 功夫到家

Summary

- 掌握近年来的主流网络结构
- 结合实际问题和任务灵活使用
- 持续了解和跟进研究进展
- 自己能有一些思考、拓展和突破
- 深度学习的可解释性 (可信赖、可靠、安全)



规格严格 功夫到家

下节内容

- 深度学习基础
 - 深度学习基本介绍
 - 人工神经网络基础
 - 经典网络结构
- 视觉神经网络与典型训练范式
 - 视觉Transformer
 - 神经网络的典型训练范式
 - 典型深度学习框架

规格严格 功夫到家

T h e E n d

THANKS FOR YOUR ATTENTION

規格嚴格 功夫到家