



哈爾濱工業大學

HARBIN INSTITUTE OF TECHNOLOGY

第五章 图像分割

哈尔滨工业大学机器学习研究中心

XXXX年X月X日




图像分割


Semantic Segmentation

Label each pixel in the image with a category label

Don't differentiate instances, only care about pixels



Instance Segmentation



语义分割

语义分割是对图像中的所有像素进行分类，为每个像素赋予相应的类别

实例分割

实例分割需要在语义分割的基础上识别同一类别中不同的物体

规格严格 功夫到家


图像分割



原始图片



图像分类



目标检测



语义分割



实例分割



全景分割



規格嚴格 功夫到家

图像分割的原则

- 将图像域 R 分成 n 个子区域 $R_1, R_2, \dots, R_n$, 满足
 - 完备性
 $\cup R_i = R, i = 1, \dots, n$
 - 互斥性
 $R_i \cap R_j = \emptyset, i \neq j$
 - 区域一致性
每个 R_i 内像素满足某种相似性原则（属于同一类别、同一实例）
 - （相邻）区域差异性
相邻区域不满足同一准则（属于不同类别、不同实例）

規格嚴格 功夫到家

如何进行分割？



規格嚴格 功夫到家

本章内容 - 图像分割

➤ 传统图像分割方法

- 基于边界的图像分割
- 基于区域的图像分割

➤ 基于深度学习的图像分割方法

- 语义分割
- 实例分割

規格嚴格 功夫到家

传统分割方法

➤ 阈值与边界

- 基于不连续性（边缘），寻找子区域/目标的划分阈值或边界
- 阈值法（Otsu大津法）、边缘检测

➤ 区域与聚类

- 基于相似性，直接对子区域进行聚类
- 区域生长、分水岭算法、K-means、均值偏移

規格嚴格 功夫到家

传统分割方法

➤ 阈值与边界

- 基于不连续性（边缘），寻找子区域/目标的划分阈值或边界
- 阈值法（Otsu大津法）、边缘检测

➤ 区域与聚类

- 基于相似性，直接对子区域进行聚类
- 区域生长、分水岭算法、K-means、均值偏移

規格嚴格 功夫到家

阈值法

```
cv2.threshold(img, 127, 255, cv2.THRESH_BINARY)
```

➤ 原理


- 通过像素值大小进行分割

➤ 优势

- 简单直观、计算量低、可解释性强

➤ 缺陷

- 需要手动设置阈值
- 忽略空间信息、对噪声与光照敏感、只适用于高对比度场景
- 无语义理解能力



规格严格 功夫到家

阈值法

```
cv2.threshold(img, 127, 255, cv2.THRESH_BINARY)
```

➤ 原理

- 通过像素值大小进行分割

➤ 优势

- 简单直观、计算量低、可解释性强

➤ 缺陷

- 需要手动设置阈值
- 忽略空间信息、对噪声与光照敏感、只适用于高对比度场景
- 无语义理解能力



规格严格 功夫到家

Otsu大津法

$$\begin{aligned} \operatorname{argmax}_T \sigma_B^2(T) &= \omega_0(\mu_0 - \mu_T)^2 + \omega_1(\mu_1 - \mu_T)^2 \\ &= \underbrace{\omega_0(T)}_{\text{背景占比}} \cdot \underbrace{\omega_1(T)}_{\text{前景占比}} \cdot \underbrace{[\mu_0(T) - \mu_1(T)]^2}_{\text{两类均值差}} \end{aligned}$$

➤ 原理

- 遍历所有可能的灰度值，寻找一个阈值 T ，使得按此阈值分割后，前景与背景两类的类间方差最大

➤ 优势

- 可自动获取阈值、数学基础严谨

➤ 缺陷

- 严重依赖直方图双峰假设
- 忽略空间信息，仅为一维统计决策
- 仅适用于二分类问题



规格严格 功夫到家

Otsu大津法

```
cv2.threshold(img, 0, 255, cv2.THRESH_BINARY + cv2.THRESH_OTSU)
```

➤ 原理


- 遍历所有可能的灰度值，寻找一个阈值 T ，使得按此阈值分割后，前景与背景两类的类间方差最大

➤ 优势

- 可自动获取阈值、数学基础严谨

➤ 缺陷

- 严重依赖直方图双峰假设
- 忽略空间信息，仅为一维统计决策
- 仅适用于二分类问题



规格严格 功夫到家

边缘检测法 (Canny)

```
edges = cv2.Canny(img, 100, 200)
```

➤ 优势

- 物理意义直观、计算高效
- 不依赖趋于一致性假设

➤ 缺陷

- 对噪声极度敏感
- 难以获得闭合边界
- 语义缺失（无法区分物体轮廓和纹理）



规格严格 功夫到家

传统分割方法

➤ 阈值与边界

- 基于不连续性（边缘），寻找子区域/目标的划分阈值或边界
- 阈值法（Otsu大津法）、边缘检测

➤ 区域与聚类

- 基于相似性，直接对子区域进行聚类
- 区域生长、分水岭算法、K-means、均值偏移

规格严格 功夫到家

区域生长法

```
regiongrowth_segmentation(img, num_seeds=1,
                           threshold=20, connectivity=8)
```

➤ 原理

- 从预设种子点出发，依据相似性准则（如灰度差），将邻域中满足条件的像素不断并入区域，直至队列为空。

➤ 优势

- 原理直观、结果连续、规则物体效果好

➤ 缺陷

- 严重依赖（人工）预定义种子点
- 对噪声敏感，易受模糊边界影响
- 生长结果受遍历顺序影响



规格严格 功夫到家

分水岭算法

➤ 原理

- 将图像视为地形，像素值视为海拔并模拟水位上升过程，低洼处形成盆地，不同盆地水汇合处筑堤即为分割边界。

➤ 优势

- 边界定位精准，连续闭合
- 全局性强，适合粘连物体分离

➤ 缺陷

- 过分割（产生海量无意义区域）
- 依赖预处理（平滑）、计算开销大



规格严格 功夫到家

K均值聚类

```
K = 100
cv2.kmeans(img, K, None, criteria, 10, cv2.KMEANS_RANDOM_CENTERS)
```

➤ 原理


- 随机初始化K个聚类中心 →
- 每个像素划归最近的聚类中心 →
- 重新计算各类的均值作为新中心 →
- 迭代至收敛（中心不再变化）

➤ 优势

- 简单高效、无需空间假设

➤ 缺陷

- 需要预设K值、对初始中心敏感
- 仅依赖颜色，忽略空间信息



规格严格 功夫到家

均值偏移法

```
cv2.pyrMeanShiftFiltering(img,
    spatial_radius,
    color_radius,
    max_level)
```

➤ 原理

- 每个像素点沿其邻域内数据点的密度梯度方向，不断迭代地“爬坡”到密度中心。收敛到同一个密度中心的像素被归为同一类，从而实现自动聚类。

➤ 优势

- 无需预设K值，对异型数据鲁棒

➤ 缺陷

- 计算复杂度高，高维数据易失效



规格严格 功夫到家

传统方法的共同缺陷

- 严重依赖人工设计，缺乏语义理解能力
- 对噪声和纹理极其敏感，鲁棒性差
- 缺乏全局理解与上下文建模能力
- 参数依赖度高，泛化能力弱
- 手工定义相似性度量，无法处理复杂模式


規格嚴格 功夫到家

本章内容 - 图像分割

- 传统图像分割方法
 - 基于边界的图像分割
 - 基于区域的图像分割
- 基于深度学习的图像分割方法
 - 语义分割
 - 实例分割

規格嚴格 功夫到家

深度学习三要素




规格严格 功夫到家

深度学习三要素 —— 算力

➤ 硬件


➤ CPU、GPU、TPU、NPU、FPGA.....



优势：灵活、内存廉价
劣势：速度慢




优势：性价比高、计算密集
劣势：显存受限、灵活性差



优势：转为AI计算设计
劣势：通用性稍差，一般人买不到

规格严格 功夫到家

深度学习三要素 —— 算力




Sevilla, J., Heim, L., Ho, A., Besiroglu, T., Hobbhahn, M., & Villalobos, P. (2022, July). Compute trends across three eras of machine learning. In *IJCNN* (pp. 1-8). IEEE.

规格严格 功夫到家

深度学习三要素 —— 算力

➤ 软件



规格严格 功夫到家

深度学习三要素 —— 数据



规格严格 功夫到家

深度学习三要素 —— 数据


	Wikipedia	Books	Journals	Reddit links	CC	Other	Total
GPT-1		4.6					4.6
GPT-2				40			40
GPT-3	11.4	21	101	50	570		753
The Pile v1	6	118	244	63	227	167	825
Megatron-11B	11.4	4.6		38	107		161
MT-NLG	6.4	118	77	63	983	127	1374
Gopher	12.5	2100	164.4		3450	4823	10550

各模型训练数据量

单位为GB，
粗体为公开数据，斜体为确定但不公开数据。

规格严格 功夫到家

深度学习三要素——算法



规格严格 功夫到家


常见数据集介绍 - MNIST

- 10 classes
- 60,000 training set
- 10,000 test set
- Task
 - Classification
 - Generation



常见数据集介绍 - Fashion-MNIST

- 10 classes
- 60k training set
- 10k test set
- Task
 - Classification
 - Generation



2026-5-27

規格嚴格 功夫到家

常见数据集介绍 - MS COCO

- COCO 2015 as e.g.
- 80 classes
- Over 200k images
- Task
 - Detection
 - Caption
 - Segmentation



The man at bat readies to swing at the pitch while the umpire looks on.



A large bus sitting next to a very tall building.

2026-5-27


規格嚴格 功夫到家

常见数据集介绍 - LSUN

- 10 scenes/20 objects
- ~1M images

➤ Task

- Classification
- Generation
- Saliency Prediction



2026-5-27

规格严格 功夫到家

常见数据集介绍 - ImageNet

- 1000 classes
- >14M images

➤ Task

- Classification
- Generation
- Detection
- ...
- Pre-training



2026-5-27


规格严格 功夫到家

常见数据集介绍 - Cifar

- 10/100 classes
- Cifar-10 as e.g.
 - 50k training images
 - 10k test images

- Task
 - Classification
 - Generation

airplane
automobile
bird
cat
deer
dog
frog
horse
ship
truck



2026-5-27

规格严格 功夫到家

常见数据集介绍 - Pascal VOC

- 20 classes
- >10k images

- Task
 - Classification
 - Detection
 - Segmentation

20 classes



Image

Objects

Class




2026-5-27

规格严格 功夫到家

常见数据集介绍 - Cityscapes

- 30 classes
- 5k pixel-level
- 20k weakly annotated
- Task
 - Segmentation
 - Generation




2026-5-27

规格严格 功夫到家

从网络结构出发

- 如何将分类网络改造为分割网络？



规格严格 功夫到家

从网络结构出发


➤ 全连接层与卷积层的相互转化

- 全连接层和卷积层之间唯一的不同就是卷积层中的神经元只与输入数据中的一个局部区域连接，并且在卷积列中的神经元共享参数
- 对于任一个卷积层，都存在一个能实现和它一样的前向传播函数的全连接层
- 任何全连接层都可以被转化为一个等效的卷积层
- 将全连接层转化为卷积层在该场景中更加有用


规格严格 功夫到家

从网络结构出发

➤ 全连接层与卷积层的相互转化




规格严格 功夫到家



规格严格 功夫到家


全卷积网络 FCN



规格严格 功夫到家

神经网络中的典型上采样方法


➤ 插值 (传统方法)



规格严格 功夫到家

神经网络中的典型上采样方法

➤ 插值 (传统方法)



规格严格 功夫到家

神经网络中的典型上采样方法

➤ 插值 (传统方法)

- 常用的包括: Nearest、Bilinear、Bicubic、Lanczos等

➤ 优势

- 通常支持任意倍率采样, 效果稳定 (无参数)
- 计算效率高 (通常毫秒甚至微秒级响应)

➤ 缺陷

- 手工设计方法, 细节保留能力差
- 特定情况易出现锯齿 (通常可以采用抗锯齿操作, 扩大采样密度)

规格严格 功夫到家

神经网络中的典型上采样方法

➤ 像素重排 (Pixel Shuffle)


- 将 $N \times N$ 个通道视为一组, 重新排列成 $N \times N$ 的窗格

➤ 优势

- 无需插值, 信息保留完整

➤ 缺陷


- 必须是整数倍采样
- 对高频细节或规律性纹理不敏感
- 容易产生块状噪声



规格严格 功夫到家

神经网络中的典型上采样方法


➤ 小波变换 (通常正/逆变换同时使用)



规格严格 功夫到家

神经网络中的典型上采样方法

➤ 小波变换



规格严格 功夫到家

神经网络中的典型上采样方法

➤ 转置卷积 (又称反卷积、分步卷积)

➤ 前向传播: $y = Cx$

➤ 反向传播: $\frac{\partial L}{\partial x} = C^T \frac{\partial L}{\partial y}$

➤ 右图: 以卷积的im2col实现为例

➤ w 向量实现 $2 \times 2 \rightarrow 1 \times 1$ 的映射

➤ w' 向量转置, 即实现 $1 \times 1 \rightarrow 2 \times 2$


$$\begin{array}{ccc}
 \begin{array}{c} f \\ \begin{bmatrix} 1 & 2 & 0 \\ 1 & 1 & 3 \\ 0 & 2 & 2 \end{bmatrix} \end{array} & \star & \begin{array}{c} w \\ \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \end{array} = \begin{array}{c} o \\ \begin{bmatrix} 12 & 17 \\ 11 & 21 \end{bmatrix} \end{array} \\
 \downarrow \text{im2col} & & \downarrow \text{im2col} \quad \quad \uparrow \text{col2im} \\
 \begin{array}{c} \begin{bmatrix} 1 & 2 & 1 & 1 \\ 2 & 0 & 1 & 3 \\ 1 & 1 & 0 & 2 \\ 1 & 3 & 2 & 2 \end{bmatrix} & * & \begin{array}{c} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \\ w' \end{array} = \begin{array}{c} \begin{bmatrix} 12 \\ 17 \\ 11 \\ 21 \end{bmatrix} \\ o' \end{array}
 \end{array}
 \end{array}$$

规格严格 功夫到家

神经网络中的典型上采样方法

➤ 转置卷积 (又称反卷积、分步卷积)


N.B.: Blue maps are inputs, and cyan maps are outputs.



规格严格 功夫到家

全卷积网络 FCN (CVPR'15)


➤ FCN上采样



规格严格 功夫到家

全卷积网络 FCN (CVPR'15)

➤ FCN上采样




规格严格 功夫到家

U-Net (MICCAI'15)

➤ 将FCN “单次跳跃相加”


任何事物都可以通过
对观察的反思来加深理解
—— 列维-斯特劳斯



规格严格 功夫到家

U-Net (MICCAI'15)


➤ 细胞分割任务



规格严格 功夫到家


U-Net (MICCAI'15)

➤ 数据增广 (网格顶点随机+网格内部像素位置插值)



规格严格 功夫到家

DeepLab系列工作



规格严格 功夫到家

DeepLab v1 (ICLR'15)

➤ FCN问题

- 分类网络为了增大感受野不断池化，空间分辨率急剧下降（输出特征图是输入的1/8甚至1/16），上采样回去时边界模糊


➤ 能否增大感受野的同时不降低空间分辨率？

- 空洞卷积（膨胀卷积）


规格严格 功夫到家

DeepLab v1 (ICLR'15)

➤ 空洞卷积



普通卷积




空洞卷积

规格严格 功夫到家

DeepLab v1 (ICLR'15)

单独的后处理模块，无需训练，只依赖模型输出

Fully Connected CRF



➤ 全连接条件随机场 (Conditional Random Field)

➤ 解决上采样损失边界信息的问题

➤ 看邻居：加强邻域预测结果对当前像素点的校验

➤ 看整体：考虑长程关联与语义信息，修正明显不合理的地方


➤ 看细节：结合形状、颜色等原始信息，判断标签是否合理

➤ 利用CRF对像素间空间关系的建模能力，补充恢复图像细节信息，提升分割精度


规格严格 功夫到家

DeepLab v1 (ICLR'15)


➤ 全连接条件随机场 (Conditional Random Field)




Image/G.T.




DCNN output



CRF Iteration 1



CRF Iteration 2




CRF Iteration 10

规格严格 功夫到家

DeepLab v2 (T-PAMI'16)

➤ DeepLab v1的期刊版本


➤ 提出空洞卷积金字塔：多尺度感知+上下文增强



规格严格 功夫到家

DeepLab v2 (T-PAMI'16)

➤ ASPP vs. LargeFOV




Method	before CRF	after CRF
LargeFOV	65.76	69.84
ASPP-S	66.98	69.73
ASPP-L	68.96	71.57

规格严格 功夫到家

DeepLab v3 (CVPR'17)

➤ 改进ASPP，去除CRF



- 空洞卷积后增加BN层，稳定训练
- 超大rate空洞卷积改为 1×1 卷积（覆盖不到有效像素， 1×1 降算力消耗）
- 增加全局池化层（补充全局特征）



规格严格 功夫到家


DeepLab v3+ (ECCV'18)

➤ 采用编码器-解码器架构



规格严格 功夫到家

实例分割 $\approx$ 语义分割 + 目标检测




规格严格 功夫到家

目标检测基础

R-CNN (Region-CNN, CVPR'14)

➤ 选框 + 提取特征/类别预测 + 非极大值抑制后处理

R-CNN: *Regions with CNN features*




规格严格 功夫到家

R-CNN (Region-CNN, CVPR'14)

➤ Selective Search 候选框获取

- 初始超像素
- 基于相似行进行相邻区域合并
 - 颜色相关性（直方图）
 - 纹理相似性（SIFT特征）
 - 尺寸相似性（优先合并小区域）
 - 形状兼容性（衡量合并后区域边界框的填充程度）
- 多样化策略
 - 多尺度分割
 - 使用不同颜色空间、相似性度量



规格严格 功夫到家

R-CNN (Region-CNN, CVPR'14)

➤ 特征提取与判别

- AlexNet+ImageNet预训练模型提取特征
- SVM进行分类（类别、是否是物体）

➤ 非极大值抑制 (Non-Maximum Suppression, NMS)

- 从一堆重叠的框中，只保留最好的那个，去掉多余的重复框。

步骤：

1. 按置信度分数从高到低排序
2. 取出分数最高的框，加入“保留列表”
3. 计算其余框与这个框的 IoU（交并比）
4. 删除所有 $\text{IoU} > \text{阈值}$ （如0.5）的框
5. 重复步骤2-4，直到候选框列表为空

规格严格 功夫到家

R-CNN (Region-CNN, CVPR'14)

➤ 速度缺陷

- 每张图生成1000~2000个候选框

能否合并?


- 对每个候选区域，使用神经网络抽取特征
- 特征送入每一类的SVM分类器，判别是否属于该类

规格严格 功夫到家

Fast R-CNN (ICCV'15)

➤ 端到端训练

- 每张图生成1000~2000个候选框 (~几秒钟 CPU)
- 对每个候选区域，使用神经网络抽取特征
- 特征送入每一类的SVM分类器，判别是否属于该类




规格严格 功夫到家

Fast R-CNN (ICCV'15)

➤ 端到端训练

- 对整张图提取特征图
- 每张图生成1000~2000个候选框 (~几秒钟 CPU)
- 对每个候选区域, 使用 **神经网络抽取的特征**
- 特征通过ROI Pooling, 映射为固定尺寸, 并直接训练分类, 替代SVM





规格严格 功夫到家

Faster R-CNN (NeurIPS'15)

➤ RPN(Region Proposal Networks) 网络直接



- 在全卷积网络最后一层特征图滑动一个小窗口, 生成一系列候选框



滑窗 (固定尺寸) 如何生成不同尺寸的候选框?

每个位置用多个预设的、不同尺度和比例的锚点, 来覆盖各种大小的目标

3个尺度: 128^2 、 256^2 、 512^2 个像素
3个比例: 1:1、1:2、2:1



规格严格 功夫到家


R-CNN vs. Fast R-CNN vs. Faster R-CNN

对比维度	R-CNN	Fast R-CNN	Faster R-CNN
候选框生成方法	Selective Search (CPU 2s/图像)	Selective Search (CPU 2s/图像)	RPN (GPU 几乎无成本)
特征提取方法	每个候选区域 单独计算	整图输入CNN 共享特征图	整图输入CNN 共享特征图
是否端到端训练	否	近似 (除候选框)	是
速度 (VOC 2007)	47秒/图	0.3秒/图 (除候选框)	0.2秒/图 (含候选框)
精度 (VOC 2007)	53.5%	66.9%	73.2% (VOC 2012)

规格严格 功夫到家

Mask R-CNN (ICCV'17)


➤ 基于Faster R-CNN改造



规格严格 功夫到家


Mask R-CNN (ICCV'17)

➤ RoI Pool vs. RoI Align



操作	RoI Pool	RoI Align
边界操作	坐标取整	保留浮点数边界
内部池化 (10个格子分成3个)	近似划分 ([3, 3, 4])	均匀画格 ([3.33, 3.33, 3.33])
取值	MaxPool	双线性插值计算采样点值

规格严格 功夫到家



规格严格 功夫到家

T h e E n d

THANKS FOR YOUR ATTENTION

規格嚴格 功夫到家