

13-14. 立体视觉

张宏志

机器学习研究中心, 计算学部
2026 春

zhanghz@hit.edu.cn 390684271@qq.com




14 对极几何与双目视觉

规格严格 功夫到家



立体视觉深度恢复

➤ 目标: 通过寻找与 x 对应的图像坐标 x' 来恢复深度




立体视觉深度恢复

➤ 目标: 通过寻找与 x 对应的图像坐标 x' 来恢复深度

➤ 子问题:

- 标定: 如何恢复 (或确定) 相机之间的关系 (如果尚未已知)?
- 匹配: 如何搜索匹配点 x' ?



匹配问题




- 已知两个从具有不同内参和外参的相机拍摄的图像。
- 如何将第一张图像中的一个点与第二张图像中的一个点进行匹配?

规格严格 功夫到家




对极几何



规格严格 功夫到家

极线约束





x_1 的潜在匹配点位于极线 l_2

约束作用： 如果已知左图中的点 x_1 ，那么其在右图中的对应匹配点 x_2 必然位于极线 l_2 上。

计算意义： 这一约束将立体匹配的搜索范围从整个二维图像平面（2D搜索）缩小到了特定的一维直线（1D搜索）。极大地提高了立体视觉算法的计算效率和匹配准确性。

规格严格 功夫到家


示例：会聚相机



一对叠加了对应匹配点及其极线（白色）的图像

规格严格 功夫到家


示例：会聚相机



这张图的极点在哪儿？

规格严格 功夫到家

示例：会聚相机



这张图的极点在哪儿？

在这种情况下，两个极点都位于可见图像范围之外

本质矩阵
(Essential matrix)

规格严格 功夫到家

回顾：单相机模型

$$x = K[R|t]X$$

上式表示一个相机如何将三维世界点 X 投影到二维图像像素坐标 x ：


- X ：三维世界点（齐次坐标，4维）
- $[R|t]$ ：相机的外参矩阵，表示世界坐标系到相机坐标系的刚体变换（旋转 + 平移）
- K ：相机内参矩阵，包含焦距、主点等参数
- x ：图像上的二维像素点（齐次坐标，3维）

局限： 这个模型只描述了“一个相机看到什么”，无法恢复深度信息——因为无数个不同深度的三维点都可能投影到同一个像素点上。

规格严格 功夫到家



回顾：为什么需要双目？



为了恢复深度，引入第二个相机，形成 **立体视觉系统**。此时，同一个三维点 X 会在两个图像上分别成像为 x 和 x' （在各自像素坐标系下）。

目标：已知两个相机的内外参，以及一对匹配点 (x, x') ，求解该点的三维位置 X 。

规格严格 功夫到家



单目到双目的过渡

步骤1：相机标定 $\rightarrow$ 获得内参 K, K' 和外参 $[R|t]$

在双目系统中，通过标定获得以下参数：

- 左相机内参 K ，右相机内参 K'
- 从左相机到右相机的相对位姿：旋转矩阵 R ，平移向量 t

步骤2：将像素坐标转换为归一化坐标

$$\hat{x} = K^{-1}x, \quad \hat{x}' = K'^{-1}x'$$

把像素坐标转换到“归一化相机坐标系”下：假设相机焦距为1、主点在原点时的理想成像平面坐标。消除内参的影响，使后续几何关系仅依赖于相机间的相对位姿。此时， $\hat{x}$ 和 $\hat{x}'$ 实际上是从各自相机光心出发、指向三维点 X 的单位方向向量（在各自相机坐标系下）。

规格严格 功夫到家



单目到双目的过渡

步骤3：建立对极约束

三维点 X 、左相机光心 O 、右相机光心 O' 三点共面，该平面称为 **对极平面**。由这三个点生成的三个向量也共面。将所有向量都转换到 **右相机的坐标系**下：

- 向量1：从左光心指向右光心的基线向量 $\vec{t}$ （在右相机系下，这就是平移向量）。
- 向量2：从右光心指向空间点的向量 $\hat{x}'$ 。
- 向量3：从左光心指向空间点的向量 $\hat{x}$ 。但这个向量是在左相机系下的，需要把它旋转到右相机系下，即 $R\hat{x}$ 。

结论：向量 $\vec{t}$ 、 $\hat{x}'$ 和 $R\hat{x}$ 必须共面。

在向量代数中，判断三个向量 $\vec{a}, \vec{b}, \vec{c}$ 是否共面的充要条件：它们的混合积（标量三重积）为0。

$$\vec{a} \cdot (\vec{b} \times \vec{c}) = 0$$

规格严格 功夫到家



单目到双目的过渡

步骤3：建立对极约束

结论：向量 $\vec{t}$ 、 $\hat{x}'$ 和 $R\hat{x}$ 必须共面。

在向量代数中，判断三个向量 $\vec{a}, \vec{b}, \vec{c}$ 是否共面的充要条件：它们的混合积（标量三重积）为0。

$$\vec{a} \cdot (\vec{b} \times \vec{c}) = 0$$

在对极几何中： $\vec{a} = \vec{t}$ ； $\vec{b} = \hat{x}'$ ； $\vec{c} = R\hat{x}$ 。所以，共面约束的数学表达式如下：

$$\hat{x}' \cdot (\vec{t} \times (R\hat{x})) = 0$$

这就是**对极约束**最原始的物理表达。为了将叉乘变成矩阵乘法，引入了反对称矩阵

对于任意向量 $\vec{t} = [t_x, t_y, t_z]^T$ ，它与另一个向量 $\vec{v}$ 的叉乘 $\vec{t} \times \vec{v}$ 可以等价地写成一个矩阵乘以向量：

$$\vec{t} \times \vec{v} = \begin{bmatrix} t_x \\ t_y \\ t_z \end{bmatrix} \times \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix} = \begin{bmatrix} t_y v_z - t_z v_y \\ t_z v_x - t_x v_z \\ t_x v_y - t_y v_x \end{bmatrix} = [t]_{\times} \vec{v} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix} \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix}$$

规格严格 功夫到家



单目到双目的过渡

步骤3：建立对极约束

结论：向量 $\vec{t}$ 、 $\hat{x}'$ 和 $R\hat{x}$ 必须共面。

$$\hat{x}' \cdot (\vec{t} \times (R\hat{x})) = 0$$

$$\vec{t} \times \vec{v} = \begin{bmatrix} t_x \\ t_y \\ t_z \end{bmatrix} \times \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix} = \begin{bmatrix} t_y v_z - t_z v_y \\ t_z v_x - t_x v_z \\ t_x v_y - t_y v_x \end{bmatrix} = [t]_{\times} \vec{v} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix} \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix}$$

结合点积转矩阵乘法的形式（ $\vec{a} \cdot \vec{b} = \vec{a}^T \vec{b}$ ），重写表达式如下：

$$\hat{x}'^T ([t]_{\times} (R\hat{x})) = 0$$

根据矩阵结合律，把中间两项结合起来：

$$\hat{x}'^T ([t]_{\times} R) \hat{x} = 0$$

这就定义了本质矩阵 E ：

$$E = [t]_{\times} R$$

本质矩阵
(Longuet-Higgins, 1981)

家

规格严格 功夫到家



本质矩阵

➢ 本质矩阵（ E ）编码了两个相机视图之间的 **相对位姿**（旋转和平移）。

➢ 它将立体视觉中对应的图像点关联起来。

➢ 该矩阵由相机的内参及其相对位置推导得出。



本质矩阵的用法

本质矩阵扮演着连接二维图像观测与三维物理世界的核心角色。尽管 **最终目标是恢复场景的三维结构或估计相机的运动轨迹**，但本质矩阵本身并不直接输出三维坐标，而是作为求解过程中的关键中间变量。其具体应用逻辑遵循以下三个严谨步骤：

1. 相对位姿估计：通过匹配两幅图像中的特征点，可以计算出本质矩阵 E 。利用SVD等数学工具对 E 进行分解，可以解算出两个相机坐标系之间的相对旋转矩阵 R 和平移向量 t （注：此时平移向量仅包含方向信息，模长为1）。这一步确立了双视图几何中的相对位置关系，为后续的三维重建提供了必要的运动参数。

2. 三维点三角化：在获取了相机的相对位姿（即 R 和 t ）后，即可构建出两个相机的投影矩阵。结合已知的对应像素点对，利用三角测量原理求解三维空间点 X 的坐标。该过程基于几何约束：从两个相机光心出发、分别穿过对应像素点的两条射线，在理想情况下应在三维空间中相交于一点。通过线性或非线性优化方法求解该交点，即可获得场景点的三维坐标。

3. 尺度恢复与全局一致性：由于本质矩阵的定义特性，其分解得到的平移向量 t 具有尺度不确定性（即无法区分“近距离的小幅度移动”与“远距离的大幅度移动”）。因此，仅凭本质矩阵恢复出的三维结构是“单目尺度模糊”的。在实际应用中，通常需要通过以下途径恢复真实物理尺度：

传感器融合：引入惯性测量单元等外部传感器提供的绝对位移信息。

先验知识：利用场景中已知长度的物体或距离作为参照。

基础矩阵 (Fundamental Matrix)

规格严格 功夫到家



本质矩阵的局限性与适用前提

本质矩阵是描述双视图几何关系的核心数学工具，其定义的极线约束方程为：

$$\hat{x}^T E \hat{x}' = 0$$


该方程成立的前提是坐标 $\hat{x}$ 和 $\hat{x}'$ 必须位于**归一化相机坐标系**中。这意味着输入数据必须经过焦距归一化处理，消除了相机内部光学特性的影响。然而，在实际应用场景中，直接获取归一化坐标往往面临以下局限性：

- **依赖内参知识：**从图像像素坐标 x 转换到归一化坐标 $\hat{x}$ 需要精确的相机内参矩阵 K （即 $\hat{x} = K^{-1}x$ ）。

- **未标定场景失效：**当相机未经过标定，或者在处理历史影像、网络图片等元数据缺失的情况时，内参矩阵 K 和 K' 是未知的。此时，无法计算归一化坐标，导致基于 E 的约束方程无法直接建立。

规格严格 功夫到家

极线约束：未标定情况



如果我们不知道 K 和 K' ，那么我们可以用未知的归一化坐标来写出极线约束：

$$\hat{x}^T E \hat{x}' = 0 \quad x = K \hat{x}, \quad x' = K' \hat{x}'$$

规格严格 功夫到家



基础矩阵

在不知道 K 和 K' 的情况下，我们可以利用未知的归一化坐标来定义一个类似的关系。

$$\begin{aligned} \hat{x}^T E \hat{x}' &= 0 \\ \hat{x} &= K^{-1} x \\ \hat{x}' &= K'^{-1} x' \end{aligned} \Rightarrow \boxed{x^T F x' = 0} \quad \text{with} \quad F = K^{-T} E K'^{-1}$$

基础矩阵
(Faugeras and Luong, 1992)

规格严格 功夫到家

基础矩阵的内在约束与自由度分析

在探讨基础矩阵的具体求解算法之前，必须首先明确其内在的数学性质与自由度限制。这些几何与代数特性直接决定了线性方程组的构建方式以及后续非线性约束的施加机制。

1. 秩为2的内在属性：基础矩阵的核心作用是将一幅图像中的点映射为另一幅图像中过极点的极线。从代数结构上看，

$$\begin{aligned} F &= K^{-T} E K'^{-1} \\ E &= [t]_{\times} R \end{aligned}$$

由于平移向量 t 的反对称矩阵 $[t]_{\times}$ 的秩恒为 2，且旋转矩阵 R 及内参矩阵 K, K' 均为满秩矩阵，因此基础矩阵 F 的秩必然为 2。对于 3×3 矩阵而言，这等价于

$$\det(F) = 0$$

这一非线性约束是基础矩阵与生俱来的内在属性。

规格严格 功夫到家



基础矩阵的内在约束与自由度分析

2. 自由度的推导

基础矩阵是一个 3×3 的齐次矩阵，理论上包含 9 个元素。然而，其实际独立参数的数量受到两个关键条件的制约：

尺度等价性：

$$x^T F x = 0$$

上述对级约束方程是齐次的，矩阵 F 的整体尺度不确定，损失 1 个自由度。

秩约束：

$$\det(F) = 0$$

行列式为 0 提供了 1 个额外的非线性约束，再损失 1 个自由度。

基础矩阵的真实自由度为

$$9 - 1 - 1 = 7$$

至少需要 7 组独立的匹配点才能唯一确定两视图间的极线几何关系。



基础矩阵的内在约束与自由度分析

3. 向经典估计算法的过渡

尽管基础矩阵仅有 7 个自由度，但在实际的数值求解过程中，由于 $\det(F) = 0$ 是非线性约束，无法直接将其纳入常规的线性方程组中。因此，在工程实践中衍生出了两种经典的估算策略：

8点法 (8-point algorithm)：在线性求解阶段暂时搁置秩约束，将 F 视为具有 8 个自由度（仅考虑尺度等价性）的普通矩阵。该方法计算简便，但对噪声较为敏感。

7点法 (7-point algorithm)：严格基于最小配置，利用 7 组匹配点求解线性方程组的零空间。该方法充分利用了内在约束，但可能产生多达三个合法解，需进一步筛选。

这两种方法构成了多视图几何中基础矩阵估计的理论基石。



估计基础矩阵

➤ 8点法 (8-point algorithm)

- 利用8组匹配点对构建方程，通过奇异值分解 (SVD) 求其最小二乘解
- 对求得的基础矩阵 F 再次进行 SVD 分解，以强制施加 $\det(F)=0$ 的秩约束条件。

➤ 7点法 (7-point algorithm)

- 利用7组匹配点对，通过 SVD 求解方程组的零空间，从而得到两个基础向量
- 求解这两个向量的线性组合，使其满足 $\det(F)=0$ 的约束条件。

➤ 最小化重投影误差 (Minimize reprojection error)

- 采用非线性最小二乘法对基础矩阵进行精细化估计。

规格严格 功夫到家



8点法 (8-point algorithm)

1. 求解齐次线性方程组

a. 列出方程式

$$x^T F x' = 0$$

$$u u' f_{11} + u v' f_{12} + u f_{13} + v u' f_{21} + v v' f_{22} + v f_{23} + u' f_{31} + v' f_{32} + f_{33} = 0$$

$$A f = \begin{bmatrix} u_1 u_1' & u_1 v_1' & u_1 & v_1 u_1' & v_1 v_1' & v_1 & u_1' & v_1' & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_n u_n' & u_n v_n' & u_n & v_n u_n' & v_n v_n' & v_n & u_n' & v_n' & 1 \end{bmatrix} \begin{bmatrix} f_{11} \\ f_{12} \\ f_{13} \\ f_{21} \\ f_{22} \\ f_{23} \\ f_{31} \\ f_{32} \\ f_{33} \end{bmatrix} = 0$$

b. 使用SVD从 $Af=0$ 求解 f

规格严格 功夫到家



未知的相机投影矩阵

回顾：已知二维图像坐标 $\begin{bmatrix} su \\ sv \\ s \end{bmatrix}$ 和已知三维图像坐标 $\begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$

$$0 = m_{11}X + m_{12}Y + m_{13}Z + m_{14} - m_{31}uX - m_{32}uY - m_{33}uZ - m_{34}u$$

$$0 = m_{21}X + m_{22}Y + m_{23}Z + m_{24} - m_{31}vX - m_{32}vY - m_{33}vZ - m_{34}v$$

➤ 方法一：齐次线性方程组。使用 SVD 求解 m 的元素

$$\begin{bmatrix} X_1 & Y_1 & Z_1 & 1 & 0 & 0 & 0 & -u_1 X_1 & -u_1 Y_1 & -u_1 Z_1 & -u_1 \\ 0 & 0 & 0 & 0 & X_1 & Y_1 & Z_1 & -v_1 X_1 & -v_1 Y_1 & -v_1 Z_1 & -v_1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ X_n & Y_n & Z_n & 1 & 0 & 0 & 0 & -u_n X_n & -u_n Y_n & -u_n Z_n & -u_n \\ 0 & 0 & 0 & 0 & X_n & Y_n & Z_n & -v_n X_n & -v_n Y_n & -v_n Z_n & -v_n \end{bmatrix} \begin{bmatrix} m_{11} \\ m_{12} \\ m_{13} \\ m_{14} \\ m_{21} \\ m_{22} \\ m_{23} \\ m_{24} \\ m_{31} \\ m_{32} \\ m_{33} \\ m_{34} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}$$

$Am = 0$ 形式

规格严格 功夫到家



回顾：利用SVD求解齐次线性方程组 (DLT算法)

➤ 优化问题构建

由于噪声的存在或数据量的冗余，方程组 $Am = 0$ 往往没有精确的非零解。因此，将问题转化为一个带约束的最小二乘优化问题。需要寻找一个非零向量 m ，使得残差 $\|Am\|^2$ 最小，为了避免平凡解 $m = 0$ ，必须施加范数约束。

目标函数： $\min_m \|Am\|^2$ ；约束条件： $\|m\|^2 = 1$

➤ 拉格朗日乘数法

引入拉格朗日乘子 λ ，构造拉格朗日函数 $L(m, \lambda)$ ：

$$L(m, \lambda) = \|Am\|^2 - \lambda(\|m\|^2 - 1)$$

展开范数项 (注意 $\|x\|^2 = x^T x$)：

$$L(m, \lambda) = (Am)^T (Am) - \lambda(m^T m - 1) = m^T A^T A m - \lambda(m^T m - 1)$$

规格严格 功夫到家



回顾：利用SVD求解齐次线性方程组（DLT算法）

➤ 拉格朗日乘数法

引入拉格朗日乘子 λ ，构造拉格朗日函数 $L(m, \lambda)$ ：

$$L(m, \lambda) = \|Am\|^2 - \lambda(\|m\|^2 - 1)$$

展开范数项（注意 $\|x\|^2 = x^T x$ ）：

$$L(m, \lambda) = (Am)^T(Am) - \lambda(m^T m - 1) = m^T A^T A m - \lambda(m^T m - 1)$$

对 m 求偏导并令其为 0： $\frac{\partial L}{\partial m} = 2A^T A m - 2\lambda m = 0$ ；整理得： $A^T A m = \lambda m$

结论：最优解 m 必须是矩阵 $A^T A$ 的**特征向量**，而对应的拉格朗日乘子 λ 即为该特征向量对应的**特征值**。

此时，目标函数的值为：

$$\|Am\|^2 = m^T (A^T A m) = m^T (\lambda m) = \lambda(m^T m) = \lambda$$

因为我们要最小化 $\|Am\|^2$ ，所以 m 应当取 $A^T A$ 的**最小特征值对应的特征向量**。



回顾：利用SVD求解齐次线性方程组（DLT算法）

➤ 从特征分解到奇异值分解（SVD）

虽然理论上可以通过计算 $A^T A$ 的特征分解来求解，但在实际数值计算中，直接对 A 进行**奇异值分解（SVD）** 是更优的选择。为什么使用 SVD？

- 数值稳定性：**计算 $A^T A$ 会导致矩阵的条件数平方化，如果 A 本身接近秩亏， $A^T A$ 会变得极度病态，导致精度丢失。SVD 直接作用于 A ，避免了这一问题。
- 数学等价性：**根据 SVD 的定义，矩阵 A 可以分解为： $A = U\Sigma V^T$ ，其中：
 - U 是 $2n \times 2n$ 的正交矩阵，满足 $U^T U = I$
 - Σ 是 $2n \times 12$ 的对角矩阵，对角线元素 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{12} \geq 0$ 为奇异值。
 - V 是 12×12 的正交矩阵，其列向量 $v_1, \dots, v_{12}$ 即为右奇异向量。

将 SVD 代入 $A^T A$ ：

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T \Sigma) V^T$$

可以看出， $A^T A$ 的特征分解形式正是 $V(\Sigma^T \Sigma)V^T$ 。这意味着： $A^T A$ 的**特征向量**就是 V 的列向量。 $A^T A$ 的**特征值** λ_i 等于奇异值的平方 σ_i^2 。



8点法 (8-point algorithm)

1. 求解齐次线性方程组

- 列出方程式
- 使用SVD从 $Af=0$ 中求解 f

2. 对求得的基础矩阵 F 再次进行 SVD 分解，以强制施加 $\det(F)=0$ 的约束条件。

利用SVD直接解 $Af=0$ ，解出的矩阵记为 F_{alg} 。由于噪声的存在， F_{alg} 的秩通常是3（即满秩），行列式 $\det(F_{alg}) \neq 0$ 。这意味着在几何上是不合法的，需要强行“投影”到满足条件的空间里。

- 对 F_{alg} 进行分解： $F_{alg} = U\Sigma V^T$ ，其中 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \sigma_3)$ ，且 $\sigma_1 \geq \sigma_2 \geq \sigma_3$ 。
- 将最小的奇异值 σ_3 强制设为 0。构造新的奇异值矩阵 $\Sigma' = \text{diag}(\sigma_1, \sigma_2, 0)$

$$F = U\Sigma'V^T$$



8点法 (8-point algorithm)

1. 求解齐次线性方程组

- 列出方程式
- 使用SVD从 $Af=0$ 中求解 f

2. 对求得的基础矩阵 F 再次进行 SVD 分解，以强制施加 $\det(F)=0$ 的约束条件。

$$\Sigma' = \text{diag}(\sigma_1, \sigma_2, 0), F_{final} = U\Sigma'V^T$$

3. 使用 **RANSAC** 算法来处理异常值（每次随机抽取 8 个点）



- 采样8个点：RANSAC 会在所有匹配点中随机挑选 8 对点，用之前推导的公式算出一个基础矩阵 F 。
- 测试/判定异常值：利用 F 检验剩下所有的匹配点。如果某个点代入

$$x'^T F x = 0$$

后误差太大，则那个点就被判定为异常值（Outlier）；反之则是内点（Inlier）。



判定异常值




找到家


置信度最高的前 100 个局部特征匹配结果。在本例中，有 93 个匹配是正确的（以绿色高亮显示），7 个是错误的（以红色高亮显示）。



在超过一万个局部特征中，筛选出置信度最高的 800 个匹配点



保留那些相对于‘最优’基础矩阵而言属于‘内点’的匹配。



从对极几何到相机标定

- 估计基础矩阵被称为“弱标定”
- 如果知道两个相机的标定矩阵，就可以估计本质矩阵： $E = K^T F K$
- 本质矩阵提供了相机之间的相对旋转和平移，即它们的外参

规格严格 功夫到家

选 F 还是 E? —— 看具体应用场景

- 基础矩阵 (F)
 - 优点：不需要知道相机内参，直接用图像上的点计算，简单省事。
 - 缺点：拿来做 3D 重建的话精度不够；而且它反映不出相机真实的运动轨迹。
- 本质矩阵 (E)
 - 优点：更精准！能直接反映出相机的旋转和平移，是做 3D 重建的绝佳选择。
 - 缺点：必须得提前知道相机的内参；而且计算起来更复杂。
- 使用场景
 - 图像匹配 & 立体视觉：图省事、求快，选 F。
 - 3D 重建 & 运动估计：追求高精度，优先选 E。
- 结论
 - 如果你不知道相机内参，或者只是想简单处理一下，那就用 F；但如果你要做高精度的任务，且清楚相机的内参，那就果断上 E。

规格严格 功夫到家

视觉系统

规格严格 功夫到家

视觉系统

One camera



Two cameras



N cameras



规格严格 功夫到家

Let's consider two eyes

One camera



Two cameras



N cameras



规格严格 功夫到家

泰坦尼克号的立体图像



(a) 远洋客轮泰坦尼克号的立体补色图像。红色图像显示右眼视图，青色显示左眼视图。当像 (b) 那样通过红/青立体眼镜观看时，青色对比出现在左眼图像中，红色变化出现在右眼中，从而产生 3D 的感知。


立体镜 (Stereoscope)



左图：19世纪末的立体照片，拍摄地点为美国波士顿查尔斯街林荫道。这种照片采用双镜头相机从两个略微不同的角度同时拍摄同一场景，形成左右两幅略有差异的图像，模拟人眼视差。

右图：一台典型的19世纪木质立体镜，结构包括两个目镜、可调节焦距的旋钮和用于插入立体照片的插槽。使用者将双眼分别对准两个目镜，大脑会自动融合左右图像，产生具有深度感的三维视觉效果。


测量视差



Left image Right image
拍了一张照片，然后向右移动了大约 1 米，又拍了第二张照片。

规格严格 功夫到家


测量视差



Left image Right image

规格严格 功夫到家


测量视差



Left image Right image

规格严格 功夫到家

测量视差




$$\text{深度图 } Z = f \frac{T}{D(x,y)}$$

规格严格 功夫到家

回顾：立体视觉深度恢复


➤ 目标：通过寻找与 x 对应的图像坐标 x' 来恢复深度



立体视觉

规格严格 功夫到家

利用极线约束寻找对应点




$$\begin{aligned} x'^T F x &= 0 \\ l'^T x' = 0 &\Rightarrow x'^T l' = 0 \end{aligned} \quad \Rightarrow \quad l' = Fx$$

规格严格 功夫到家


立体图像校正

- 将图像平面重新投影到一个平行于两个相机中心连线的公共平面上
- 在此变换之后，像素的运动是水平的
- 需要两个单应性矩阵（3x3 变换），每张输入图像的重投影各对应一个



规格严格 功夫到家

稠密对齐




对于每一条极线：

对于左图中的每一个像素 / 窗口：

与右图中同一极线上的每一个像素 / 窗口进行比较
选择匹配代价（例如 SSD、归一化相关性）最小的位置

规格严格 功夫到家

基于相似性约束的对应点搜索



- 沿右图的扫描线滑动一个窗口，并将其内容（图像块）与左图中的参考窗口进行比较。
- 匹配代价：平方差之和（SSD）或归一化相关性。

基于相似性约束的对应点搜索

