

13-14. 立体视觉

张宏志

机器学习研究中心，计算学部
2026 春

zhanghz@hit.edu.cn 390684271@qq.com



13.1 图像形成的几何学


图像坐标与世界坐标之间的映射

- 小孔成像模型
- 投影几何
 - 消失点与消失线
- 投影矩阵



降维机器 (3D to 2D)


3D world



Point of observation




2D image






消失点和线

现实世界中，一组互相平行的直线，在图像中会汇聚到一点。这个点叫：消失点 (Vanishing Point)




消失点和线





小孔成像模型




f = 焦距
 c = 相机中心 (光心)



长度和面积不被保持


在三维世界投影到二维图像的过程中，物体的真实长度和真实面积会因透视效应而改变，因此无法直接从图像中的尺寸推断真实尺寸。






投影：世界坐标 $\rightarrow$ 图像坐标

如果 $x = 2$,
 $y = 3$, $z = 5$, $f = 2$.
 u' 和 v'
的值是多少?



投影：世界坐标 $\rightarrow$ 图像坐标



如何处理这种通用情况？

齐次坐标

齐次坐标可以把
平移、旋转、缩
放、投影统一表
示成矩阵乘法。

转换为齐次坐标

$$(x, y) \Rightarrow \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

齐次图像坐标

$$(x, y, z) \Rightarrow \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

齐次场景坐标
(齐次空间坐标)

为什么要转换？

从齐次坐标转换（回普通坐标）

$$\begin{bmatrix} x \\ y \\ w \end{bmatrix} \Rightarrow (x/w, y/w)$$

$$\begin{bmatrix} x \\ y \\ z \\ w \end{bmatrix} \Rightarrow (x/w, y/w, z/w)$$

齐次坐标

对缩放不变 (具有尺度不变性)

$$k \begin{bmatrix} x \\ y \\ w \end{bmatrix} = \begin{bmatrix} kx \\ ky \\ kw \end{bmatrix} \Rightarrow \begin{bmatrix} \frac{kx}{kw} \\ \frac{ky}{kw} \end{bmatrix} = \begin{bmatrix} \frac{x}{w} \\ \frac{y}{w} \end{bmatrix}$$

齐次坐标

笛卡尔坐标
(直角坐标)

笛卡尔坐标中的一个点，在齐次坐标中对应一条射线

问题：假设我们有一个点的笛卡尔坐标（直角坐标），那么它对应的齐次坐标是什么？

假设笛卡尔坐标中的点：

(1, 2)

对应的齐次坐标可以写成：

(1, 2, 1)

也可以写成：

(2, 4, 2)

(3, 6, 3)

(100, 200, 100)

...

它们全部位于：

从原点出发的同一条射线 (Ray) 上。



齐次坐标中的基础几何

- 直线方程: $ax + by + c = 0$ $line_i = \begin{bmatrix} a_i \\ b_i \\ c_i \end{bmatrix}$
- 在像素坐标后附加一个 1, 即可得到齐次坐标 $p_i = \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix}$
- 通过两个点的叉积可以得到一条直线 $line_{ij} = p_i \times p_j$
- 两条直线的交点可以通过两条直线的叉积得到 $q_{ij} = line_i \times line_j$



齐次坐标中的基础几何

➤ 通过两个点的叉积可以得到一条直线 ($line_{ij} = p_i \times p_j$)

直线的齐次表示为 $line = \begin{bmatrix} a \\ b \\ c \end{bmatrix}$, 对应普通方程 $ax + by + c = 0$ 。

步骤：取两点 $p_1 = \begin{bmatrix} 2 \\ 3 \\ 1 \end{bmatrix}$ 、 $p_2 = \begin{bmatrix} 5 \\ -1 \\ 1 \end{bmatrix}$, **计算叉积**

第一个分量: $3 \times 1 - 1 \times (-1) = 3 + 1 = 4$

第二个分量: $1 \times 5 - 2 \times 1 = 5 - 2 = 3$

第三个分量: $2 \times (-1) - 3 \times 5 = -2 - 15 = -17$

因此，过两点的直线齐次表示为：

$$line_{12} = p_1 \times p_2 = \begin{bmatrix} 4 \\ 3 \\ -17 \end{bmatrix}$$

对应普通直线方程: $4x + 3y - 17 = 0$ 。



齐次坐标中的基础几何

➤ 两条直线的交点可以通过两条直线的叉积得到 ($q_{ij} = line_i \times line_j$)

步骤：取两条直线 $line_1 = \begin{bmatrix} 1 \\ 0 \\ -2 \end{bmatrix}$ **(对应** $x - 2 = 0$ **)**、 $line_2 = \begin{bmatrix} 0 \\ 1 \\ -3 \end{bmatrix}$ **(对应** $y - 3 = 0$ **)**，**计算叉积**

第一个分量： $0 \times (-3) - (-2) \times 1 = 0 + 2 = 2$

第二个分量： $(-2) \times 0 - 1 \times (-3) = 0 + 3 = 3$


第三个分量： $1 \times 1 - 0 \times 0 = 1 - 0 = 1$

因此，两直线交点的齐次坐标为：

$$q_{12} = line_1 \times line_2 = \begin{bmatrix} 2 \\ 3 \\ 1 \end{bmatrix}$$



投影矩阵



$$\mathbf{x} = \mathbf{K}[\mathbf{R} \quad \mathbf{t}] \mathbf{X}$$

$\mathbf{x}$: 图像坐标系 $(u, v, 1)$
 $\mathbf{K}$: 内参矩阵 (3×3)
 $\mathbf{R}$: 相机旋转 (3×3)
 $\mathbf{t}$: 相机平移 (3×1)
 $\mathbf{X}$: 世界坐标 $(X, Y, Z, 1)$

公式 $\mathbf{x} = \mathbf{K}[\mathbf{R}|\mathbf{t}]\mathbf{X}$ 描述了坐标变换的全过程:

$\mathbf{X}$ (世界坐标): 物体在真实三维世界中的位置。


$[\mathbf{R}|\mathbf{t}]$ (外参矩阵): 描述相机本身的姿态。这一步将世界坐标转换为相机坐标系下的坐标。

$\mathbf{K}$ (内参矩阵): 描述相机内部的光学属性, 如焦距 (f)、主点位置等。这一步将相机坐标系下的三维点投影到二维图像像素平面上。

$\mathbf{x}$ (图像坐标): 最终在照片上看到的二维像素位置。



投影矩阵



内参假设

- 单位纵横比 (Unit aspect ratio)
- 光心位于 (0,0)
- 无错切 (No skew)

外参假设

- 无旋转 (No rotation)
- 相机位于 (0,0,0)

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{X} \rightarrow w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} \rightarrow \begin{aligned} u &= f \cdot \left(\frac{x}{z}\right) \\ v &= f \cdot \left(\frac{y}{z}\right) \end{aligned}$$



移除假设



单应性变换

1. 相似变换 (Similarity Transformation)

相似变换保持**形状不变**，只改变位置、方向和大小。它包含三个基本操作：

- 平移 (Translation)
- 旋转 (Rotation)
- 均匀缩放 (Uniform Scale)

数学表示：在齐次坐标下，相似变换矩阵为：

$$H_s = \begin{bmatrix} s \cos \theta & -s \sin \theta & t_x \\ s \sin \theta & s \cos \theta & t_y \\ 0 & 0 & 1 \end{bmatrix}$$

其中：


- s : 缩放因子 ($s > 0$)
- θ : 旋转角度
- (t_x, t_y) : 平移向量

自由度分析：相似变换有 **4个自由度**：

- 1个缩放参数 s
- 1个旋转参数 θ
- 2个平移参数 t_x, t_y

变换公式：对点 (x, y) 应用相似变换后：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s \cos \theta & -s \sin \theta & t_x \\ s \sin \theta & s \cos \theta & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$



相似变换
(平移、缩放、旋转)



单应性变换

2. 仿射变换 (Affine Transformation)

仿射变换保持**平行性**，但不保持角度和长度比例。它在相似变换基础上增加了**剪切**操作。

数学表示：在齐次坐标下，仿射变换矩阵为：

$$H_a = \begin{bmatrix} a & b & t_x \\ c & d & t_y \\ 0 & 0 & 1 \end{bmatrix}$$

其中：

- a, b, c, d : 控制旋转、缩放和剪切
- (t_x, t_y) : 平移向量

与相似变换的关系：当满足以下条件时，仿射变换退化为相似变换：

- $a = d = s \cos \theta$
- $b = -c = -s \sin \theta$


自由度分析：仿射变换有 **6个自由度**：

- 4个参数 (a, b, c, d) 控制线性变换
- 2个平移参数 (t_x, t_y)

变换公式：对点 (x, y) 应用仿射变换后：

$$\begin{cases} x' = ax + by + t_x \\ y' = cx + dy + t_y \end{cases}$$

关键特性：仿射变换中 $w = 1$ 始终成立，因此无需齐次坐标的归一化步骤。



仿射变换
(仅保持平行性)



单应性变换

3. 投影变换/单应性变换 (Projective Transformation / Homography)

单应性变换是最一般的**2D到2D的线性变换**，能表示**透视效果**（如倾斜拍摄的平面物体）。

数学表示：单应性矩阵是一个 3×3 的非奇异矩阵：

$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix}$$

由于齐次坐标的等价性（ H 与 λH 表示同一变换， $\lambda \neq 0$ ），通常将 h_{33} 归一化为 1，因此单应性矩阵有 **8个自由度**。

变换过程：

1. 齐次坐标变换：

$$\begin{bmatrix} x'_h \\ y'_h \\ w \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

2. 归一化为笛卡尔坐标（关键步骤）：


$$\begin{cases} x' = \frac{x'_h}{w} = \frac{h_{11}x + h_{12}y + h_{13}}{h_{31}x + h_{32}y + h_{33}} \\ y' = \frac{y'_h}{w} = \frac{h_{21}x + h_{22}y + h_{23}}{h_{31}x + h_{32}y + h_{33}} \end{cases}$$

与前两种变换的关系：

- **仿射变换**是单应性变换的特例：当 $h_{31} = h_{32} = 0$ 时，分母变为常数 h_{33} ，归一化后退化为线性变换。
- **相似变换**是仿射变换的特例：进一步满足 $h_{11} = h_{22}$ 且 $h_{12} = -h_{21}$ 。

几何意义：单应性变换描述了**同一平面在两个不同视角下的投影关系**。例如：

- 拍摄一张平放的纸张，从不同角度得到的两幅图像间存在单应性关系
- 分母 $h_{31}x + h_{32}y + h_{33}$ 体现了**透视效果**：当分母趋近于0时，点会“趋于无穷远”，模拟了近大远小的视觉现象



投影/单应性变换
(能表示透视效果)

规格严格 功夫到家



移除假设：已知光心

内参假设

- 单位宽高比
- 无错切

外参假设

- 无旋转 (No rotation)
- 相机位于 (0,0,0)

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{X} \rightarrow w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & u_0 & 0 \\ 0 & f & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



移除假设: 正方形像素

内参假设
• 无错切

外参假设
• 无旋转 (No rotation)
• 相机位于 (0,0,0)

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{X} \rightarrow w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha & 0 & u_0 & 0 \\ 0 & \beta & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



移除假设: 非错切像素

内参假设


外参假设

- 无旋转 (No rotation)
- 相机位于 (0,0,0)

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{X} \rightarrow w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha & s & u_0 & 0 \\ 0 & \beta & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



具有旋转和平移的相机





允许相机平移

内参假设

外参假设


• 无旋转 (No rotation)

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{t} \end{bmatrix} \mathbf{X} \quad \rightarrow \quad w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha & 0 & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & t_x \\ 0 & 1 & 0 & t_y \\ 0 & 0 & 1 & t_z \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



点的3D旋转

绕着坐标轴**逆时针**旋转：



$$\mathbf{R} = R_z(\gamma)R_y(\beta)R_x(\alpha)$$

$$R_x(\alpha) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \alpha & -\sin \alpha \\ 0 & \sin \alpha & \cos \alpha \end{bmatrix}$$

$$R_y(\beta) = \begin{bmatrix} \cos \beta & 0 & \sin \beta \\ 0 & 1 & 0 \\ -\sin \beta & 0 & \cos \beta \end{bmatrix}$$

$$R_z(\gamma) = \begin{bmatrix} \cos \gamma & -\sin \gamma & 0 \\ \sin \gamma & \cos \gamma & 0 \\ 0 & 0 & 1 \end{bmatrix}$$



允许相机旋转

$$\mathbf{x} = \mathbf{K}[\mathbf{R} \quad \mathbf{t}] \mathbf{X}$$



$$w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha & s & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



自由度

$$X = [x, y, z, 1]^T \rightarrow x = [u, v, w]^T$$

$$\mathbf{x} = \begin{bmatrix} \alpha r_{11} + s r_{21} & \alpha r_{12} + s r_{22} & \alpha r_{13} + s r_{23} & \alpha t_x + s t_y + u_0 t_z \\ \beta r_{21} & \beta r_{22} & \beta r_{23} & \beta t_y + v_0 t_z \\ r_{31} & r_{32} & r_{33} & t_z \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



自由度

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix} \mathbf{X}$$



5

?

6

$$w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha & s & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix} \begin{bmatrix} t_x \\ t_y \\ t_z \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$



相机成像模型中的自由度

➤ 内参矩阵 K —— 5个自由度

$$K = \begin{bmatrix} \alpha & s & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix}$$

- α, β : 分别代表 x 和 y 方向的焦距（以像素为单位），通常 $\alpha \neq \beta$ 表示像素非正方形。
- s : 倾斜因子（skew），描述图像坐标轴是否正交，理想情况下为0。
- u_0, v_0 : 主点坐标（图像中心在像素坐标系中的位置）。

☑共5个独立参数: $\alpha, \beta, s, u_0, v_0$, 所以实际自由度是5。



相机成像模型中的自由度

➤ 外参矩阵 $[R|t]$ —— 6个自由度

$$[R|t] = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \end{bmatrix}$$

- R 是 3×3 旋转矩阵，描述相机相对于世界坐标系的旋转。虽然它有9个元素，但受正交约束 ($R^T R = I, \det(R) = 1$)，**只有3个独立参数**（如欧拉角或轴角表示）。
- $t = [t_x, t_y, t_z]^T$ 是平移向量，描述相机原点在世界坐标系中的位置，有3个独立参数。
- ☒ **共6个独立参数**：3个旋转 + 3个平移

$$R_x(\alpha) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \alpha & -\sin \alpha \\ 0 & \sin \alpha & \cos \alpha \end{bmatrix}$$

$$R_y(\beta) = \begin{bmatrix} \cos \beta & 0 & \sin \beta \\ 0 & 1 & 0 \\ -\sin \beta & 0 & \cos \beta \end{bmatrix}$$

$$R_z(\gamma) = \begin{bmatrix} \cos \gamma & -\sin \gamma & 0 \\ \sin \gamma & \cos \gamma & 0 \\ 0 & 0 & 1 \end{bmatrix}$$



$$X = [x, y, z, 1]^T \rightarrow x = [u, v, w]^T$$

$$u = \frac{\alpha(r_{11}x + r_{12}y + r_{13}z + t_x) + s(r_{21}x + r_{22}y + r_{23}z + t_y) + u_0(r_{31}x + r_{32}y + r_{33}z + t_z)}{r_{31}x + r_{32}y + r_{33}z + t_z}$$

$$v = \frac{\beta(r_{21}x + r_{22}y + r_{23}z + t_y) + v_0(r_{31}x + r_{32}y + r_{33}z + t_z)}{r_{31}x + r_{32}y + r_{33}z + t_z}$$



消失点在图像上的坐标

➤ 什么是消失点?

在透视几何中，现实世界里的一组**平行线**（例如铁轨、大楼的边缘），在照片（图像平面）上看起来会汇聚到一个点。这个点就是**消失点**。

- **直观理解**：眼睛顺着平行线的方向看过去，视线与图像平面的交点。
- **数学定义**：消失点就是空间中**无穷远点**在图像上的投影。

➤ 齐次坐标中的“无穷远”

在齐次坐标中，一个三维空间点 X 表示为四维向量 $[X, Y, Z, W]^T$ 。

普通点（有限点）：当 $W \neq 0$ 时（通常取 $W = 1$ ），对应欧氏空间中的点 $(X/W, Y/W, Z/W)$ 。

无穷远点（方向）：当 $W = 0$ 时，该点位于无穷远处。此时， $[X, Y, Z, 0]^T$ 不再代表一个具体的位置，而是代表一个**方向向量** (X, Y, Z) 。



齐次坐标下平行线的交点 ($W = 0$)

➤ 两条平行的铁轨

假设在二维平面（比如地面 $z = 0$ ）上看两条平行的铁轨。为了方便计算，假设它们沿着 **X轴** 方向延伸。

- **直线 L_1 (左边的铁轨)**：方程是 $y = 1$ 。
- **直线 L_2 (右边的铁轨)**：方程是 $y = -1$ 。

显然，这两条线在普通几何里是平行的，永远不相交。但在射影几何里，我们要找它们的交点。

➤ 把直线写成“齐次向量”

在射影几何中，直线 $ax + by + c = 0$ 可以表示为一个向量 $l = [a, b, c]^T$ 。

- **对于 L_1 ($y - 1 = 0$)**: $a = 0, b = 1, c = -1$

$$l_1 = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}$$

- **对于 L_2 ($y + 1 = 0$)**: $a = 0, b = 1, c = 1$

$$l_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$



齐次坐标下平行线的交点 ($W = 0$)

➤ 用叉积求交点

交点 $x = l_1 \times l_2$ 。

- **x分量**: $(1)(1) - (-1)(1) = 1 + 1 = 2$
- **y分量**: $-((0)(1) - (-1)(0)) = 0$
- **z分量 (也就是齐次坐标的 w)**: $(0)(1) - (1)(0) = 0$

所以, 交点的齐次坐标是: $x_{intersection} = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}$

➤ 为什么这是无穷远点?

把这个齐次坐标还原成普通的 (x, y) 坐标, 规则是除以第三个分量 w : $x_{real} = \frac{2}{0}$, $y_{real} = \frac{0}{0}$

它不仅仅是“无穷远”, 它还携带了**方向信息**。可以对向量 $[2, 0, 0]^T$ 进行缩放, 得到最简形式: $x_{\infty} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$

这个向量 $[1, 0, 0]^T$ 的含义是: 1. $w = 0$: 确认它是无穷远点。 2. $(1, 0)$: 确认它的方向是 X 轴正方向。



齐次坐标下平行线的交点 ($W = 0$)

➤ 直线显式分量表达

假设在三维空间中有一条直线：

- 起点（或直线上任意一点）： $P_0 = (x_0, y_0, z_0)$
- 方向向量： $d = (d_x, d_y, d_z)$
- 参数： k （代表从起点出发沿方向移动的距离倍数）

那么，直线上任意一点 $P(x, y, z)$ 的坐标可以写成三个独立的方程：

$$\begin{cases} x(k) = x_0 + k \cdot d_x \\ y(k) = y_0 + k \cdot d_y \\ z(k) = z_0 + k \cdot d_z \end{cases}$$



齐次坐标下平行线的交点 ($W = 0$)

➤ 齐次坐标：从“有限点”到“无穷远点”

将上面点的显式坐标写成**齐次坐标**的形式。对于直线上任意一个有限的点 (k 是有限值)，其齐次坐标为：

$$\mathbf{P}_{hom} = \begin{bmatrix} x_0 + kd_x \\ y_0 + kd_y \\ z_0 + kd_z \\ 1 \end{bmatrix}$$

要找这条直线在**无穷远处**的点（也就是消失点对应的空间点）。这意味着让 $k \rightarrow \infty$ 。**提取公因子** k 如下：

$$\mathbf{P}_{hom} = \begin{bmatrix} k(\frac{x_0}{k} + d_x) \\ k(\frac{y_0}{k} + d_y) \\ k(\frac{z_0}{k} + d_z) \\ 1 \end{bmatrix}$$



齐次坐标下平行线的交点 ($W = 0$)

➤ 齐次坐标：从“有限点”到“无穷远点”

在齐次坐标中，所有分量同乘或同除以一个非零常数，代表的点是同一个点。为了方便取极限，我们把整个向量除以 k ：

$$\mathbf{P}'_{hom} = \frac{1}{k} \mathbf{P}_{hom} = \begin{bmatrix} \frac{x_0}{k} + d_x \\ \frac{y_0}{k} + d_y \\ \frac{z_0}{k} + d_z \\ \frac{1}{k} \end{bmatrix}$$

现在，让 $k \rightarrow \infty$ ： $-\frac{x_0}{k} \rightarrow 0$ $-\frac{y_0}{k} \rightarrow 0$ $-\frac{z_0}{k} \rightarrow 0$ $-\frac{1}{k} \rightarrow 0$

于是得到： $\mathbf{P}_{\infty} = \begin{bmatrix} d_x \\ d_y \\ d_z \\ 0 \end{bmatrix}$




消失点 = 来自无穷远的投影

$$\mathbf{p} = \mathbf{K}[\mathbf{R} \quad \mathbf{t}] \begin{bmatrix} x \\ y \\ z \\ 0 \end{bmatrix} \Rightarrow \mathbf{p} = \mathbf{K}\mathbf{R} \begin{bmatrix} x \\ y \\ z \end{bmatrix} \Rightarrow \mathbf{p} = \mathbf{K} \begin{bmatrix} x_R \\ y_R \\ z_R \end{bmatrix}$$

$$w \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & u_0 \\ 0 & f & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_R \\ y_R \\ z_R \end{bmatrix} \Rightarrow \begin{aligned} u &= \frac{fx_R}{z_R} + u_0 \\ v &= \frac{fy_R}{z_R} + v_0 \end{aligned}$$



消失点 = 来自无穷远的投影





消失点 = 来自无穷远的投影

已知空间中一组平行线的方向向量 d ，以及相机的参数（内参 K 和外参旋转 R ），如何算出这组平行线在照片上汇聚的那个点 (u,v) 的具体位置？

➤ 定义空间中的直线与无穷远点

- $d = [d_x, d_y, d_z]^T$ ：空间中平行线的**方向向量**。
- $P = P_0 + kd$ ：这是直线的参数方程。 P_0 是起点， k 是距离参数。
- $P \approx kd \quad (k \rightarrow \infty)$ ：当 k 趋向于无穷大时，起点 P_0 的影响可以忽略不计。此时，直线上的点主要由方向 d 决定。这在数学上对应了齐次坐标中的“无穷远点”概念（即第四维为0）。

➤ 投影公式的核心变换

$$p = KRd$$

普通的投影公式是 $p = K[R|t]P$ 。但因为在处理无穷远点（方向向量），平移向量 t 被消去了。所以公式简化为：先旋转（ R ），再投影（ K ）。



消失点 = 来自无穷远的投影

➤ 求解 (u,v)



$$\begin{bmatrix} u \\ v \\ w \end{bmatrix} = \mathbf{KR} \begin{bmatrix} d_x \\ d_y \\ d_z \end{bmatrix} = \begin{bmatrix} fr_{11}d_x + fr_{12}d_y + fr_{13}d_z + u_0(r_{31}d_x + r_{32}d_y + r_{33}d_z) \\ fr_{21}d_x + fr_{22}d_y + fr_{23}d_z + v_0(r_{31}d_x + r_{32}d_y + r_{33}d_z) \\ r_{31}d_x + r_{32}d_y + r_{33}d_z \end{bmatrix}$$

$$u = \frac{f(r_{11}d_x + r_{12}d_y + r_{13}d_z) + u_0(r_{31}d_x + r_{32}d_y + r_{33}d_z)}{r_{31}d_x + r_{32}d_y + r_{33}d_z}$$

$$v = \frac{f(r_{21}d_x + r_{22}d_y + r_{23}d_z) + v_0(r_{31}d_x + r_{32}d_y + r_{33}d_z)}{r_{31}d_x + r_{32}d_y + r_{33}d_z}$$

需要记住的要点

- 消失点和消失线
- 针孔相机模型和相机投影矩阵
- 齐次坐标



$$\mathbf{x} = \mathbf{K}[\mathbf{R} \quad \mathbf{t}] \mathbf{X}$$

$$(x, y) \Rightarrow \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$



需要记住的要点

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix} \mathbf{X}$$

模拟相机

$$\underbrace{\mathbf{x}}_{\text{Unknown}} = \mathbf{K} \underbrace{\left[\mathbf{R} \quad \mathbf{t} \right]}_{\text{Known}} \underbrace{\mathbf{X}}_{\text{Known}}$$



相机标定

$$\underbrace{\mathbf{x}}_{\text{Known}} = \underbrace{\mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}}_{\text{Unknown}} \underbrace{\mathbf{X}}_{\text{Known}}$$

$\mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}$

内参标定 外参标定 / 姿态估计



三维重建 I

$$\underbrace{\mathbf{x}}_{\text{Known}} = \underbrace{\mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}}_{\text{Known}} \underbrace{\mathbf{X}}_{\text{Unknown}}$$



三维重建 II

$$\underbrace{\mathbf{x}}_{\text{Known}} = \mathbf{K} \underbrace{\begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}}_{\text{Unknown Unknown}} \mathbf{X}$$



相机标定

$$\underbrace{\mathbf{x}}_{\text{Known}} = \underbrace{\mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}}_{\text{Unknown}} \underbrace{\mathbf{X}}_{\text{Known}}$$

$\mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}$

内参标定 外参标定 / 姿态估计



13.2 相机标定（相机反解）



直接线性变换 (Direct Linear Transformation, DLT)



如何标定相机（相机反解）？

$$\mathbf{x} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix} \mathbf{X}$$


$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} * & * & * & * \\ * & * & * & * \\ * & * & * & * \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$



标定相机

使用具有已知几何结构的场景


- 将图像上的二维点与三维空间点进行对应匹配
- 获取最小二乘解（或者非线性解）



标定相机

使用具有已知几何结构的场景

- 将图像上的二维点与三维空间点进行对应匹配
- 获取最小二乘解（或者非线性解）



已知二维图像坐标



$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \\ m_{31} & m_{32} & m_{33} & m_{34} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

已知三维图像坐标




未知的相机投影矩阵

夫到家

ChArUco标定板

- 一种专为计算机视觉设计的混合式相机标定工具。
- 左侧是标准的黑白棋盘格图案，其角点在图像处理中可被精确检测并达到亚像素级精度，是计算相机畸变和焦距的关键依据。
- 中间部分是嵌入在棋盘格白色区域内的多个小型ArUco标记，每个标记都有唯一的二进制编码ID，即使在部分遮挡、倾斜或光照不佳的情况下也能被快速、准确地识别和定位。





标定相机

已知
二维图像坐标

880 214
43 203
270 197
886 347
745 302
943 128
476 590
419 214
317 335
783 521
235 427
665 429
655 362
427 333
412 415
746 351
434 415
525 234
716 308
602 187



已知
三维图像坐标

312.747 309.140 30.086
305.796 311.649 30.356
307.694 312.358 30.418
310.149 307.186 29.298
311.937 310.105 29.216
311.202 307.572 30.682
307.106 306.876 28.660
309.317 312.490 30.230
307.435 310.151 29.318
308.253 306.300 28.881
306.650 309.301 28.905
308.069 306.831 29.189
309.671 308.834 29.029
308.255 309.955 29.267
307.546 308.613 28.963
311.036 309.206 28.913
307.518 308.175 29.069
309.950 311.262 29.990
312.160 310.772 29.080
311.988 312.709 30.514



未知的相机投影矩阵



已知
二维图像坐标

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \\ m_{31} & m_{32} & m_{33} & m_{34} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

已知
三维图像坐标

$$\begin{aligned} su &= m_{11}X + m_{12}Y + m_{13}Z + m_{14} \\ sv &= m_{21}X + m_{22}Y + m_{23}Z + m_{24} \\ s &= m_{31}X + m_{32}Y + m_{33}Z + m_{34} \end{aligned}$$

$$(m_{31}X + m_{32}Y + m_{33}Z + m_{34})u = m_{11}X + m_{12}Y + m_{13}Z + m_{14}$$

$$(m_{31}X + m_{32}Y + m_{33}Z + m_{34})v = m_{21}X + m_{22}Y + m_{23}Z + m_{24}$$

$$m_{31}uX + m_{32}uY + m_{33}uZ + m_{34}u = m_{11}X + m_{12}Y + m_{13}Z + m_{14}$$

$$m_{31}vX + m_{32}vY + m_{33}vZ + m_{34}v = m_{21}X + m_{22}Y + m_{23}Z + m_{24}$$



未知的相机投影矩阵



已知
二维图像坐标

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \\ m_{31} & m_{32} & m_{33} & m_{34} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

已知
三维图像坐标

$$m_{31}uX + m_{32}uY + m_{33}uZ + m_{34}u = m_{11}X + m_{12}Y + m_{13}Z + m_{14}$$

$$m_{31}vX + m_{32}vY + m_{33}vZ + m_{34}v = m_{21}X + m_{22}Y + m_{23}Z + m_{24}$$

$$0 = m_{11}X + m_{12}Y + m_{13}Z + m_{14} - m_{31}uX - m_{32}uY - m_{33}uZ - m_{34}u$$

$$0 = m_{21}X + m_{22}Y + m_{23}Z + m_{24} - m_{31}vX - m_{32}vY - m_{33}vZ - m_{34}v$$



未知的相机投影矩阵



已知
二维图像坐标

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \\ m_{31} & m_{32} & m_{33} & m_{34} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

已知
三维图像坐标

$$0 = m_{11}X + m_{12}Y + m_{13}Z + m_{14} - m_{31}uX - m_{32}uY - m_{33}uZ - m_{34}u$$

$$0 = m_{21}X + m_{22}Y + m_{23}Z + m_{24} - m_{31}vX - m_{32}vY - m_{33}vZ - m_{34}v$$

- 方法一：齐次线性方程组。使用**SVD**
求解 m 的元素

$$\begin{bmatrix} X_1 & Y_1 & Z_1 & 1 & 0 & 0 & 0 & 0 & -u_1X_1 & -u_1Y_1 & -u_1Z_1 & -u_1 \\ 0 & 0 & 0 & 0 & X_1 & Y_1 & Z_1 & 1 & -v_1X_1 & -v_1Y_1 & -v_1Z_1 & -v_1 \\ & & & & & & \vdots & & & & & \\ X_n & Y_n & Z_n & 1 & 0 & 0 & 0 & 0 & -u_nX_n & -u_nY_n & -u_nZ_n & -u_n \\ 0 & 0 & 0 & 0 & X_n & Y_n & Z_n & 1 & -v_nX_n & -v_nY_n & -v_nZ_n & -v_n \end{bmatrix} \begin{bmatrix} m_{11} \\ m_{12} \\ m_{13} \\ m_{14} \\ m_{21} \\ m_{22} \\ m_{23} \\ m_{24} \\ m_{31} \\ m_{32} \\ m_{33} \\ m_{34} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}$$

$Am = 0$ 形式



利用SVD求解齐次线性方程组 (DLT算法)

➤ 优化问题构建

由于噪声的存在或数据量的冗余，方程组 $A\mathbf{m} = \mathbf{0}$ 往往没有精确的非零解。因此，将问题转化为一个**带约束的最小二乘优化问题**。需要寻找一个非零向量 $\mathbf{m}$ ，使得残差 $\|A\mathbf{m}\|^2$ 最小。为了避免平凡解 $\mathbf{m} = \mathbf{0}$ ，必须施加范数约束。

目标函数： $\min_{\mathbf{m}} \|A\mathbf{m}\|^2$ ； **约束条件：** $\|\mathbf{m}\|^2 = 1$

➤ 拉格朗日乘数法

引入拉格朗日乘子 λ ，构造拉格朗日函数 $L(\mathbf{m}, \lambda)$ ：

$$L(\mathbf{m}, \lambda) = \|A\mathbf{m}\|^2 - \lambda(\|\mathbf{m}\|^2 - 1)$$

展开范数项（注意 $\|\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{x}$ ）：

$$L(\mathbf{m}, \lambda) = (A\mathbf{m})^T (A\mathbf{m}) - \lambda(\mathbf{m}^T \mathbf{m} - 1) = \mathbf{m}^T A^T A \mathbf{m} - \lambda(\mathbf{m}^T \mathbf{m} - 1)$$



利用SVD求解齐次线性方程组 (DLT算法)

➤ 拉格朗日乘数法

引入拉格朗日乘子 λ , 构造拉格朗日函数 $L(\mathbf{m}, \lambda)$:

$$L(\mathbf{m}, \lambda) = \|\mathbf{A}\mathbf{m}\|^2 - \lambda(\|\mathbf{m}\|^2 - 1)$$

展开范数项 (注意 $\|\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{x}$) :

$$L(\mathbf{m}, \lambda) = (\mathbf{A}\mathbf{m})^T (\mathbf{A}\mathbf{m}) - \lambda(\mathbf{m}^T \mathbf{m} - 1) = \mathbf{m}^T \mathbf{A}^T \mathbf{A} \mathbf{m} - \lambda(\mathbf{m}^T \mathbf{m} - 1)$$

对 $\mathbf{m}$ 求偏导并令其为 0: $\frac{\partial L}{\partial \mathbf{m}} = 2\mathbf{A}^T \mathbf{A} \mathbf{m} - 2\lambda \mathbf{m} = \mathbf{0}$; 整理得: $\mathbf{A}^T \mathbf{A} \mathbf{m} = \lambda \mathbf{m}$

结论: 最优解 $\mathbf{m}$ 必须是矩阵 $\mathbf{A}^T \mathbf{A}$ 的**特征向量**, 而对应的拉格朗日乘子 λ 即为该特征向量对应的**特征值**。

此时, 目标函数的值为:

$$\|\mathbf{A}\mathbf{m}\|^2 = \mathbf{m}^T (\mathbf{A}^T \mathbf{A} \mathbf{m}) = \mathbf{m}^T (\lambda \mathbf{m}) = \lambda(\mathbf{m}^T \mathbf{m}) = \lambda$$

因为我们要最小化 $\|\mathbf{A}\mathbf{m}\|^2$, 所以 $\mathbf{m}$ 应当取 $\mathbf{A}^T \mathbf{A}$ 的**最小特征值对应的特征向量**。



利用SVD求解齐次线性方程组 (DLT算法)

➤ 从特征分解到奇异值分解 (SVD)

虽然理论上可以通过计算 $A^T A$ 的特征分解来求解，但在实际数值计算中，直接对 A 进行**奇异值分解 (SVD)** 是更优的选择。为什么使用 SVD？

- 数值稳定性：** 计算 $A^T A$ 会导致矩阵的条件数平方化，如果 A 本身接近秩亏， $A^T A$ 会变得极度病态，导致精度丢失。SVD 直接作用于 A ，避免了这一问题。
- 数学等价性：** 根据 SVD 的定义，矩阵 A 可以分解为： $A = U\Sigma V^T$ ，其中：
 - U 是 $2n \times 2n$ 的正交矩阵，满足 $U^T U = I$
 - Σ 是 $2n \times 12$ 的对角矩阵，对角线元素 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{12} \geq 0$ 为奇异值。
 - V 是 12×12 的正交矩阵，其列向量 $v_1, \dots, v_{12}$ 即为右奇异向量。

将 SVD 代入 $A^T A$ ：

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T \Sigma)V^T$$

可以看出， $A^T A$ 的特征分解形式正是 $V(\Sigma^T \Sigma)V^T$ 。这意味着： $A^T A$ 的**特征向量**就是 V 的列向量。 $A^T A$ 的**特征值** λ_i 等于奇异值的平方 σ_i^2 。



未知的相机投影矩阵

已知
二维图像坐标

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \\ m_{31} & m_{32} & m_{33} & m_{34} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

已知
三维图像坐标

$$0 = m_{11}X + m_{12}Y + m_{13}Z + m_{14} - m_{31}uX - m_{32}uY - m_{33}uZ - m_{34}u$$

$$0 = m_{21}X + m_{22}Y + m_{23}Z + m_{24} - m_{31}vX - m_{32}vY - m_{33}vZ - m_{34}v$$

- 方法一：齐次线性方程组。使用SVD求解 m 的元素

$$\begin{bmatrix} X_1 & Y_1 & Z_1 & 1 & 0 & 0 & 0 & 0 & -u_1X_1 & -u_1Y_1 & -u_1Z_1 \\ 0 & 0 & 0 & 0 & X_1 & Y_1 & Z_1 & 1 & -v_1X_1 & -v_1Y_1 & -v_1Z_1 \\ & & & & & \vdots & & & & & \\ X_n & Y_n & Z_n & 1 & 0 & 0 & 0 & 0 & -u_nX_n & -u_nY_n & -u_nZ_n \\ 0 & 0 & 0 & 0 & X_n & Y_n & Z_n & 1 & -v_nX_n & -v_nY_n & -v_nZ_n \end{bmatrix} \begin{bmatrix} m_{11} \\ m_{12} \\ m_{13} \\ m_{14} \\ m_{21} \\ m_{22} \\ m_{23} \\ m_{24} \\ m_{31} \\ m_{32} \\ m_{33} \\ m_{34} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

为了求解这12个未知参数 m_{ij} ，需要固定一个尺度。通常假设 $m_{34} \neq 0$ ，并令 $m_{34} = 1$ 。然后，将所有包含未知参数 m_{ij} 的项移到等式左边，将已知的项移到右边。

$Am = 0$ 形式



未知的相机投影矩阵



已知
二维图像坐标

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \\ m_{31} & m_{32} & m_{33} & m_{34} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

已知
三维图像坐标

$$0 = m_{11}X + m_{12}Y + m_{13}Z + m_{14} - m_{31}uX - m_{32}uY - m_{33}uZ - m_{34}u$$

$$0 = m_{21}X + m_{22}Y + m_{23}Z + m_{24} - m_{31}vX - m_{32}vY - m_{33}vZ - m_{34}v$$

➤ 方法二：非齐次线性方程组。求解m的元素

$$\begin{bmatrix} X_1 & Y_1 & Z_1 & 1 & 0 & 0 & 0 & 0 & -u_1X_1 & -u_1Y_1 & -u_1Z_1 \\ 0 & 0 & 0 & 0 & X_1 & Y_1 & Z_1 & 1 & -v_1X_1 & -v_1Y_1 & -v_1Z_1 \\ & & & & & & \vdots & & & & \\ X_n & Y_n & Z_n & 1 & 0 & 0 & 0 & 0 & -u_nX_n & -u_nY_n & -u_nZ_n \\ 0 & 0 & 0 & 0 & X_n & Y_n & Z_n & 1 & -v_nX_n & -v_nY_n & -v_nZ_n \end{bmatrix} \begin{bmatrix} m_{11} \\ m_{12} \\ m_{13} \\ m_{14} \\ m_{21} \\ m_{22} \\ m_{23} \\ m_{24} \\ m_{31} \\ m_{32} \\ m_{33} \end{bmatrix} = \begin{bmatrix} u_1 \\ v_1 \\ \vdots \\ u_n \\ v_n \end{bmatrix}$$

Ax=b 形式

$$x = (A^T A)^{-1} A^T b$$



直接线性变换 (Direct Linear Transformation, DLT)

基于 DLT 的相机标定

目标： 根据已知的 3D 空间点 (X, Y, Z) 及其对应的 2D 图像投影点 (x, y) ，来估算相机的投影矩阵 M 。

第一步： 对每一组点对，在齐次坐标系下写出投影方程：

$$s \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = M \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

第二步： 将上式展开为每个点提供两个线性方程，然后将所有点的方程重新排列，构建一个齐次线性方程组 $\mathbf{A} \mathbf{m} = \mathbf{0}$ （其中 $\mathbf{m}$ 是由矩阵 M 中 12 个未知数构成的向量）。

第三步： 使用 SVD 求解该方程组得到 M ，最后将其重塑为 3×4 的矩阵形式。

第四步：（可选）通过 RQ 分解，将投影矩阵 M 拆解为内参矩阵 (K) 和外参矩阵 (旋转矩阵 R 、平移向量 T)。

补充说明：

- 该方法简单高效，但缺点是无法模拟镜头畸变。
- 在实际应用中，通常把它作为初始解，后续再接入非线性优化（即最小化重投影误差）来进行精细调整。
- 该方法在摄影测量和计算机视觉领域被广泛使用。